



Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης

Πολυτεχνική Σχολή

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Τομέας Ηλεκτρονικής και Υπολογιστών
Εργαστήριο Επεξεργασίας Πληροφορίας και Υπολογισμών

**ΣΥΛΛΟΓΗ ΚΑΙ ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ
ΚΑΤΑΝΑΛΩΣΗΣ ΕΝΕΡΓΕΙΑΣ ΚΙΝΗΤΩΝ
ΤΗΛΕΦΩΝΩΝ ΜΕ ΧΡΗΣΗ ΤΕΧΝΙΚΩΝ
ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ**

Διπλωματική Εργασία

Γεώργιος Μπαλαούρας

Επιβλέποντες: Ανδρέας Λ. Συμεωνίδης, Αναπληρωτής Καθηγητής, ΑΠΘ
Εμμανουήλ Τσαρδούλιας, Μεταδιδακτορικός Ερευνητής, ΑΠΘ

Θεσσαλονίκη, Οκτώβριος 2020

Ευχαριστίες

Αρχικά, θα ήθελα να ευχαριστήσω τον αναπληρωτή καθηγητή κ. Ανδρέα Συμεωνίδη, για την εμπιστοσύνη που μου έδειξε με την ανάθεση της παρούσας διπλωματικής εργασίας, καθώς και για την έμπρακτη βοήθεια που μου έδωσε τις στιγμές που τη χρειάστηκα.

Έπειτα, ευχαριστώ ιδιαίτερα τον συνεπιβλέποντα της διπλωματικής, μεταδιδακτορικό ερευνητή, Εμμανουήλ Τσαρδούλια, για τη συνεργασία που είχαμε, τη συνεχή παρακολούθηση και επίβλεψη της εργασίας στο διάστημα αυτών των έξι μηνών. Ένα μεγάλο ευχαριστώ και στον υποψήφιο διδάκτορα, Θωμά Καρανικιώτη, για τις πολύτιμες συμβουλές του σε επιμέρους θέματα που παρουσιάστηκαν.

Επιπλέον, αισθάνομαι την ανάγκη να ευχαριστήσω όλους τους χρήστες της εφαρμογής, που συμμετείχαν ανώνυμα στη συλλογή δεδομένων συνεισφέροντας στην επιτυχή ολοκλήρωση της εργασίας, η οποία χωρίς αυτούς δε θα ήταν εφικτή.

Ακόμα, ένα εγκάρδιο ευχαριστώ στα αδέρφια μου, Μαρία και Ευριπίδη, και τους γονείς μου, Στέφανο και Όλγα, για τη συνεχή στήριξη τους σε κάθε βήμα της ζωής μου.

Τέλος, οφείλω ένα μεγάλο ευχαριστώ στους φίλους μου, για τις όμορφες στιγμές που ζήσαμε καθ' όλη τη διάρκεια των σπουδών μας και στην κοπέλα μου, Σοφία, για την ψυχολογική υποστήριξη και την υπομονή που επέδειξε στο διάστημα των σπουδών μου.

Σας ευχαριστώ όλους!

Γιώργος

Περίληψη

Στη σύγχρονη εποχή είναι αδιαμφισβήτητη πραγματικότητα πως τα «έξυπνα» κινητά τηλέφωνα αποτελούν κυρίαρχο στοιχείο της ζωής του ανθρώπου. Με το πάτημα ενός κουμπιού μπορεί κάποιος να ενημερωθεί για τις εξελίξεις παγκοσμίως, να επικοινωνήσει με άτομα από την άλλη άκρη του πλανήτη και να ψυχαγωγηθεί. Ειδικότερα, κύριος πόλος έλξης τους αποτελεί η φορητότητα τους, η οποία κατέστη δυνατή μέσω της αξιοποίησης των μπαταριών. Ωστόσο, αυτές διαθέτουν συγκεκριμένο αριθμό επαναφορτίσεων και συνεπώς, η διάρκεια ζωής μιας συσκευής εξαρτάται άμεσα από τον τύπο χρήσης της και τη στρατηγική επαναφόρτισης της.

Η παρούσα διπλωματική εργασία ασχολείται με την ανάλυση της χρήσης των κινητών τηλεφώνων και την εκτίμηση της κατανάλωσης ενέργειας (energy drain) της μπαταρίας τους. Αρχικά, για τη συλλογή των δεδομένων αναπτύχθηκε η εφαρμογή BatteryApp, η οποία περιοδικά καταγράφει τις λειτουργίες της συσκευής και τις πληροφορίες της μπαταρίας. Στη συνέχεια, ακολουθεί η ομαδοποίηση (clustering) όμοιων τύπων χρήσεων των συσκευών μέσω της ιεραρχικής ομαδοποίησης, η οποία δεν επιβάλει την εξ' αρχής (*apriori*) επιλογή συγκεκριμένου αριθμού ομάδων και δεν εισάγει περιορισμούς στη συνάρτηση απόστασης που θα επιλεχθεί. Έπειτα, αυτή αξιολογείται ως προς το περιεχόμενό της, έτσι ώστε να επιλεγούν εκείνες οι ομάδες που περιέχουν την περισσότερη πληροφορία. Τέλος, για την εκτίμηση του energy drain, χρησιμοποιήθηκαν ένα απλό γραμμικό μοντέλο, δύο παραλλαγές της γραμμικής παλινδρόμησης, όπου εισάγεται η έννοια της ποινής (Ridge και Lasso Regression), και ένα μη γραμμικό μοντέλο, που ανήκει στην κατηγορία του Ensemble Learning (eXtreme Gradient Boosted trees), με τη διαδικασία μάθησης των παραμέτρων να πραγματοποιείται σε κάθε μια από τις επιλεγμένες ομάδες ξεχωριστά.

Γεώργιος Μπαλαούρας
mpalaourg@ece.auth.gr

Τμήμα Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών
Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης, Ελλάδα
Οκτώβριος 2020

TITLE**DATA COLLECTION AND ANALYSIS OF ENERGY CONSUMPTION OF MOBILE PHONES USING MACHINE LEARNING TECHNIQUES****Abstract**

In a modern-day society there is the consensus that smartphones have a dominant role in everyday life. By just pressing a button, someone can not only get up to speed with the current events on a global scale, but also get in touch with people all over the world and find various forms of entertainment. In particular, one of the features that makes smartphones so attractive is the portability they offer, since they utilize batteries. However, batteries have a certain amount of charges in their disposal, consequently the lifespan of a device is directly correlated to its utilization, as well as its charging strategy.

The current thesis focuses on the analysis of mobile phones' usage and the prediction of the battery's energy drain. To begin with, for data collection the application "BatteryApp", which periodically keeps record of the device's usage and the battery information, was developed. The next step is the grouping of similar uses of devices through Hierarchical Clustering, which does not require an a priori selection for a specific cluster number and does not set limitations regarding the chosen distance function. After that, it was assessed based on its content in order to select the clusters with the higher information value. Lastly, the prediction of the energy drain was constructed by employing a simple linear model, two variants of linear regression, where the penalty concept is introduced (Ridge and Lasso Regression), and a non-linear model, which belongs to the Ensemble Learning category (eXtreme Gradient Boosted trees), with the parameters' learning procedure being applied to each selected cluster individually.

Georgios Balaouras
mpalaourg@ece.auth.gr
Electrical & Computer Engineering Department
Aristotle University of Thessaloniki, Greece
October 2020

Περιεχόμενα

Ευχαριστίες	ii
Περίληψη.....	iv
Abstract.....	vi
Περιεχόμενα	viii
Λίστα εικόνων	x
Λίστα Πινάκων	xii
1 Εισαγωγή	1
1.1 Κίνητρα.....	1
1.2 Περιγραφή του προβλήματος	2
1.3 Προτεινόμενη αντιμετώπιση	2
1.4 Συνεισφορά της διπλωματικής.....	2
1.5 Διάρθρωση εγγράφου.....	3
2 Θεωρητικό Υπόβαθρο	4
2.1 Μπαταρία	4
2.1.1 Γλωσσάρι όρων μπαταρίας	4
2.1.2 Κατηγορίες Μπαταριών	5
2.1.3 Μπαταρίες ιόντων λιθίου	5
2.1.4 Μπαταρίες ιόντων λιθίου πολυμερούς	6
2.2 Τεχνητή νοημοσύνη.....	6
2.2.1 Εισαγωγή στη μηχανική μάθηση	6
2.2.2 Υπολογιστές και νοημοσύνη	7
2.2.3 Τύποι προβλημάτων	8
2.2.4 Ομαδοποίηση - Clustering	8
2.2.5 Παλινδρόμηση - Regression.....	13
3 Σχετική Βιβλιογραφία	17
3.1 Συμβατικές τεχνικές	17
3.1.1 Τάση Ανοιχτού Κυκλώματος.....	17
3.1.2 Ρεύμα Εκφόρτισης - Coulomb Counting Method	18
3.1.3 Εσωτερική και Σύνθετη Αντίσταση	18
3.2 Προσαρμοστικά φίλτρα	19
3.2.1 Kalman Filter (KF)	19
3.2.2 Extended Kalman Filter (EKF).....	20
3.2.3 Unscented Kalman Filter (UKF)	21
3.3 Τεχνικές μηχανικής μάθησης	22
3.3.1 Γενετικοί αλγόριθμοι	22

	Περιεχόμενα
3.3.2 Νευρωνικά δίκτυα.....	22
3.3.3 Μηχανές διανυσμάτων υποστήριξης (SVM).....	23
4 Μεθοδολογία.....	25
4.1 Ανάπτυξη εφαρμογής BatteryApp	25
4.1.1 Υποσυστήματα εφαρμογής	25
4.1.2 Συλλογή δεδομένων.....	28
4.2 Ανάλυση δεδομένων.....	29
4.2.1 Προεπεξεργασία αρχείων	30
4.2.2 Ορισμός παραθύρων χρήσης.....	30
4.2.3 Υπολογισμός μεταβλητής εξόδου (energy drain).....	31
4.2.4 Ομαδοποίηση παραθύρων χρήσης.....	32
4.2.5 Παλινδρόμηση για εκτίμηση μεταβλητής εξόδου	34
5 Πειράματα & Αποτελέσματα	37
5.1 Στατιστικά αρχείων.....	37
5.2 Πείραμα 1: Μεμονωμένος χρήστης	39
5.3 Πείραμα 2: Πολλαπλοί χρήστες	49
5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας.....	59
6 Σύνοψη	70
6.1 Προβλήματα	70
6.2 Συμπεράσματα	70
6.3 Μελλοντική Εργασία	71
Βιβλιογραφία	73

Λίστα εικόνων

Εικόνα 1: Αριθμός μοναδικών smartphone χρηστών παγκοσμίως.....	1
Εικόνα 2: Ροή ιόντων σε μπαταρία ιόντων λιθίου [Πηγή]	5
Εικόνα 3: Στάδια και ροή μηχανικής μάθησης [Πηγή]	7
Εικόνα 4: Παραδείγματα ομαδοποίησης βάσει ομοιοτήτων [Πηγή]	9
Εικόνα 5: Η Cophenetic απόσταση δύο σημείων	12
Εικόνα 6: Υπολογισμός τελικής εκτίμησης στη συλλογική μάθηση [Πηγή]	15
Εικόνα 7: Διακύμανση της σύνθετης αντίστασης	19
Εικόνα 8: Η συνεχής διαδικασία πρόβλεψης και διόρθωσης των Bayesian φίλτρων.....	20
Εικόνα 9: Σύγκριση μετασχηματισμού μεταξύ EKF και UKF [Πηγή]	21
Εικόνα 10: Η αρχιτεκτονική του νευρωνικού δικτύου πρόσθιας τροφοδότησης [30]	23
Εικόνα 11: Η δομή του κοινού αλγορίθμου UKF και SVM [34]	24
Εικόνα 12: Στιγμιότυπο εφαρμογής BatteryApp.....	26
Εικόνα 13: Μήνυμα σφάλματος περιόδου δειγματοληψίας	26
Εικόνα 14: Μηνύματα ενημέρωσης χρήστη για τη μεταφόρτωση αρχείου	27
Εικόνα 15: Ειδοποίηση υπενθύμισης για χρήση εφαρμογής	27
Εικόνα 16: Ειδοποίηση εκτέλεσης εφαρμογής στο παρασκήνιο	27
Εικόνα 17: Επικοινωνία των διαφόρων υποσυστημάτων της εφαρμογής	29
Εικόνα 18: Μέση τιμή roughness penalty για διαφορετικά μεγέθη παραθύρων	31
Εικόνα 19: Heatmap συσχέτισης χαρακτηριστικών εισόδου και εξόδου.....	32
Εικόνα 20: Heatmap συσχέτισης αρχικών χαρακτηριστικών χρήσης κινητού	33
Εικόνα 21: Heatmap συσχέτισης τελικών χαρακτηριστικών χρήσης κινητού	34
Εικόνα 22: Τύποι αρχείων.....	37
Εικόνα 23: Ιστόγραμμα μεταφορτωμένων αρχείων.....	37
Εικόνα 24: Ιστόγραμμα πτώσης επιπέδου μπαταρίας	38
Εικόνα 25: Αθροιστική συνάρτηση κατανομής πτώσης επιπέδου μπαταρίας	38
Εικόνα 26: Ιστόγραμμα χρονικής διάρκειας Session	39
Εικόνα 27: Αθροιστική συνάρτηση κατανομής χρονικής διάρκειας Session	39
Εικόνα 28: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=single [Πείραμα 1]	40
Εικόνα 29: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=complete [Πείραμα 1]	40
Εικόνα 30: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=average [Πείραμα 1].....	41
Εικόνα 31: Mean Silhouette ανά αριθμό ομάδων linkage=complete [Πείραμα 1]	41
Εικόνα 32: Mean Silhouette ανά αριθμό ομάδων linkage=average [Πείραμα 1]	41
Εικόνα 33: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 0]....	43
Εικόνα 34: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 1]....	43
Εικόνα 35: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 3]....	43
Εικόνα 36: Απεικόνιση ομάδων στον δισδιάστατο χώρο [Πείραμα 1]	44
Εικόνα 37: Απεικόνιση ομάδων στον τρισδιάστατο χώρο [Πείραμα 1].....	44
Εικόνα 38: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 1]	46
Εικόνα 39: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 1]	46
Εικόνα 40: Σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 1].....	47
Εικόνα 41: Σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 1].....	47
Εικόνα 42: Πρόβλεψη energy drain [selected model_1] [Πείραμα 1].....	48
Εικόνα 43: Ιστόγραμμα σφαλμάτων πρόβλεψης [selected model_1] [Πείραμα 1]	48
Εικόνα 44: Μεγένθυνση πρόβλεψης energy drain [selected model_1] [Πείραμα 1].....	49
Εικόνα 45: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=single [Πείραμα 2]	49
Εικόνα 46: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=complete [Πείραμα 2]	50
Εικόνα 47: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=average [Πείραμα 2].....	50
Εικόνα 48: Mean Silhouette ανά αριθμό ομάδων linkage=complete [Πείραμα 2]	50
Εικόνα 49: Mean Silhouette ανά αριθμό ομάδων linkage=average [Πείραμα 2]	51

Λίστα εικόνων

Εικόνα 50: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 0]	52
Εικόνα 51: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 1]	52
Εικόνα 52: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 2]	52
Εικόνα 53: Απεικόνιση ομάδων στον δισδιάστατο χώρο [Πείραμα 2].....	53
Εικόνα 54: Απεικόνιση ομάδων στον τρισδιάστατο χώρο [Πείραμα 2].....	53
Εικόνα 55: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 2]	55
Εικόνα 56: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 2]	55
Εικόνα 57: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_2] [Πείραμα 2]	55
Εικόνα 58: Σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 2].....	56
Εικόνα 59: Σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 2].....	57
Εικόνα 60: Σπουδαιότητα χαρακτηριστικών [model_2] [Πείραμα 2].....	57
Εικόνα 61: Πρόβλεψη energy drain [selected model_1] [Πείραμα 2].....	58
Εικόνα 62: Ιστόγραμμα σφαλμάτων πρόβλεψης [selected model_1] [Πείραμα 2]	58
Εικόνα 63: Μεγένθυνση πρόβλεψης energy drain [selected model_1] [Πείραμα 2]	59
Εικόνα 64: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=single [Πείραμα 3]	59
Εικόνα 65: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=complete [Πείραμα 3]	60
Εικόνα 66: Δενδρόγραμμα Ιεραρχικής ομαδοποίησης linkage=average [Πείραμα 3].....	60
Εικόνα 67: Mean Silhouette ανά αριθμό ομάδων linkage=complete [Πείραμα 3]	60
Εικόνα 68: Mean Silhouette ανά αριθμό ομάδων linkage=average [Πείραμα 3]	61
Εικόνα 69: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 0]	62
Εικόνα 70: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 1]	62
Εικόνα 71: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 3]....	62
Εικόνα 72: Απεικόνιση ομάδων στον δισδιάστατο χώρο [Πείραμα 3]	63
Εικόνα 73: Απεικόνιση ομάδων στον τρισδιάστατο χώρο [Πείραμα 3].....	63
Εικόνα 74: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 3]	65
Εικόνα 75: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 3]	65
Εικόνα 76: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_3] [Πείραμα 3]	65
Εικόνα 77: Σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 3].....	66
Εικόνα 78: Σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 3].....	67
Εικόνα 79: Σπουδαιότητα χαρακτηριστικών [model_3] [Πείραμα 3].....	67
Εικόνα 80: Πρόβλεψη energy drain [selected model_1] [Πείραμα 3].....	68
Εικόνα 81: Ιστόγραμμα σφαλμάτων πρόβλεψης [selected model_1] [Πείραμα 3]	68
Εικόνα 82: Μεγένθυνση πρόβλεψης energy drain [selected model_1] [Πείραμα 3].....	69

Λίστα Πινάκων


Πίνακας 1: Δεδομένα επεξήγησης απόστασης Gower.....	10
Πίνακας 2: Κανονικοποιημένες ομοιότητες S1, S2	10
Πίνακας 3: Μετατροπή σε επεξαργάσιμη μορφή της μεταβλητής Bool1	10
Πίνακας 4: Κανονικοποιημένη ομοιότητα S3	11
Πίνακας 5: Τελική απόσταση Gower	11
Πίνακας 6: Τελικά χαρακτηριστικά χρήσης κινητού	33
Πίνακας 7: Χαρακτηριστικά περιγραφής μπαταρίας.....	34
Πίνακας 8: Τελικά χαρακτηριστικά παλινδρόμησης	35
Πίνακας 9: Παράμετρος μεθόδου Ridge και Lasso.....	35
Πίνακας 10: Παράμετροι μεθόδου xgboost	35
Πίνακας 11: Αξιολόγηση ομαδοποίησης [Πείραμα 1]	42
Πίνακας 12: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_0] [Πείραμα 1]	45
Πίνακας 13: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_1] [Πείραμα 1]	45
Πίνακας 14: Αποτελέσματα επιλογής χαρακτηριστικών [Πείραμα 1].....	46
Πίνακας 15: Σπουδαιότερα χαρακτηριστικά μοντέλων [Πείραμα 1].....	47
Πίνακας 16: Αποτελέσματα ρύθμισης υπερπαραμέτρων [Πείραμα 1].....	48
Πίνακας 17: Αποτελέσματα σετ δεδομένων ελέγχου (test set) [Πείραμα 1]	48
Πίνακας 18: Αξιολόγηση ομαδοποίησης [Πείραμα 2]	51
Πίνακας 19: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_0] [Πείραμα 2]	54
Πίνακας 20: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_1] [Πείραμα 2]	54
Πίνακας 21: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_2] [Πείραμα 2]	54
Πίνακας 22: Αποτελέσματα επιλογής χαρακτηριστικών [Πείραμα 2].....	56
Πίνακας 23: Σπουδαιότερα χαρακτηριστικά μοντέλων [Πείραμα 2].....	56
Πίνακας 24: Αποτελέσματα ρύθμισης υπερπαραμέτρων [Πείραμα 2].....	58
Πίνακας 25: Αποτελέσματα σετ δεδομένων ελέγχου (test set) [Πείραμα 2]	58
Πίνακας 26: Αξιολόγηση ομαδοποίησης [Πείραμα 3]	61
Πίνακας 27: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_0] [Πείραμα 3]	64
Πίνακας 28: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_1] [Πείραμα 3]	64
Πίνακας 29: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_3] [Πείραμα 3]	64
Πίνακας 30: Αποτελέσματα επιλογής χαρακτηριστικών [Πείραμα 3].....	66
Πίνακας 31: Σπουδαιότερα χαρακτηριστικά μοντέλων [Πείραμα 3].....	66
Πίνακας 32: Αποτελέσματα ρύθμισης υπερπαραμέτρων [Πείραμα 3].....	68
Πίνακας 33: Αποτελέσματα σετ δεδομένων ελέγχου (test set) [Πείραμα 3]	68

1 Εισαγωγή

Το Κεφάλαιο αυτό αποτελεί το εισαγωγικό κομμάτι της παρούσας διπλωματικής εργασίας. Στην Ενότητα 1.1, παρουσιάζονται τα κίνητρα που οδήγησαν στην εκπόνηση της. Στις Ενότητες 1.2 και 1.3, περιγράφεται το πρόβλημα προς επίλυση και δίνεται η προτεινόμενη αντιμετώπιση του, αντίστοιχα. Συνεχίζοντας, η Ενότητα 1.4 περιέχει τη συνεισφορά της στην καταγραφή της χρήσης του κινητού τηλεφώνου και την επίδραση αυτής στη μεταβολή του επιπέδου φόρτισης της μπαταρίας. Τέλος, στην Ενότητα 1.5 συνοψίζεται η διάρθρωση του παρόντος εγγράφου.

1.1 Κίνητρα

Τα κινητά τηλέφωνα λογίζονται ως ένα από τα μεγαλύτερα σύγχρονα τεχνολογικά επιτεύγματα του ανθρώπου. Αποτελούν αναπόσπαστο κομμάτι της καθημερινότητας του, καθώς έλυσαν βασικά θέματα διαπροσωπικής επικοινωνίας, η οποία έγινε πιο γρήγορη και ευέλικτη, απελευθερωμένη από χωρικούς και τοπικούς περιορισμούς. Επιπλέον, τα «έξυπνα» κινητά (smartphones), έχουν μετατραπεί σε μικρούς φορητούς υπολογιστές παρέχοντας επιπλέον δυνατότητες, όπως η πρόσβαση στο διαδίκτυο και τις υπηρεσίες του (ηλεκτρονικό ταχυδρομείο), η χρήση των μέσων κοινωνικής δικτύωσης και η λήψη, επεξεργασία και αναπαραγωγή πολυμέσων (εικόνες, ήχοι, βίντεο). Αυτή η φορητότητα κατέστη δυνατή μέσω της αξιοποίησης των μπαταριών και συνιστά έναν από τους κύριους πόλους έλξης για τον τελικό χρήστη.



Εικόνα 1: Αριθμός μοναδικών smartphone χρηστών παγκοσμίως από το 2016 έως το 2021 (σε δισεκατομμύρια) [Πηγή]

Οι μπαταρίες χρειάζονται περιοδική φόρτιση, καθώς η κατανάλωση ενέργειας που προκαλεί η συνεχής λειτουργία του κινητού, οδηγεί στη συχνή εξάντληση τους και πρέπει σύντομα να απορριφθούν και να αντικατασταθούν. Αυτή η απόσυρση, γίνεται -κατά μέσο όρο- ανά δύο χρόνια, παράγοντας μεγάλες ποσότητες τοξικών αποβλήτων, που προστίθενται στην καταπόνηση του περιβάλλοντος. Συνεπώς, η αναγνώριση και η ομαδοποίηση των παραγόντων που συνεισφέρουν στην εξάντληση τους είναι σημαντική, καθώς οι συσκευές συνεχίζουν να εξελίσσονται, τόσο για τους κατασκευαστές, βελτιώνοντας τη σχεδίαση τους, όσο και για τους ιδιοκτήτες, αναγνωρίζοντας μοτίβα χρήσεων. Αυτά θα οδηγήσουν σε συσκευές με μεγαλύτερη διάρκεια ζωής μειώνοντας την περιβαλλοντική επίπτωση, σύμφωνα με τα ιδανικά του Green Computing [54].

1.2 Περιγραφή του προβλήματος

Για τον λόγο αυτό τα τελευταία χρόνια ολοένα και περισσότερο επιστημονικό ενδιαφέρον συγκεντρώνεται στην ερεύνα μεθόδων αναγνώρισης και ανάλυσης της χρήστης κινητών τηλεφώνων. Αναμφίβολα η τεχνητή νοημοσύνη και ειδικότερα η μηχανική μάθηση διαδραματίζουν ένα σπουδαίο ρόλο στην ανάπτυξη τέτοιων μεθόδων.

1.2 Περιγραφή του προβλήματος

Η εκτίμηση του επιπέδου φόρτισης είναι ένα δύσκολο πρόβλημα (μη γραμμικό, χρονομεταβαλλόμενο, δυναμικό) λόγω της φύσης της μπαταρίας. Εξαρτάται από πληθώρα παραμέτρων και οι έως τώρα προσπάθειες (Κεφάλαιο 3), χρησιμοποιούν κάποια φυσική ιδιότητά της (τάση, ρεύμα, αντίσταση) για την πρόβλεψη του, χωρίς να λαμβάνουν υπόψιν τη θερμοκρασία της ή την τρέχουσα κατάσταση των υπολογιστικών πόρων που εκτελούνται στη συσκευή (φορτίο επεξεργαστή, διαθέσιμη μνήμη RAM). Έτσι, συνθέτουν λύσεις που πάσχουν από μεγάλα σφάλματα για διαφορετικές περιοχές λειτουργίας της.

Επιπρόσθετα, ο χρήστης έχει πρόσβαση στην πραγματική τιμή του επιπέδου φόρτισης της μπαταρίας μέσω του λογισμικού της συσκευής. Από την άλλη, η μεταβολή του λόγω ενός συγκεκριμένου τύπου χρήστης, μπορεί αφενός να αναδείξει μοτίβα λειτουργιών και αφετέρου να τα συνδέσει με την αντίστοιχη κατανάλωση ενέργειας που προκαλούν. Έτσι, θα αποκτήσει καλύτερο έλεγχο επί της διαδικασίας εκφόρτισης και θα μπορεί να αναγνωρίζει συμπεριφορές που οδηγούν σε υπερβολική κατανάλωση, επιτυγχάνοντας υψηλότερη διάρκεια ζωής της συσκευής.

1.3 Προτεινόμενη αντιμετώπιση

Η εν λόγω διπλωματική εργασία ασχολείται με την ανάλυση της χρήστης των κινητών τηλεφώνων και με την εκτίμηση της κατανάλωσης ενέργειας (energy drain) της μπαταρίας τους. Αρχικά, αναπτύχθηκε η εφαρμογή BatteryApp, για την καταγραφή της χρήστης της συσκευής και των πληροφοριών της μπαταρίας, ανά τακτά χρονικά διαστήματα. Πιο συγκεκριμένα, κατά τη λειτουργία της συσκευής συλλέγονται δεδομένα, όπως το φορτίο του επεξεργαστή, η διαθέσιμη μνήμη RAM, η σύνδεση στο διαδίκτυο και η αξιοποίηση του GPS, ενώ για την μπαταρία, το επίπεδο της, η τάση της, η θερμοκρασία και η υγεία της.

Στη συνέχεια, οι μετρήσεις αυτές δημιουργούν παράθυρα χρήστης, για ομαλοποίηση των δεδομένων και αποφυγή τοπικά ακραίων τιμών. Η δημιουργία ενός μοντέλου παλινδρόμησης για κάθε πιθανή λειτουργία του κινητού τηλεφώνου αποτελεί ένα δύσκολο εγχείρημα, αν όχι αδύνατο. Έτσι, μετά τον ορισμό των παραθύρων θα ακολουθήσει η ομαδοποίηση αυτών βάσει χαρακτηριστικών που δείχνουν τη χρήση του. Τέλος, για κάθε μια από τις παραπάνω ομάδες θα υλοποιηθεί ένα μοντέλο παλινδρόμησης, με σκοπό την εκτίμηση της κατανάλωσης ενέργειας, με τη διαδικασία μάθησης των παραμέτρων να πραγματοποιείται σε κάθε ομάδα ξεχωριστά.

1.4 Συνεισφορά της διπλωματικής

Η συνεισφορά της διπλωματικής είναι τριπλή:

- Ανάπτυξη εφαρμογής, για την περιοδική καταγραφή των λειτουργιών της συσκευής και των πληροφοριών της μπαταρίας.
- Ομαδοποίηση όμοιων χρήσεων της συσκευής (unsupervised learning).
- Εκτίμηση της κατανάλωσης ενέργειας για κάθε ομάδα.

1.5 Διάρθρωση εγγράφου

Το κείμενο της εργασίας περιλαμβάνει 6 κεφάλαια:

- Το τρέχον αποτελεί εισαγωγικό κομμάτι του εγγράφου.
- Το δεύτερο, περιλαμβάνει το θεωρητικό υπόβαθρο για την κατανόησή του.
- Το τρίτο, συνοψίζει την υπάρχουσα βιβλιογραφία για την εκτίμηση του επιπέδου φόρτισης της μπαταρίας.
- Το τέταρτο, περιλαμβάνει την αναλυτική περιγραφή της μεθοδολογίας που ακολουθήθηκε.
- Το πέμπτο, παρουσιάζει τα πειράματα που εκτελέστηκαν και τα αποτελέσματά τους.
- Τέλος, το έκτο καταλήγει με τα συμπεράσματα και τις πιθανές μελλοντικές επεκτάσεις.

2 Θεωρητικό Υπόβαθρο

Το Κεφάλαιο αυτό περιλαμβάνει το θεωρητικό υπόβαθρο για την κατανόηση της παρούσας διπλωματικής εργασίας. Στην Ενότητα 2.1, συνοψίζονται κάποιες βασικές γνώσεις που αφορούν τη λειτουργία των μπαταριών. Τέλος, στην Ενότητα 2.2 δίνονται ορισμένες πληροφορίες σχετικά με το πεδίο της τεχνητής νοημοσύνης, τα προβλήματα που προσπαθεί να επιλύσει και τους αλγορίθμους που θα χρησιμοποιηθούν στη διπλωματική.

2.1 Μπαταρία

Σε πρώτο στάδιο, παρατίθενται οι ορισμοί διαφόρων τεχνικών χαρακτηριστικών της μπαταρίας και φαινομένων που διέπουν τη λειτουργία της, που εμφανίζονται στην έκταση του παρόντος εγγράφου. Στη συνέχεια ακολουθεί μια σύντομη περιγραφή των κατηγοριών που αυτές εντάσσονται. Τέλος, παρουσιάζονται ο τρόπος λειτουργίας, τα πλεονεκτήματα και τα μειονεκτήματα των μπαταριών ιόντων λιθίου και ιόντων λιθίου πολυμερούς.

2.1.1 Γλωσσάρι όρων μπαταρίας

Χωρητικότητα	Η ποσότητα ηλεκτρικού φορτίου που μπορεί να αποθηκεύσει η μπαταρία.
Απόδοση	Ο λόγος της τάσης λειτουργίας προς την τάση ανοιχτού κυκλώματος της μπαταρίας.
Κύκλος λειτουργίας	Η εκφόρτιση και επακόλουθη φόρτιση μιας μπαταρίας έως ότου επανέλθει σε κατάσταση πλήρους φόρτισης.
Διάρκεια ζωής	Ο συνολικός αριθμός κύκλων λειτουργίας, προτού η χωρητικότητά της μειωθεί κάτω από το 80% της αρχικής ονομαστικής χωρητικότητας.
Ενεργειακή πυκνότητα	Η ενέργεια που παρέχεται ανά μονάδα όγκου της μπαταρίας (Wh/L).
Ειδική ενέργεια	Η ποσότητα αποθηκευμένης ηλεκτρικής ενέργειας ανά κιλό της μπαταρίας (Wh/kg).
Φαινόμενο μνήμης (Memory effect)	Η απόκλιση στην τάση λειτουργίας της μπαταρίας, που προκαλείται από ελλιπή φόρτιση ή εκφόρτιση, η οποία μπορεί να οδηγήσει σε διαθεσιμότητα μόνο μέρους της αποθηκευμένης ενέργειας και αδυναμία αξιόπιστου καθορισμού του επιπέδου φόρτισης της.
Αυτοεκφόρτιση (Self-discharge)	Οι εσωτερικές χημικές αντιδράσεις μειώνουν το αποθηκευμένο φορτίο της μπαταρίας χωρίς καμία σύνδεση μεταξύ των ηλεκτροδίων ή οποιουδήποτε εξωτερικού κυκλώματος.
Υπερφόρτιση (Overcharge)	Η συνέχιση της φόρτισης της μπαταρίας, ενώ βρίσκεται σε κατάσταση πλήρους φόρτισης.
Όριο αποκοπής (Cutoff threshold)	Η τάση κάτω από την οποία η μπαταρία θεωρείται πλήρως εκφορτισμένη (ορίζεται από τους κατασκευαστές). Ορισμένες ηλεκτρονικές συσκευές, όπως τα κινητά τηλέφωνα, θα κλείσουν αυτόματα όταν φτάσουν σ' αυτήν την τάση.
Βαθιά εκφόρτιση (Deep discharge)	Η εκφόρτιση της μπαταρίας πέρα από το όριο αποκοπής. Προκαλεί αύξηση της εσωτερικής αντίστασης της μπαταρίας και είναι πολύ δύσκολη η εκ νέου φόρτιση της.

2.1.2 Κατηγορίες Μπαταριών

Υπάρχουν δύο είδη μπαταριών. Η πρώτη κατηγορία είναι οι μπαταρίες πρώτης τάξης ή κύριες, οι οποίες όταν χρησιμοποιηθούν και εξαντληθεί η ενέργεια τους «αχρηστεύονται» και δε δύνανται να επαναχρησιμοποιηθούν. Στη δεύτερη κατηγορία εντάσσονται οι μπαταρίες δεύτερης τάξης ή δευτερεύουσες, οι οποίες μπορούν να επαναφορτιστούν και να χρησιμοποιηθούν ξανά. Οι τελευταίες αξιοποιούνται ευρέως και σε διάφορες εφαρμογές, όπως τα παιχνίδια, τα εργαλεία και τις ηλεκτρονικές συσκευές (υπολογιστές, κινητά τηλέφωνα).

Οι πιο γνωστοί τύποι επαναφορτιζόμενων μπαταριών είναι οι:


- Μπαταρίες Μολύβδου-Οξέος (*Lead-Acid Batteries*),
- Μπαταρίες Υδριδίου Νικελίου-Μετάλλου (*Nickel-Metal Hydride Batteries*),
- Μπαταρίες Ιόντων Λιθίου (*Lithium-Ion Batteries*).

Στην παρούσα διπλωματική εργασία θα μας απασχολήσουν οι μπαταρίες ιόντων λιθίου και λιθίου πολυμερούς (Lithium-ion Polymer battery ή LiPo), που αποτελούν εξέλιξη και βελτίωση των πρώτων.

2.1.3 Μπαταρίες ιόντων λιθίου

Οι μπαταρίες ιόντων λιθίου ανήκουν στην οικογένεια των επαναφορτιζόμενων μπαταριών, έχουν γνωρίσει τεράστια επιτυχία και έχουν επικρατήσει στο χώρο των φορητών συσκευών [38]. Αξίζει να σημειωθεί πως η τεχνολογία αυτήν είναι η ταχύτερα αναπτυσσόμενη στο χώρο αυτό.

Οι μπαταρίες ιόντων λιθίου χρησιμοποιούν μια κάθοδο (θετικό ηλεκτρόδιο), μια άνοδο (αρνητικό ηλεκτρόδιο) και έναν ηλεκτρολύτη ως αγωγό [39]. Η λειτουργία τους βασίζεται στη μετακίνηση ιόντων μεταξύ της ανόδου και της καθόδου διαμέσου του ηλεκτρολύτη. Πιο συγκεκριμένα, κατά τη διάρκεια της εκφόρτισης τα ιόντα λιθίου ρέουν από την άνοδο προς την κάθοδο, ενώ η φόρτιση αντιστρέφει αυτήν τη ροή.



Εικόνα 2: Ροή ιόντων σε μπαταρία ιόντων λιθίου [Πηγή]

Το θετικό ηλεκτρόδιο είναι ένα οξείδιο μετάλλου, το αρνητικό είναι κατασκευασμένο από μέταλλο και ο ηλεκτρολύτης είναι ένα άλας λιθίου σε οργανικό διάλυμα. Η επιλογή αυτών των υλικών, δημιουργεί τους διάφορους τύπους μπαταριών ιόντων λιθίου και μπορεί να επηρεάσει δραματικά τα χαρακτηριστικά τους. Στην πιο συμβατική δομή της, περιέχει μια άνοδο από γραφίτη, μια κάθοδο από οξείδιο λιθίου κοβαλτίου (LiCoO_2) και έναν υγρό ηλεκτρολύτη¹ [38].

¹ Οι υγροί ηλεκτρολύτες είναι διαλύματα ενός άλατος λιθίου σε οργανικούς διαλύτες (πχ. ανθρακικά άλατα).

2.2 Τεχνητή νοημοσύνη

Πλεονεκτήματα αυτού του τύπου μπαταριών, αποτελούν η υψηλή χωρητικότητα, η χαμηλή εσωτερική αντίσταση και η πολύ καλή απόδοση τους. Παράλληλα, έχουν αξιόλογη διάρκεια ενός κύκλου λειτουργίας, εκτεταμένη διάρκεια ζωής και λειτουργούν σε μεγάλο εύρος θερμοκρασιών. Επιπλέον, χαρακτηρίζονται από υψηλή ενεργειακή πυκνότητα, πολύ μικρό φαινόμενο μνήμης και χαμηλή αυτοεκφόρτιση, που δίνει τη δυνατότητα αποθήκευσης για μεγάλο χρονικό διάστημα, χωρίς να χρειάζεται κάποιο ειδικό περιβάλλον. Τέλος, υποστηρίζουν σύντομους χρόνους φόρτισης και τη δυνατότητα γρήγορης φόρτισης.

Ωστόσο, η χρήση τους έχει και περιορισμούς, όπως η απώλεια χωρητικότητας και η έκλυση θερμότητας όταν υπερφορτίζονται. Επιπλέον, η χημεία των ιόντων λιθίου λειτουργεί καλά σε αυξημένες θερμοκρασίες, αλλά παρατεταμένη έκθεση στη θερμότητα μειώνει τη ζωή της μπαταρίας. Τέλος, συνήθως απαιτούν ένα κύκλωμα διαχείρισης για προστασία από υπερφορτίσεις και πολύ υψηλές θερμοκρασίες λειτουργίας.

2.1.4 Μπαταρίες ιόντων λιθίου πολυμερούς

Οι μπαταρίες λιθίου πολυμερούς, ανήκουν στην κατηγορία μπαταριών ιόντων λιθίου και αποτελούν εξέλιξη και βελτίωση των προκατόχων τους. Η μεγαλύτερη διαφορά συνίσταται στον χρησιμοποιούμενο ηλεκτρολύτη, ο οποίος δεν είναι πλέον υγρός οργανικός διαλύτης, αλλά ένα πολυμερές υλικό.

Χαρακτηρίζονται από τα ίδια πλεονεκτήματα με τις μπαταρίες ιόντων λιθίου. Πιο συγκεκριμένα, διαθέτουν χαμηλούς ρυθμούς αυτοεκφόρτισης, πολύ μικρό φαινόμενο μνήμης και πολύ καλή απόδοση. Σε σύγκριση με άλλους τύπους μπαταριών λιθίου ιόντων, έχουν μεγαλύτερη χωρητικότητα και παρέχουν υψηλότερη ειδική ενέργεια. Επιπλέον, δύνανται να κατασκευαστούν σε επιθυμητές διαστάσεις και χρησιμοποιούνται σε εφαρμογές όπου το βάρος είναι κρίσιμο χαρακτηριστικό, όπως τα κινητά τηλέφωνα. Τέλος, διαθέτουν στιβαρή κατασκευή και υψηλή ανθεκτικότητα σε κακή φυσική ή ηλεκτρική καταπόνηση [40].

Ομοίως, επιδέχονται τους ίδιους περιορισμούς όσον αφορά τις υψηλές θερμοκρασίες και την ευαισθησία σε υπερφορτίσεις και βαθιές εκφορτίσεις. Έτσι, μπορούν να χρησιμοποιηθούν με ασφάλεια και αποτελεσματικότητα μόνο εάν συνδυάζονται με ηλεκτρονικό σύστημα, υπεύθυνο για τη διαχείριση της χρήσης και της επαναφόρτισης, καθώς και για τη διατήρηση της μπαταρίας εντός της ασφαλούς περιοχής λειτουργίας [41]. Τέλος, το κόστος κατασκευής είναι υψηλότερο σε σύγκριση με τις μπαταρίες ιόντων λιθίου.

2.2 Τεχνητή νοημοσύνη

Στην Ενότητα αυτή, αρχικά θα γίνει μια εισαγωγή στις έννοιες της μηχανικής μάθησης και τους τύπους προβλημάτων που επιλύει. Στη συνέχεια, στις Υποενότητες 2.2.4 και 2.2.5, θα παρουσιαστούν οι έννοιες της ομαδοποίησης και της παλινδρόμησης, των αλγορίθμων που θα χρησιμοποιηθούν στα πλαίσια της διπλωματικής και οι μετρικές για την αξιολόγηση αυτών, αντίστοιχα.


2.2.1 Εισαγωγή στη μηχανική μάθηση

Η μάθηση είναι μια από τις πρωταρχικές ιδιότητες της συμπεριφοράς των ανθρώπων. Έχουν πραγματοποιηθεί αρκετές μελέτες και έρευνες στο πεδίο της γνωστικής ψυχολογίας, αλλά ακόμα και τώρα η έννοιά της δεν έχει γίνει πλήρως κατανοητή. Η τεχνητή νοημοσύνη είναι ο τομέας της επιστήμης των υπολογιστών, που ασχολείται, εκτός των άλλων, με τη σχεδίαση ευφυών υπολογιστικών συστημάτων, δηλαδή συστημάτων που επιδεικνύουν χαρακτηριστικά που σχετίζονται με τη νοημοσύνη στην

2.2 Τεχνητή νοημοσύνη

ανθρώπινη συμπεριφορά, ώστε να επιτύχουν τη λεγόμενη μηχανική μάθηση. Ένας γενικός ορισμός που δίνεται από τον Mitchell [42], είναι ο εξής:

«Ένας υπολογιστής λέμε ότι μαθαίνει από την εμπειρία E ως προς κάποια κλάση εργασιών T και μέτρο απόδοσης P , αν η απόδοσή του σε εργασίες της T , όπως αξιολογείται από το P , βελτιώνεται μέσω της εμπειρίας E .»



Εικόνα 3: Στάδια και ροή μηχανικής μάθησης [[Πηγή](#)]

Σε απλούστερα λόγια, η μηχανική μάθηση σκοπεύει στη δημιουργία μηχανών ικανών να βελτιώνουν την απόδοση τους σε συγκεκριμένους τομείς, μέσω της αξιοποίησης προηγούμενων γνώσεων και εμπειριών. Έτσι, δημιουργούνται μοντέλα και αλγόριθμοι, που μαθαίνουν από δεδομένα που τους παρέχονται κατά την εκπαίδευση και κάνουν προβλέψεις σχετικά με αυτά.

Η μηχανική μάθηση είναι στενά συνδεδεμένη με την υπολογιστική στατιστική, ένας κλάδος που και αυτός επικεντρώνεται στην πρόβλεψη μέσω της χρήσης υπολογιστών. Έχει ισχυρούς δεσμούς με τη μαθηματική βελτιστοποίηση, η οποία παρέχει μεθόδους, θεωρία και πρακτικές εφαρμογές. Χρησιμοποιείται σε μια σειρά από υπολογιστικές εργασίες, όπου τόσο ο σχεδιασμός όσο και ο ρητός προγραμματισμός των αλγορίθμων είναι ανέφικτος. Παραδείγματα εφαρμογών αποτελούν η αναγνώριση προτύπων, η ανάπτυξη στρατηγικών σε διάφορες καταστάσεις, οι μηχανές αναζήτησης και η υπολογιστική όραση. Τέλος, η μηχανική μάθηση μερικές φορές συγχέεται με την εξόρυξη δεδομένων, όπου η τελευταία επικεντρώνεται περισσότερο στην εξερευνητική ανάλυση των δεδομένων, γνωστή και ως μη επιτηρούμενη μάθηση.

2.2.2 Υπολογιστές και νοημοσύνη

Ο ορισμός του Mitchell, είναι σημαντικός για τον καθορισμό της μηχανικής μάθησης σε ένα βασικό λειτουργικό πλαίσιο, ακολουθώντας την πρόταση του Alan Turing στην εργασία του «Υπολογιστικές Μηχανές και Νοημοσύνη», ότι το ερώτημα αν μπορούν οι μηχανές να σκεφτούν, μπορεί να αντικατασταθεί με το ερώτημα αν μπορούν οι μηχανές να κάνουν αυτό που εμείς (ως νοήμονες οντότητες) μπορούμε να κάνουμε.

Στο πεδίο της ανάλυσης δεδομένων, η μηχανική μάθηση είναι μια μέθοδος που χρησιμοποιείται για την κατασκευή πολύπλοκων μοντέλων και αλγορίθμων που οδηγούν στην πρόβλεψη. Τα αναλυτικά μοντέλα επιτρέπουν στους ερευνητές, τους επιστήμονες δεδομένων, τους μηχανικούς και τους αναλυτές να λαμβάνουν αξιόπιστες αποφάσεις, να

2.2 Τεχνητή νοημοσύνη

παράγουν χρήσιμα αποτελέσματα και να αναδεικνύουν αλληλοσυσχετίσεις μέσω της μάθησης από ιστορικές σχέσεις και τάσεις στα δεδομένα.

Επιπρόσθετα, ως ικλάδος της τεχνητής νοημοσύνης ασχολείται με τη μελέτη αλγορίθμων που βελτιώνουν τη συμπεριφορά τους, σε κάποια εργασία που τους έχει ανατεθεί, χρησιμοποιώντας την εμπειρία τους. Για τα συστήματα που ανήκουν στη συμβολική τεχνητή νοημοσύνη, η δυνατότητα μάθησης προσδιορίζεται ως η ικανότητα απόκτησης επιπλέον γνώσης, που μεταβάλει την ήδη καταχωρημένη είτε αυξομειώνοντάς την είτε αλλάζοντάς κάποια χαρακτηριστικά της. Από την άλλη, για τα συστήματα που ανήκουν στη μη συμβολική τεχνητή νοημοσύνη, ως μάθηση προσδιορίζεται η δυνατότητα τους να μετασχηματίζουν την εσωτερική τους δομή.

Οι μηχανές έχουν τη δυνατότητα να μαθαίνουν, αλλά η κατασκευή μηχανών ικανών να μαθαίνουν τόσο καλά όσο ο άνθρωπος απέχει αρκετά. Ωστόσο, για συγκεκριμένες περιοχές μάθησης έχουν αναπτυχθεί αλγόριθμοι που έχουν δώσει λύσεις σε αναπάντητα έως τώρα ερωτήματα. Μερικοί από τους κλάδους της επιστήμης που επωφελούνται από τα επιτεύγματα στον τομέα της μηχανικής μάθησης είναι: η Εξόρυξη Δεδομένων, η Θεωρία της Πληροφορίας, η Αριθμητική Βελτιστοποίηση, ο Προσαρμοστικός Έλεγχος, η Νευροβιολογία και η Γλωσσολογία.

2.2.3 Τύποι προβλημάτων

Οι εργασίες μηχανικής μάθησης –συνήθως- κατατάσσονται σε τρεις μεγάλες κατηγορίες, ανάλογα με τη φύση των δεδομένων ή την ανατροφοδότηση (feedback) που είναι διαθέσιμα σε ένα σύστημα εκμάθησης. Αυτές είναι [43]:

- *Επιτηρούμενη μάθηση* (επιβλεπόμενη μάθηση ή *supervised learning*): Ο αλγόριθμος δέχεται τις παραδειγματικές εισόδους, καθώς και τα επιθυμητά αποτελέσματα από έναν «δάσκαλο» και ο στόχος είναι να μάθει έναν γενικό κανόνα προκειμένου να αντιστοιχίσει τις εισόδους με τα αποτελέσματα.
- *Μη επιτηρούμενη μάθηση* (μη επιβλεπόμενη μάθηση ή *unsupervised learning*): Ο αλγόριθμος δέχεται τις παραδειγματικές εισόδους, αλλά σε αντίθεση με την προηγούμενη κατηγορία δεν του παρέχονται τα επιθυμητά αποτελέσματα. Η μη επιβλεπόμενη μάθηση χρησιμοποιείται για να ανακαλύψει κρυμμένα μοτίβα σε δεδομένα, να αναλύσει συσχετισμούς ή/και να τα ομαδοποιήσει.
- *Ενισχυτική μάθηση* (*reinforcement learning*): Ο αλγόριθμος αλληλεπιδρά με ένα δυναμικό περιβάλλον στο οποίο πρέπει να επιτευχθεί ένας συγκεκριμένος στόχος (όπως η οδήγηση ενός οχήματος), χωρίς κάποιος «δάσκαλος» να του λέει ρητά αν έχει φτάσει κοντά στο στόχο του.


2.2.4 Ομαδοποίηση - Clustering

Η ομαδοποίηση προσπαθεί να εντάξει ένα σύνολο δειγμάτων σε ομάδες, με τέτοιο τρόπο ώστε τα δείγματα στην ίδια ομάδα (cluster) να είναι πιο όμοια (με βάσει κάποια μετρική ομοιότητας) μεταξύ τους, παρά με εκείνα από άλλες ομάδες [48]. Χρησιμοποιείται σε πληθώρα εφαρμογών είτε για κατανόηση των δειγμάτων, για παράδειγμα ομαδοποίηση συναφών εγγράφων ή μετοχών που έχουν παρόμοια διακύμανση στις τιμές τους, είτε για σύνοψη αυτών, για παράδειγμα μείωση του μεγέθους μεγάλων σετ δεδομένων.

Αξίζει να σημειωθεί, όμως, πως ομαδοποίηση δεν είναι η επιβλεπόμενη ταξινόμηση. Τα δείγματα σε μια εργασία ταξινόμησης έχουν ετικέτες και κάθε σημείο δεδομένων ταξινομείται σύμφωνα με ορισμένες μετρήσεις. Οι αλγόριθμοι ταξινόμησης προσπαθούν να μοντελοποιήσουν τη σχέση μεταξύ των μετρήσεων (χαρακτηριστικά) στα δεδομένα και της κατηγορίας που τους έχει ανατεθεί. Στη συνέχεια, το μοντέλο προβλέπει την

2.2 Τεχνητή νοημοσύνη

κατηγορία των νέων δειγμάτων. Από την άλλη, τα δείγματα στην ομαδοποίηση δεν έχουν ετικέτες και το μοντέλο είναι υπεύθυνο για να βρει μοτίβα στο σύνολο δεδομένων, έτσι ώστε παρόμοια δείγματα να ενταχθούν στην ίδια ομάδα.



Εικόνα 4: Παραδείγματα ομαδοποίησης βάσει ομοιοτήτων [Πηγή]

Η iεραρχική ομαδοποίηση είναι μια γενική οικογένεια αλγορίθμων ομαδοποίησης που δημιουργούν εμφωλευμένες ομάδες συγχωνεύοντας διαδοχικές υπο-ομάδες. Αυτήν η iεραρχία ομάδων αντιπροσωπεύεται ως δέντρο (ή δενδρόγραμμα). Η ρίζα του δέντρου είναι η ομάδα που συγκεντρώνει όλα τα δείγματα, ενώ τα φύλλα αποτελούνται από ένα μόνο δείγμα. Οι αλγόριθμοι iεραρχικής ομαδοποίησης χρησιμοποιούν ως μετρική τον πίνακα ομοιότητας ή απόστασης και βάσει του κριτηρίου σύνδεσης (linkage) που χρησιμοποιούν για τη συγχώνευση των ομάδων, ορίζονται οι εξής εκδοχές [48]:

- **Single linkage:** Ελαχιστοποιεί την απόσταση μεταξύ των πλησιέστερων δειγμάτων για ένα ζευγάρι ομάδων.
- **Complete linkage:** Ελαχιστοποιεί τη μέγιστη απόσταση μεταξύ των δειγμάτων για ένα ζευγάρι ομάδων.
- **Average linkage:** Ελαχιστοποιεί τον μέσο όρο των αποστάσεων μεταξύ όλων των δειγμάτων για ένα ζευγάρι ομάδων.

2.2.4.1 Συνάρτηση απόστασης Gower

Θεωρία

Η ταυτόχρονη ύπαρξη, κατηγορικών (δυαδικών) και αριθμητικών χαρακτηριστικών στα δεδομένα, δεν επιτρέπει τη χρήση των συμβατικών μετρικών απόστασης που δίνονται από τον τύπο για την απόσταση Minkowski τάξης r

$$d_r(x_i, x_j) = \left(\sum_{k=1}^n (x_{ik} - x_{jk})^r \right)^{\frac{1}{r}}, \quad (2.1)$$

όπου n , ο αριθμός των χαρακτηριστικών, x_{ik} , x_{jk} είναι οι τιμές των k -οστών χαρακτηριστικών των δειγμάτων x_i , x_j , αντίστοιχα. Για $r = 1$, ορίζεται η απόσταση Μανχάταν και για $r = 2$, η Ευκλείδεια απόσταση.

Γίνεται εύκολα κατανοητό, πως δεν μπορεί ο παραπάνω τύπος να χρησιμοποιηθεί σε κατηγορικά δεδομένα. Σε αυτό το πρόβλημα έρχεται να δώσει λύση, η απόσταση Gower

2.2 Τεχνητή νοημοσύνη

[44], μια μετρική για την εύρεση ομοιότητας μεταξύ δύο σειρών ενός συνόλου δεδομένων που αποτελείται από χαρακτηριστικά μικτού τύπου. Χρησιμοποιεί την απόσταση Μανχάταν για τις αριθμητικές μεταβλητές και την απόσταση ζαριού (Dice distance) για τη μέτρηση της ομοιότητας μεταξύ των δυαδικών μεταβλητών. Ο μαθηματικός τύπος της απόστασης Gower είναι

$$S_{i,j} = \frac{\sum_k^n w_{ijk} S_{ijk}}{\sum_k^n w_{ijk}}, \quad (2.2)$$

όπου S_{ijk} , η συνεισφορά στην ομοιότητα της k -οστής μεταβλητής και w_{ijk} , συνήθως 1 ή 0, για να δείξει αν η σύγκριση με την k -οστή μεταβλητή είναι έγκυρη.

Παράδειγμα εφαρμογής

Παρακάτω παρατίθεται ένα παράδειγμα εφαρμογής της μετρικής, για ευκολότερη κατανόηση της χρήσης και της συνεισφοράς της. Έστω, τα δεδομένα του Πίνακα 1, όπου Num_1 , Num_2 αριθμητικές μεταβλητές και Bool_1 δυαδική.

Πίνακας 1: Δεδομένα επεξήγησης απόστασης Gower

Num₁	Num₂	Bool₁
1	2.6	True
12	5.0	False
4	7.0	True

Χρησιμοποιώντας την απόσταση Μανχάταν για τις δύο πρώτες μεταβλητές και κανονικοποιώντας την, προκύπτουν οι ομοιότητες S_1, S_2 βάσει των Num_1 και Num_2 , αντίστοιχα.

Πίνακας 2: Κανονικοποιημένες ομοιότητες S_1, S_2

S₁			S₂		
0	1	0.2727	0	0.5454	1
1	0	0.7272	0.5454	0	0.4545
0.2727	0.7272	0	1	0.4545	0

Για την ομοιότητα S_3 , θα χρησιμοποιηθεί απόσταση ζαριού (Dice distance) που μετατρέπει αρχικά σε επεξεργάσιμη μορφή τη δυαδική Bool_1 ,

Πίνακας 3: Μετατροπή σε επεξαργάσιμη μορφή της μεταβλητής Bool_1

Bool₁	Bool₁ – True		Bool₁ – False
True	1		0
False	0		1
True	1		0

$$\text{Dice Distance} = \frac{\text{NNEQ}}{\text{NTT} + \text{NNZ}} = \frac{\text{NTF} + \text{NFT}}{\text{NTT} + (\text{NTF} + \text{NFT} + \text{NTT})} = \frac{2 + 1}{0 + (2 + 1 + 0)} = 1, \quad (2.3)$$

όπου NTT, ο αριθμός των διαστάσεων όπου και οι δύο τιμές είναι Αληθείς, NTF, ο αριθμός των διαστάσεων όπου η πρώτη τιμή είναι Αληθής και η δεύτερη Ψευδής, NFT, ο αριθμός των διαστάσεων όπου η πρώτη τιμή είναι Ψευδής και η δεύτερη Αληθής, NFF, ο αριθμός των διαστάσεων όπου και οι δύο τιμές είναι Ψευδείς, NNEQ, ο αριθμός των μη ίσων διαστάσεων και NNZ, ο αριθμός των μη μηδενικών διαστάσεων.

Υπολογίζοντας την ομοιότητα S_3 , προκύπτει

Πίνακας 4: Κανονικοποιημένη ομοιότητα S_3

S_3		
0	1	0
1	0	1
0	1	0

Τέλος, για $w_1 = w_2 = w_3 = 1$, μπορεί να υπολογιστεί η απόσταση Gower, που επιβεβαιώνει τη διαίσθηση μας ότι η γραμμή 1, μοιάζει περισσότερο με τη σειρά 3 (μικρότερη απόσταση), παρά με τη σειρά 2.

Πίνακας 5: Τελική απόσταση Gower

Απόσταση Gower		
0	0.8484	0.4242
0.8484	0	0.7272
0.4242	0.7272	0

2.2.4.2 Αξιολόγηση ομαδοποίησης

Συντελεστής Silhouette

Είναι μία γραφική μέθοδος οπτικοποίησης και αξιολόγησης των ομάδων. Κάθε ομάδα αντιπροσωπεύεται από έναν συντελεστή Silhouette, που βασίζεται στη σύγκριση ως προς τη συνεκτικότητα (cohesion) και τη διαχωρισμότητα (separation) της. Η τιμή του συντελεστή για κάθε ομάδα υπολογίζει πόσο όμοιο είναι ένα αντικείμενο με τα υπόλοιπα που ανήκουν στην ίδια ομάδα. Αποκαλύπτει, δηλαδή, ποια αντικείμενα βρίσκονται σωστά μέσα στην ομάδα τους [45], [47]. Μαθηματικά, υπολογίζεται με τον τύπο

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} , \quad (2.4)$$

όπου $a(i)$, η μέση απόσταση του σημείου i από τα υπόλοιπα σημεία της ίδιας ομάδας, $b(i)$, η μέση απόσταση του σημείου i από τα σημεία που βρίσκονται στην κοντινότερη ομάδα.

Το μέσο πλάτος των συντελεστών αυτών παρέχει μία εκτίμηση της αξιολόγησης των ομαδοποιήσεων και μπορεί να χρησιμοποιηθεί για την επιλογή ενός «κατάλληλου» πλήθους ομάδων. Τέλος, παίρνει τιμές μεταξύ $[-1, 1]$, όπου τιμές κοντά στη μονάδα δηλώνουν καλύτερη ομαδοποίηση.

Συντελεστής συσχέτισης Cophenetic

Ο συντελεστής Cophenetic χρησιμοποιείται για την επικύρωση του δενδρογράμματος και φανερώνει πόσο καλά συνδέονται τα αντικείμενα στο ιεραρχικό δέντρο με βάση το κριτήριο σύνδεσης που έχουμε επιλέξει. Για ένα (υπο)δέντρο μίας ομάδας ορίζεται ως ο συντελεστής της γραμμικής συσχέτισης μεταξύ των Cophenetic αποστάσεων του δέντρου και των πραγματικών αποστάσεων (ή ανομοιοτήτων) που το συνθέτουν.

Η Cophenetic απόσταση μεταξύ δύο αντικειμένων αντιπροσωπεύεται σε ένα δενδρόγραμμα μέσω του ύψους στο οποίο συνδέονται τα δύο αντικείμενα για πρώτη φορά. Το ύψος είναι η απόσταση μεταξύ δύο υποομάδων που ενώνονται μέσω του επιλεγμένου κριτηρίου σύνδεσης. Για να επαληθεύσουμε κατά πόσο οι αποστάσεις του δέντρου αντιπροσωπεύουν με ακρίβεια τις πραγματικές αποστάσεις μεταξύ δύο

2.2 Τεχνητή νοημοσύνη


αντικειμένων, τότε υπολογίζουμε τον συντελεστή συσχέτισης Cophenetic [46], [47], όπου μαθηματικά ορίζεται

$$CPCC = \frac{\sum_{i < j} (d_{ij} - \bar{d})(d_{ij}^* - \bar{d}^*)}{\sqrt{\sum_{i < j} (d_{ij} - \bar{d})^2 (d_{ij}^* - \bar{d}^*)^2}} , \quad (2.5)$$

όπου d_{ij} , η απόσταση μεταξύ του ζευγαριού (i, j) και d_{ij}^* , η Cophenetic απόσταση τους. Επιπλέον, περιλαμβάνει τη μέση απόσταση \bar{d} και τη μέση Cophenetic απόσταση \bar{d}^* , που υπολογίζονται

$$\bar{d} = \frac{\sum_{i < j} d_{ij}}{2(n^2 - n)}, \quad \bar{d}^* = \sqrt{\frac{\sum_{i < j} (d_{ij} - d_{ij}^*)^2}{\sum_{i < j} (d_{ij}^*)^2}} . \quad (2.6)$$

Ο συντελεστής αυτός αντιπαραβάλλει τα δύο σύνολα τιμών και υπολογίζει τον βαθμό συσχέτισής τους, μεταξύ $[-1, 1]$. Στην περίπτωση που η συσχέτιση είναι ισχυρή, δηλαδή η τιμή του CPCC πλησιάζει όσο το δυνατόν περισσότερο τη μονάδα, η ομάδα τότε είναι έγκυρη και με τόση ακρίβεια τα αποτελέσματα της ομαδοποίησης αντιπροσωπεύουν τα αρχικά δεδομένα.



Εικόνα 5: Η Cophenetic απόσταση δύο σημείων

Multidimensional scaling (MDS)

Η πολυδιάστατη κλιμακοποίηση (Multidimensional scaling, MDS) στηρίζεται στην αποσύνθεση ιδιοτιμών (eigenvalue decomposition) και είναι ένα μέσο απεικόνισης του επιπέδου ομοιότητας των μεμονωμένων περιπτώσεων ενός συνόλου δεδομένων [49]. Ο όρος αυτός αφορά ένα σύνολο μεθόδων, που χρησιμοποιούνται για την απεικόνιση χρήσιμης πληροφορίας με τη χρήση του πίνακα αποστάσεων και είναι μια μορφή μη γραμμικής μείωσης των διαστάσεων. Ο αλγόριθμος MDS στοχεύει στην τοποθέτηση κάθε αντικειμένου στον N -διάστατο χώρο, έτσι ώστε οι αποστάσεις μεταξύ των αντικειμένων να διατηρούνται όσο το δυνατόν καλύτερα. Συνήθως, χρησιμοποιείται για την απεικόνιση δεδομένων υψηλών διαστάσεων, στον δισδιάστατο (2D) ή τρισδιάστατο (3D) χώρο.

2.2 Τεχνητή νοημοσύνη

Στα πλαίσια της παρούσας διπλωματικής, η πολυδιάστατη κλιμακοποίηση θα χρησιμοποιηθεί, με τον πίνακα αποστάσεων να υπολογίζεται μέσω της συνάρτησης απόστασης του Gower, για την απεικόνιση του συνόλου των δεδομένων στον δισδιάστατο και στον τρισδιάστατο χώρο. Έτσι, θα προσφέρει μια ακόμα μετρική για την αξιολόγηση της ομαδοποίησης, μέσω της οπτικοποίησης των ομάδων.

2.2.5 Παλινδρόμηση - Regression

Η παλινδρόμηση, προσπαθεί να προβλέψει την τιμή μιας συνεχούς μεταβλητής, με βάση τις τιμές άλλων μεταβλητών, θεωρώντας ένα γραμμικό ή μη, μοντέλο συσχέτισης [48]. Χρησιμοποιείται σε αρκετές εφαρμογές της στατιστικής, όπως η πρόβλεψη πωλήσεων ενός προϊόντος με βάση το κόστος της διαφήμισης, η εκτίμηση της ταχύτητας του ανέμου ως συνάρτηση της θερμοκρασίας, της υγρασίας και της ατμοσφαιρικής πίεσης, και της οικονομικής θεωρίας, όπως για παράδειγμα η πρόβλεψη της τιμής μετοχών.

Γραμμική παλινδρόμηση

Μία από τις πιο διαδεδομένες στατιστικές τεχνικές ανάλυσης δεδομένων είναι η γραμμική παλινδρόμηση. Θεωρούμε το σύνολο δεδομένων της μορφής $\{(y_i, x_{i1}, \dots, x_{ip}), i = 1, \dots, n\}$, όπου $y_i, i = 1, \dots, n$ οι τιμές της μεταβλητής απόκρισης Y , $x_{ik}, i = 1, \dots, n, k = 1, \dots, p$ οι αντίστοιχες τιμές των χαρακτηριστικών X_k και το μοντέλο γραμμικής παλινδρόμησης:

$$y_i = \beta_0 + \sum_{k=1}^p \beta_k x_{ik} + \varepsilon_i, \quad i = 1, \dots, n. \quad (2.7)$$

Στην παραπάνω εξίσωση, $\beta_k, k = 0, \dots, p$ οι άγνωστες παράμετροι του μοντέλου και $\varepsilon_i, i = 1, \dots, n$ τα τυχαία σφάλματα του μοντέλου, για τα οποία υποθέτουμε ότι ακολουθούν κανονική κατανομή με μέση τιμή 0 και διασπορά σ^2 και ότι είναι μεταξύ τους ασυσχέτιστα.

Με χρήση πινάκων το γραμμικό μοντέλο γράφεται στη μορφή:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (2.8)$$

όπου \mathbf{X} είναι ο πίνακας

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & \dots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{np} \end{bmatrix} \quad (2.9)$$

και $\mathbf{Y}, \boldsymbol{\beta}, \boldsymbol{\varepsilon}$ τα διανύσματα

$$\mathbf{Y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}. \quad (2.10)$$

Οι εκτιμήσεις των παραμέτρων, υπολογίζονται με τη μέθοδο ελαχίστων τετραγώνων και δίνονται από τον τύπο:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}. \quad (2.11)$$

Ridge Regression (L2 Regularization)

Η πολυσυγγραμμικότητα είναι ένα φαινόμενο που εμφανίζεται, όταν σε ένα σύνολο δεδομένων παρουσιάζεται υψηλή συσχέτιση μεταξύ των χαρακτηριστικών. Στο μοντέλο της γραμμικής παλινδρόμησης η ύπαρξη της οδηγεί σε υψηλά τυπικά σφάλματα για τις εκτιμήσεις ελαχίστων τετραγώνων και γι' αυτό το λόγο είναι δύσκολο να βρεθούν οι στατιστικά σημαντικές μεταβλητές που θα συμμετέχουν στο μοντέλο.

Στις περιπτώσεις που έχουμε ένα μεγάλο σύνολο δεδομένων, το οποίο αποτελείται από πολλές μεταβλητές, συχνά παρατηρούνται υψηλές συσχετίσεις. Μία μέθοδος που προτείνεται για την ανάλυση τέτοιων συνόλων δεδομένων είναι η παλινδρόμηση τύπου Ridge [50], με βάση την οποία συρρικνώνται κάποιοι συντελεστές παλινδρόμησης. Οι εκτιμήσεις της παλινδρόμησης ridge, υπολογίζονται ελαχιστοποιώντας την ποσότητα

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{k=1}^p \beta_k x_{ik} \right)^2 + \lambda \sum_{k=1}^p \beta_k^2 , \quad (2.12)$$

όπου $\lambda \geq 0$ μια ρυθμιστική παράμετρος. Για $\lambda = 0$, η εξίσωση περιγράφει τα ελάχιστα τετράγωνα.

Lasso Regression (L1 Regularization)

Ένα πρόβλημα που παρουσιάζεται με τη χρήση της μεθόδου Ridge, είναι ότι δε γίνεται επιλογή των μεταβλητών που συμμετέχουν στο μοντέλο. Στην περίπτωση που το πλήθος των επεξηγηματικών μεταβλητών είναι μεγάλο τότε το μοντέλο που προκύπτει δεν είναι εύκολα ερμηνεύσιμο. Στόχος μας είναι να επιλέξουμε ένα μοντέλο το οποίο χρησιμοποιεί τις μεταβλητές εκείνες που έχουν την πιο σημαντική επίδραση στην εξαρτημένη μεταβλητή.

Για την αντιμετώπιση του παραπάνω προβλήματος χρησιμοποιούμε τη μέθοδο Lasso (Least Absolute Shrinkage and Selection Operator) [51], με βάση την οποία συρρικνώνται κάποιοι συντελεστές παλινδρόμησης, ενώ κάποιοι άλλοι μηδενίζονται. Οι εκτιμήσεις της παλινδρόμησης Lasso, υπολογίζονται ελαχιστοποιώντας τη σχέση

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{k=1}^p \beta_k x_{ik} \right)^2 + \lambda \sum_{k=1}^p |\beta_k| , \quad (2.13)$$


όπου $\lambda \geq 0$ μια ρυθμιστική παράμετρος. Ομοίως με πριν για $\lambda = 0$, η εξίσωση περιγράφει τα ελάχιστα τετράγωνα.

eXtreme Gradient Boosting trees (xgboost)

Με τον όρο συλλογική μάθηση (Ensemble Learning) αναφερόμαστε στον συνδυασμό πολλαπλών –ατομικών- μοντέλων, με σκοπό τη δημιουργία ισχυρότερων. Ένας τρόπος για τη δημιουργία αυτής της συλλογής είναι η χρήση της τεχνικής της ενδυνάμωσης (Boosting). Πιο συγκεκριμένα, η αρχή γίνεται με την εκπαίδευση ενός μοντέλου. Στη συνέχεια, κατασκευάζεται ένα δεύτερο που εστιάζει στην ακριβή πρόβλεψη των περιπτώσεων, όπου το πρώτο είχε χαμηλή απόδοση, με σκοπό ο συνδυασμός αυτών των δύο μοντέλων να είναι καλύτερος από την εφαρμογή του καθένα ξεχωριστά. Έπειτα, επαναλαμβάνεται αυτήν η διαδικασία ενδυνάμωσης πολλαπλές φορές, με κάθε επόμενο

2.2 Τεχνητή νοημοσύνη

μοντέλο να προσπαθεί να διορθώσει τις αδυναμίες του συνδυασμού όλων των προηγούμενων. Το Gradient Boosting είναι ένας τύπος ενδυνάμωσης που περιγράφηκε προηγουμένως. Βασίζεται στη διαίσθηση ότι το καλύτερο δυνατό επόμενο μοντέλο, όταν συνδυάζεται με τα προηγούμενα, ελαχιστοποιεί το συνολικό σφάλμα πρόβλεψης. Ουσιαστικά, για μια αυθαίρετη διαφορίσιμη συνάρτηση απωλειών, επιλέγει «αδύναμες» προβλέψεις που δείχνουν προς την αρνητική κατεύθυνση της κλίσης (gradient).



Εικόνα 6: Υπολογισμός τελικής εκτίμησης στη συλλογική μάθηση [Πηγή]

Η μέθοδος xgboost (eXtreme Gradient Boosting) [52], ανήκει στην οικογένεια αλγορίθμων Ensemble Learning, όπου τα επιμέρους μοντέλα είναι δέντρα, και βασίζεται στο gradient boosting με τη συνάρτηση απωλειών να δίνεται από τον τύπο

$$L(t) = \sum_{i=1}^n l(y_i, \hat{y}_i(t)) + \sum_{k=1}^T \Omega_{f(t)}, \quad (2.14)$$

Ο πρώτος όρος μετράει πόσο καλά προσαρμόζεται το μοντέλο στα δεδομένα εκπαίδευσης (μικρές τιμές υποδηλώνουν καλή προσαρμογή) και ο δεύτερος την πολυπλοκότητα του κάθε δέντρου. Στην πολυπλοκότητα του δέντρου εισάγεται ένας νέος όρος εκτός από τον αριθμό φύλλων (T), όπου τα βάρη των φύλλων συρρικνώνονται και το $\Omega_{f(t)}$ υπολογίζεται από τον τύπο

$$\Omega_{f(t)} = \gamma T + \frac{1}{2} \lambda \|w\|^2, \quad (2.15)$$

όπου το γ , ελέγχει την ανάπτυξη του δέντρου (μεγάλες τιμές οδηγούν σε μικρά δέντρα) και το λ , ρυθμίζει κατά πόσο θα συρρικνώνονται τα βάρη του δέντρου.

2.2.5.1 Αξιολόγηση παλινδρόμησης

Η πιο συνηθισμένη μετρική για την αξιολόγηση της παλινδρόμησης είναι ο συντελεστής R^2 ή αλλιώς συντελεστής προσδιορισμού (coefficient of determination), ο οποίος δείχνει πόση διακύμανση μιας εξαρτημένης μεταβλητής εξηγείται από τις ανεξάρτητες μεταβλητές σε ένα μοντέλο παλινδρόμησης. Ωστόσο, η σχέση

$$\text{Explained variance} + \text{Error variance} = \text{Total variance} \quad (2.16)$$

ισχύει μόνο για τα γραμμικά μοντέλα, καθιστώντας τον συντελεστή R^2 ακατάλληλο για τη σύγκριση αποτελεσμάτων μεταξύ γραμμικών και μη γραμμικών μοντέλων [53].

2.2 Τεχνητή νοημοσύνη

Έτσι, στην παρούσα διπλωματική θα χρησιμοποιηθεί το Μέσο Απόλυτο Σφάλμα πρόβλεψης (MAE), που εκφράζει τη μέση διαφορά των πραγματικών τιμών και των εκτιμήσεων, είναι λιγότερο ευαίσθητο σε εξωκείμενες τιμές και οι μονάδες του είναι οι ίδιες με αυτών των δεδομένων. Επιπλέον, θα αξιοποιηθεί η ρίζα του μέσου τετραγωνικού σφάλματος (RMSE), που υπολογίζει την τυπική απόκλιση των σφαλμάτων πρόβλεψης. Αξίζει να σημειωθεί, πως μικρότερες τιμές για τις δύο αυτές μετρικές (καλύτερη το 0) σημαίνει καλύτερο μοντέλο. Τέλος, δίνονται από τους εξής τύπους:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| , \quad (2.17)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} , \quad (2.18)$$

όπου y_i , η πραγματική τιμή, \hat{y}_i , η εκτίμηση και N ο αριθμός των δειγμάτων.

3 Σχετική Βιβλιογραφία

Στο παρόν Κεφάλαιο αναλύεται η ήδη υπάρχουσα βιβλιογραφία για την εκτίμηση του Επιπέδου Φόρτισης της μπαταρίας (SOC-State of Charge). Στην Ενότητα 3.1 παρουσιάζονται οι συμβατικές τεχνικές που βασίζονται σε μια φυσική ιδιότητα της μπαταρίας. Στην Ενότητα 3.2 παρατίθενται τα προσαρμοστικά φίλτρα, που χρησιμοποιούν διάφορα μοντέλα μπαταριών σε συνδυασμό με τις φυσικές ιδιότητές της (model-based τεχνικές). Τέλος, στην Ενότητα 3.3 αναλύονται οι τεχνικές εκτίμησης που εντάσσονται στη μηχανική μάθηση (data-driven τεχνικές).

3.1 Συμβατικές τεχνικές

Στην εν λόγω κατηγορία, εντάσσονται οι προσπάθειες στη βιβλιογραφία, που χρησιμοποιούν κάποια φυσική ιδιότητα της μπαταρίας, όπως η τάση, το ρεύμα εκφόρτισης, την εσωτερική αντίσταση και τη σύνθετη αντίστασή της.

3.1.1 Τάση Ανοιχτού Κυκλώματος

Αρχικά, η Τάση Ανοιχτού Κυκλώματος (OCV-Open Circuit Voltage), ορίζεται ως η διαφορά ηλεκτρικού δυναμικού μεταξύ δύο ακροδεκτών μιας συσκευής όταν αποσυνδέεται από οποιοδήποτε κύκλωμα. Ουσιαστικά, δεν υπάρχει συνδεδεμένο εξωτερικό φορτίο και το ρεύμα μεταξύ των ακροδεκτών είναι μηδενικό. Η σχέση μεταξύ της τάσης ανοιχτού κυκλώματος και του επιπέδου φόρτισης δεν είναι ακριβώς η ίδια για όλους τους τύπους των μπαταριών, καθώς εξαρτάται από τη χωρητικότητα και το υλικό της μπαταρίας [1], αλλά μπορεί να θεωρηθεί ως μια καλή εκτίμηση [2], εφόσον η μπαταρία ξεκουραστεί επαρκώς για να φτάσει σε ισορροπία.

Τα πλεονεκτήματα αυτής της μεθόδου είναι η απλότητά της και η υψηλή ακρίβεια που μπορεί να επιτύχει. Το βασικό της μειονέκτημα είναι ο χρόνος που χρειάζεται για να φτάσει η μπαταρία σε κατάσταση ισορροπίας [3]. Πιο συγκεκριμένα, ο χρόνος ξεκούρασης που απαιτείται για να επέλθει η ισορροπία από την κατάσταση λειτουργίας, εξαρτάται από τη θερμοκρασία, το ρεύμα φορτίου και ούτω καθεξής. Για παράδειγμα, μια μπαταρία LiFePO4 (Lithium iron phosphate) σε χαμηλή θερμοκρασία, χρειάζεται περισσότερες από 2 ώρες.

Κατά συνέπεια, η μέθοδος αυτήν είναι δεν είναι εύκολα εφαρμόσιμη για εκτίμηση σε πραγματικό χρόνο. Αξίζει να σημειωθεί πως έχουν γίνει προσπάθειες για μια τέτοια εκτίμηση. Πιο συγκεκριμένα, ο Y. Xing και οι συνεργάτες του [4], υπολόγισαν σε πρώτο χρόνο την καμπύλη τάσης ανοιχτού κυκλώματος - επιπέδου φόρτισης και τη χρησιμοποίησαν ως πίνακα αναφοράς για εκτίμηση σε πραγματικό χρόνο. Η καμπύλη υπολογίστηκε για διάφορες θερμοκρασίες, 0, 25, 45 °C, δείχνοντας πως η συμπεριφορά της μπαταρίας επηρεάζεται σε μεγάλο βαθμό από τη θερμοκρασία και εφάρμοσαν δύο τεχνικές:

- Low Current OCV:** Η ύπαρξη μικρού ρεύματος, επιτρέπει την τάση υπό φορτίο (terminal voltage) να είναι καλή προσέγγιση της τάσης ανοιχτού κυκλώματος, χωρίς να χρειάζεται η ξεκούραση της μπαταρίας.
- Incremental OCV:** Η μπαταρία εκφορτίζεται με αρνητικό παλμό ρεύματος και κάθε 10% μείωσης (ή στην περίπτωση φόρτισης, αύξησης) του επιπέδου φόρτισης η μπαταρία ξεκουράζεται για 2 ώρες.

Τέλος, η μέθοδος αυτήν απαιτεί προσεκτικές παρατηρήσεις για τη μέτρηση της τάσης φόρτισης και εκφόρτισης, καθώς οι μπαταρίες εμφανίζουν χαρακτηριστικά υστέρησης

3.1 Συμβατικές τεχνικές

που οδηγούν σε υψηλό SOC όταν η μπαταρία φορτίζεται και χαμηλό όταν αποφορτίζεται [5].

3.1.2 Ρεύμα Εκφόρτισης - Coulomb Counting Method

Πρόκειται για μια από τις απλούστερες και πιο πρακτικές τεχνικές για την εκτίμηση του SOC της μπαταρίας και χρησιμοποιείται συχνά για εκτίμηση σε πραγματικό χρόνο [6]. Η μέθοδος είναι εύκολη στην εφαρμογή, με χαμηλή ισχύ στους υπολογισμούς και βασίζεται στην ολοκλήρωση του ρεύματος που διαρρέει την μπαταρία σε σχέση με το χρόνο κατά τη φόρτιση / εκφόρτιση της μπαταρίας. Η μαθηματική σχέση είναι η εξής:

$$SOC(t) = SOC(t = 0) - \frac{\int_0^t \eta * i(\tau) d\tau}{C_n} \quad (3.1)$$


- η Η απόδοση κουλόμπ (coulombic efficiency), ορίζεται ως ο λόγος της ενέργειας που απαιτείται για φόρτιση προς την ενέργεια εκφόρτισης για την ανάκτηση της αρχικής χωρητικότητας.
- $i(\cdot)$ Το ρεύμα που διαρρέει την μπαταρία, αρνητικό για φόρτιση και θετικό για εκφόρτιση.
- C_n Η ονομαστική χωρητικότητα της μπαταρίας.
- t Ο χρόνος.

Ωστόσο, είναι ένας αλγόριθμος ανοιχτού βρόγχου και μπορεί να οδηγήσει σε σημαντικές ανακρίβειες και σφάλματα, λόγω θορύβου, διαταραχών και αβεβαιοτήτων στη θερμοκρασία, στο ρεύμα και στη χωρητικότητα [8]. Παράλληλα, μια ακόμα πηγή σφάλματος είναι ο προσδιορισμός της αρχικής τιμής του επιπέδου φόρτισης που συνεισφέρει στη συσσώρευση του σφάλματος [7]. Επιπλέον, η ακρίβεια της εκτίμησης εξαρτάται σε μεγάλο βαθμό από τους αισθητήρες ρεύματος που χρησιμοποιούνται. Αυτοί συχνά ολισθαίνουν (drifting), λόγω της θερμοκρασίας και άλλων αβεβαιοτήτων [8], με αποτέλεσμα να εισάγουν σφάλμα, το οποίο είναι αθροιστικό λόγω του ολοκληρώματος. Τέλος, έχουν αναπτυχθεί τεχνικές με τις οποίες η ακρίβεια της μεθόδου είναι αποδεκτή, όπως η τακτική βαθμονόμηση της χωρητικότητας -τεχνική όμως που μειώνει τη διάρκεια ζωής της μπαταρίας [9]- και η ρύθμιση/διόρθωση της ολίσθησης του αισθητήρα ρεύματος [10].

3.1.3 Εσωτερική και Σύνθετη Αντίσταση

Η ηλεκτροχημική φασματοσκοπία σύνθετης αντίστασης (EIS), έχει χρησιμοποιηθεί εκτενώς για την κατανόηση των ηλεκτροχημικών αντιδράσεων που συμβαίνουν εντός των μπαταριών (Κεφάλαιο 2) και τον προσδιορισμό του SOC. Για να εφαρμοστεί αυτήν η μέθοδος, ένα κατάλληλο ηλεκτροχημικό μοντέλο είναι απαραίτητο. Στη συνέχεια, η σύνθετη αντίσταση της μπαταρίας εκτιμάται, μέσω επαγωγών και χωρητικοτήτων για ένα εύρος συχνοτήτων [11].

Εντούτοις, η μέθοδος μπορεί να αποβεί δύσκολη στην υλοποίηση και με υψηλό κόστος. Πιο συγκεκριμένα, απαιτούνται γεννήτριες για την παραγωγή των ημιτονοειδών σημάτων διαφόρων συχνοτήτων. Παράλληλα, η χρήση του γρήγορου μετασχηματισμού Fourier (FFT) αυξάνει σημαντικά τους υπολογισμούς. Ακόμα και αν η σύνθετη αντίσταση υπολογιστεί, η συσχέτιση της με το επίπεδο φόρτισης δεν είναι τόσο ισχυρή, όπως φαίνεται στην παρακάτω εικόνα: η σύνθετη αντίσταση δεν είναι ευαίσθητη σε μεταβολές του επιπέδου φόρτισης και μάλιστα η συσχέτιση τους είναι μη μονότονη [49]. Τέλος, η σύνθετη αντίσταση επηρεάζεται περισσότερο από αλλαγές στη θερμοκρασία και τη γήρανση της μπαταρίας και η αντιστάθμιση αυτών των επιρροών στο τελικό αποτέλεσμα είναι αρκετά πολύπλοκη [13].



Εικόνα 7: Διακύμανση της σύνθετης αντίστασης (σε mΩ) αναφορικά με το επίπεδο φόρτισης σε μπαταρίες ιόντων λιθίου (στους 25 °C) [12]

Να σημειωθεί σ' αυτό το σημείο, πως η εκτίμηση με βάση την εσωτερική αντίσταση μπορεί να θεωρηθεί ως ειδική περίπτωση της εκτίμησης με βάση τη σύνθετη αντίσταση. Συγκριτικά, η εσωτερική αντίσταση είναι πιο εύκολο να υπολογιστεί, αλλά υπόκειται και αυτή στους παραπάνω περιορισμούς.

3.2 Προσαρμοστικά φίλτρα

Οι παραπάνω συμβατικές τεχνικές, δεν κατάφεραν να επιτύχουν καλή ακρίβεια εκτίμησης για το επίπεδο φόρτισης χρησιμοποιώντας μόνο τις φυσικές ιδιότητες της μπαταρίας. Έτσι, στη συνέχεια περιγράφονται τα προσαρμοστικά φίλτρα, που χρησιμοποιούν διάφορα μοντέλα και αλγορίθμους, σε συνδυασμό με τις παραπάνω φυσικές ιδιότητες. Πιο συγκεκριμένα, θα αναλυθούν τα Kalman Filters, τα Extended Kalman Filter και τα Unscented Kalman Filter, που ανήκουν στην οικογένεια των Bayesian φίλτρων (Εικόνα 8).

3.2.1 Kalman Filter (KF)

Το Kalman Filter (KF) είναι ένα έξυπνο εργαλείο για την εκτίμηση της δυναμικής κατάστασης της μπαταρίας, μια καλά σχεδιασμένη μέθοδος, η οποία φιλτράρει τις παραμέτρους από αβέβαιες και ανακριβείς παρατηρήσεις. Παρότι το υπολογιστικό του κόστος είναι υψηλό, έχει γνωρίσει μεγάλη επιτυχία στην εκτίμηση των καταστάσεων της μπαταρίας. Το πιο ελκυστικό του χαρακτηριστικό είναι η αυτοδιορθωτική του φύση, η οποία το βοηθά να ανεχτεί μεγάλες διακυμάνσεις στο ρεύμα. Στην πραγματικότητα είναι ένα σύνολο μαθηματικών εξισώσεων, που προβλέπουν και διορθώνουν μια νέα κατάσταση επανειλημμένα, καθώς το σύστημα λειτουργεί.


Ο αλγόριθμος παρέχει μια αναδρομική λύση μέσω ενός γραμμικού βέλτιστου φιλτραρίσματος για την εκτίμηση των μεταβλητών κατάστασης. Επιπλέον, συγκρίνει τα μετρούμενα δεδομένα εισόδου και τα δεδομένα εξόδου για τον υπολογισμό της ελάχιστης μέσης τετραγωνικής απόκλισης από την πραγματική κατάσταση. Τέλος, το μοντέλο του Kalman Filter περιγράφεται από τις εξής εξισώσεις [14]:

$$\text{Πρόβλεψη: } \hat{x}_t = A_t \hat{x}_{t-1} + B_t u_t + \varepsilon_t , \quad (3.2)$$

$$\text{Διόρθωση: } z_t = C_t \hat{x}_t + \delta_t . \quad (3.3)$$

3.2 Προσαρμοστικά φίλτρα

- A_t Πίνακας ($n \times n$) που περιγράφει πως η κατάσταση μεταβαίνει από τη στιγμή $t - 1$ στη t , χωρίς έλεγχο ή θόρυβο.
- B_t Διάνυσμα ($n \times l$) που περιγράφει πως ο έλεγχος u_t αλλάζει την κατάσταση από τη στιγμή $t - 1$ στη t .
- C_t Πίνακας ($k \times n$) που περιγράφει την αντιστοίχιση της κατάστασης x_t στη μέτρηση z_t .
- ε_t, δ_t Τυχαίες μεταβλητές που αντιπροσωπεύουν τον θόρυβο πρόβλεψης και μέτρησης, θεωρούνται ανεξάρτητες και γκαουσιανές.



Εικόνα 8: Η συνεχής διαδικασία πρόβλεψης και διόρθωσης των Bayesian φίλτρων [Πηγή]

Ο Ting και η ομάδα του [15], χρησιμοποίησαν ένα RC μοντέλο μπαταρίας για να μοντελοποιήσουν το KF. Οι εξισώσεις που προκύπτουν από την ανάλυση του κυκλώματος, μετατρέπονται σε εξισώσεις κατάστασης για να περιγράψουν τη δυναμική συμπεριφορά της μπαταρίας. Οι Urbain και Rael [16] χρησιμοποίησαν την ίδια τεχνική σε ένα απλό ηλεκτρικό ισοδύναμο μοντέλο μιας μπαταρίας ιόντων λιθίου, το οποίο περιείχε μια πηγή τάσης συνδεδεμένη σε σειρά με μια αντίσταση. Αξίζει να σημειωθεί πως και οι δύο αυτές προσπάθειες πέτυχαν πολύ καλά αποτελέσματα στην εκτίμηση του SOC, με σφάλμα < 5%. Τέλος, οι Yatsui και Bai [17] συνδύασαν το KF με την τάση ανοιχτού κυκλώματος (OCV) και με το ρεύμα εκφόρτισης (Coulomb Counting) για να αντισταθμίσουν τους παράγοντες που επηρεάζουν την πρόβλεψη όσο η μπαταρία λειτουργεί και πράγματι βελτίωσαν την ακρίβεια των μεθόδων αυτών.

3.2.2 Extended Kalman Filter (EKF)

Η λειτουργία των KF βασίζεται στο γραμμικό μοντέλο καταστάσεων και στην υπόθεση γκαουσιανών κατανομών και θορύβου. Στην πραγματικότητα, το μοντέλο των μπαταριών είναι μη γραμμικό και οι εξισώσεις έχουν την εξής μορφή

$$\text{Πρόβλεψη: } x_t = g(u_t, x_{t-1}) + \varepsilon_t, \quad (3.4)$$

$$\text{Διόρθωση: } z_t = h(x_t) + \delta_t, \quad (3.5)$$

όπου $g(\cdot), h(\cdot)$ οι μη γραμμικότητες.

Τα EKF εφαρμόζονται συχνά για την αντιμετώπιση αυτών των μη γραμμικοτήτων. Πιο συγκεκριμένα, στα EKF χρησιμοποιούνται μερικές παράγωγοι και η ανάπτυξη σε σειρά Taylor πρώτης τάξης, έτσι ώστε να γραμμικοποιηθεί –τοπικά– το μοντέλο της μπαταρίας. Η γραμμικοποίηση λαμβάνει χώρα κάθε χρονική στιγμή, με το μοντέλο να συγκρίνει την εκτίμηση με την υπό μέτρηση τάση των μπαταριών και να διορθώνει τις παραμέτρους εκτίμησης του SOC. Βέβαια, το σφάλμα γραμμικοποίησης θα είναι υψηλό εάν το σύστημα


3.2 Προσαρμοστικά φίλτρα

είναι εξαιρετικά μη γραμμικό, αφού η ανάπτυξη σε σειρά Taylor πρώτης τάξης πάσχει από έλλειψη ακρίβειας σε τέτοιες περιπτώσεις [18].

Ο Chen με την ομάδα του [19], χρησιμοποίησαν το EKF με ένα μη γραμμικό μοντέλο μπαταρίας για τον υπολογισμό του SOC σε μπαταρίες ιόντων λιθίου. Το μη γραμμικό αυτό μοντέλο αποτελείται από τη μη γραμμική τάση ανοιχτού κυκλώματος (OCV) και ένα κύκλωμα RC δεύτερης τάξης. Το EKF εφαρμόζεται για να μειώσει την επίδραση του θορύβου, με το προτεινόμενο μοντέλο να επιτυγχάνει πιο ακριβή αποτελέσματα για την εκτίμηση του SOC με άγνωστη την αρχική τιμή. Στο [20] ο Zhu, πρότεινε ένα βελτιωμένο μοντέλο δεύτερης τάξης για την εκτίμηση του SOC υπό διαφορετικές συνθήκες, όπως θερμοκρασία και ρυθμούς εκφόρτισης. Το προτεινόμενο μοντέλο είχε καλύτερη απόδοση από τη Coulomb Counting τεχνική, όσον αφορά την αποτελεσματικότητα και τη δυναμική προσαρμοστικότητα. Τέλος, στο [21] αναπτύσσεται ένας Adaptive Extended Kalman Filter (AEKF) αλγόριθμος για πιο σωστή και εύρωστη εκτίμηση του SOC, με την απόδοση της μεθόδου να ελέγχεται μέσω ενός δυναμικού προφίλ ρεύματος. Τα αποτελέσματα δείχνουν ότι το AEKF είναι καλύτερο από το EKF όσον αφορά την ακρίβεια και την αξιοπιστία, με το εκτιμώμενο σφάλμα να είναι της τάξης του 1%.

3.2.3 Unscented Kalman Filter (UKF)

Η αξιοποίηση των EKF περιορίζεται μόνο σε μη γραμμικά μοντέλα πρώτης και δεύτερης τάξης, καθώς σε υψηλότερες μη γραμμικότητες οδηγεί σε μεγάλα σφάλματα γραμμικοποίησης. Για την αντιμετώπιση αυτού του προβλήματος, γίνεται η χρήση των UKF. Η μέθοδος αυτή δεν απαιτεί τον υπολογισμό του ιακωβιανού πίνακα και γκαουσιανό θόρυβο [22], χαρακτηριστικά που την κάνουν κατάλληλη για χρήση στην εκτίμηση του SOC, καθώς η λειτουργία των μπαταριών χαρακτηρίζεται από υψηλές μη γραμμικότητες και οι ιδιότητες του θορύβου συνήθως είναι άγνωστες. Επιπλέον, η ακρίβεια των UKF είναι καλύτερη από αυτήν των EKF, αλλά υστερεί στην ευρωστία, λόγω αβεβαιοτήτων στη μοντελοποίηση και ύπαρξη διαταραχών στο σύστημα.



Εικόνα 9: Σύγκριση μετασχηματισμού μεταξύ EKF και UKF [[Πηγή](#)]

Ο He με την ομάδα του [23], ανέπτυξαν έναν αλγόριθμο που συνδυάζει την Coulomb Counting τεχνική με ένα μοντέλο που προσομοιώνει την τάση της μπαταρίας ως συνάρτηση του SOC. Το UKF χρησιμοποιείται για την αυτόματη προσαρμογή των παραμέτρων του μοντέλου για τη μείωση του σφάλματος στην εκτίμηση του SOC που προκαλείται από περιβαντολογικές αλλαγές και την αυτοεκφόρτιση της μπαταρίας, με το μέσο σφάλμα εκτίμησης να είναι $< 4\%$, υπό δυναμικό φορτίο. Τέλος, στο [24] αναπτύσσεται ένας Adaptive Unscented Kalman Filter (AUKF) αλγόριθμος για την online εκτίμηση του SOC. Το πλεονέκτημα αυτής της προσέγγισης είναι ότι προσαρμοστικά

3.3 Τεχνικές μηχανικής μάθησης

διορθώνει τη συνδιακύμανση του θορύβου και ταυτόχρονα χρειάζεται λίγους πόρους λόγω της απλής δομής του. Μια σύγκριση ανάμεσα σε EKF, AEKF, UKF και AUKF αλγορίθμους, έδειξε πως το AUKF είναι καλύτερο μοντέλο όσον αφορά την απόδοση και την ακρίβεια εκτίμησης.

3.3 Τεχνικές μηχανικής μάθησης

Οι τεχνικές που περιγράφηκαν στην προηγούμενη ενότητα, απαιτούν την κατασκευή ενός φυσικού μοντέλου (model-based τεχνικές) μοντέλο που είναι δύσκολο να βρεθεί λόγω της φύσης του προβλήματος (μη γραμμικό, χρονομεταβαλλόμενο, δυναμικό). Ταυτόχρονα, ακόμα και αν το μοντέλο αυτό είναι διαθέσιμο, στις περισσότερες περιπτώσεις, δεν είναι εύκολο να προσδιοριστούν οι παράμετροί του, κάτω από διαφορετικές συνθήκες λειτουργίας. Έτσι, στη συνέχεια θα παρουσιαστούν τεχνικές που βασίζονται στα δεδομένα (data-driven τεχνικές) και ανήκουν στη μηχανική μάθηση.

3.3.1 Γενετικοί αλγόριθμοι

Ο γενετικός αλγόριθμος είναι μια μέθοδος βελτιστοποίησης, για την εύρεση των αγνώστων παραμέτρων ενός μοντέλου που περιγράφει ένα μη γραμμικό σύστημα, όπως μια μπαταρία ιόντων λιθίου. Ο τρόπος λειτουργίας των γενετικών αλγορίθμων είναι εμπνευσμένος από τη Βιολογία. Χρησιμοποιεί την ιδέα της εξέλιξης μέσω γενετικής μετάλλαξης, φυσικής επιλογής και διασταύρωσης [25]. Οι τιμές για τις παραμέτρους του συστήματος πρέπει να κωδικοποιούνται με τρόπο ώστε να αναπαρασταθούν από μια μεταβλητή. Αυτή η μεταβλητή μιμείται το γενετικό κώδικα που υπάρχει στους ζωντανούς οργανισμούς. Αρχικά, ο γενετικός αλγόριθμος παράγει πολλαπλά αντίγραφα της μεταβλητής, συνήθως με τυχαίες τιμές, δημιουργώντας ένα πληθυσμό λύσεων. Κάθε λύση, δηλαδή τιμές για τις παραμέτρους του συστήματος, ελέγχεται για το πόσο κοντά φέρνει την αντίδραση του συστήματος στην επιθυμητή, μέσω μιας συνάρτησης που δίνει το μέτρο ικανότητας της λύσης και η οποία ονομάζεται αντικειμενική συνάρτηση.


Ο Zheng [26], χρησιμοποίησε την καμπύλη τάσης-χωρητικότητας και υλοποίησε έναν γενετικό αλγόριθμο για να μοντελοποιήσει την μπαταρία. Το μέγιστο μέσο σφάλμα στην εκτίμηση του SOC ήταν $< 0.5\%$. Επιπλέον, αξίζει να σημειωθεί πως οι γενετικοί αλγόριθμοι συχνά χρησιμοποιούνται σε συνδυασμό με τεχνικές που απαιτούν την ύπαρξη μοντέλου (model-based). Ο Chen και η ομάδα του [27], δημιούργησαν ένα μοντέλο βάσει ενός περιορισμένου αριθμού ελλιπών δεδομένων. Η διαφορά με προηγούμενα μοντέλα, ήταν πως αυτό δεν ήταν υψηλής πιστότητας και συνεπώς δεν απαιτούσε μεγάλη ισχύ υπολογισμών. Ο γενετικός αλγόριθμος χρησιμοποιήθηκε για να υπολογίσει τους βέλτιστους συντελεστές, με το μοντέλο να ελέγχεται πειραματικά υπό διαφορετικές συνθήκες αποφόρτισης και να επιτυγχάνει μέσο απόλυτο σφάλμα $\leq \pm 1\%$. Τέλος, ο Mu με την ομάδα του [28], αξιοποίησαν τον γενετικό αλγόριθμο για τον υπολογισμό των παραμέτρων του μοντέλου σύνθετης αντίστασης που προέκυψε από την ηλεκτροχημική φασματοσκοπία σύνθετης αντίστασης (EIS). Ο γενετικός αλγόριθμος σε συνδυασμό με το UKF, οδήγησαν σε μέσο απόλυτο σφάλμα $\leq \pm 3\%$.

3.3.2 Νευρωνικά δίκτυα

Το νευρωνικό δίκτυο έχει πολύ υψηλή ικανότητα μάθησης και μπορεί να καθορίσει ένα πολύπλοκο και μη γραμμικό σύστημα. Σε πρώτη φάση, τα νευρωνικά δίκτυα χρησιμοποιήθηκαν για να αντιστοιχήσουν τις μετρήσεις της εσωτερικής αντίστασης, του ρεύματος εκφόρτισης και της τάσης ανοιχτού κυκλώματος (διάνυσμα εισόδου) στο SOC (έξοδος) [29]. Το εκπαιδευμένο νευρωνικό, ελέγχθηκε υπό διαφορετικές συνθήκες, με το μέσο σφάλμα να είναι της τάξεως του $\pm 5\%$. Στη συνέχεια, το νευρωνικό δίκτυο πρόσθιας τροφοδότησης (feed-forward neural network) επιλέχθηκε για να εξαλείψει την ανάγκη

3.3 Τεχνικές μηχανικής μάθησης

καθορισμού μια σχέσης μεταξύ τάσης και SOC [30]. Οι είσοδοι στο νευρωνικό είναι η τάση της μπαταρίας, το ρεύμα που τη διαρρέει και η θερμοκρασία της, τόσο για την τωρινή μέτρηση όσο και των προηγούμενων 30. Ο συνδυασμός του νευρωνικού δικτύου πρόσθιας τροφοδότησης με το UKF για τη μείωση του σφάλματος, οδήγησε σε μέσο σφάλμα $\leq \pm 2.5\%$. Τέλος, ο Hannan και η ομάδα του [31], ανέπτυξαν έναν αλγόριθμο οπισθοδρομικής αναζήτησης (backtracking search algorithm), για να υπολογίσουν τον βέλτιστο ρυθμό εκμάθησης (learning rate) και τον αριθμό νευρώνων στο κρυφό επίπεδο, με σκοπό τη βελτίωση της απόδοσης και της ευρωστίας των νευρωνικών δικτύων οπισθοδιάδοσης (back-propagation neural network). Τα αποτελέσματα του είναι σαφώς καλύτερα από προηγούμενες προσπάθειες, με μέσο απόλυτο σφάλμα $\leq 0.87\%$.



Εικόνα 10: Η αρχιτεκτονική του νευρωνικού δικτύου πρόσθιας τροφοδότησης [30]


3.3.3 Μηχανές διανυσμάτων υποστήριξης (SVM)

Τα τελευταία χρόνια, οι μηχανές διανυσμάτων υποστήριξης (Support Vector Machines), έχουν προσελκύσει αρκετή προσοχή και χρησιμοποιούνται ολοένα και περισσότερο στην επίλυση προβλημάτων παλινδρόμησης σε μη γραμμικά συστήματα. Η λειτουργία τους βασίζεται στις συναρτήσεις πυρήνα (kernel functions), όπου το μη γραμμικό πρόβλημα θα μετατραπεί σε γραμμικό υψηλότερης διάστασης. Αξίζει να σημειωθεί, πως τα μειονεκτήματα αυτής της μεθοδολογίας είναι η ρύθμιση των -εμπειρικών- παραμέτρων του αλγορίθμου και η επιλογή της κατάλληλης συνάρτησης πυρήνα.

Οι πρώτες προσπάθειες, περιλάμβαναν μετρήσεις του ρεύματος εκφόρτισης, της τάσης και της θερμοκρασίας της μπαταρίας, από διάφορες φορτίσεις και εκφορτίσεις της υπό δυναμικό φορτίο [32]. Η συνάρτηση πυρήνα που επιλέχθηκε ήταν η συνάρτηση ακτινικής βάσης (Radial Basis Function) και τα αποτελέσματα έδειξαν μέσο σφάλμα $\leq \pm 6\%$. Ωστόσο, οι μετρήσεις αυτές επηρεάζονται σε μεγάλο βαθμό από τον θόρυβο που εισάγουν οι αισθητήρες. Έτσι, ο Sheng με την ομάδα του [33], συνδύασε τις μηχανές διανυσμάτων υποστήριξης με την ασαφή λογική για να βελτιώσει την ανοχή του μοντέλου στο θόρυβο των μετρήσεων και να αναγνωρίσει τις ακραίες τιμές (outliers). Αξίζει να σημειωθεί πως έγινε η σύγκριση της μεθοδολογίας αυτής με τα νευρωνικά δίκτυα, με το μέσο απόλυτο σφάλμα να είναι $\leq \pm 0.3\%$ και $\leq \pm 0.53\%$, αντίστοιχα. Τέλος, ο Xie με την ομάδα του [34], χρησιμοποιήσαν τις μηχανές διανυσμάτων υποστήριξης σε συνδυασμό με το UKF. Πιο συγκεκριμένα, η έξοδος του UKF, δηλαδή η αρχική εκτίμηση

3.3 Τεχνικές μηχανικής μάθησης

του SOC, δινόταν ως είσοδος στο SVM. Έτσι, η εκτίμηση του SOC, πραγματοποιείται κάθε χρονική στιγμή δύο φορές, με το σφάλμα να είναι $< 1\%$.



Εικόνα 11: Η δομή του κοινού αλγορίθμου UKF και SVM [34]

4 Μεθοδολογία

Το Κεφάλαιο αυτό περιλαμβάνει την αναλυτική περιγραφή της μεθοδολογίας που ακολουθήθηκε για τη διεκπεραίωση της παρούσης εργασίας. Στην Ενότητα 4.1, περιγράφεται η ανάπτυξη της Android εφαρμογής BatteryApp². Πιο συγκεκριμένα, αναλύονται τα υποσυστήματα και η αρχιτεκτονική της, και επεξηγούνται τα δεδομένα που συλλέγονται. Τέλος, στην Ενότητα 4.2, θα περιγραφεί η μεθοδολογία για την ανάλυση των δεδομένων αυτών με σκοπό την εκτίμηση της κατανάλωσης ενέργειας των κινητών τηλεφώνων.

4.1 Ανάπτυξη εφαρμογής BatteryApp

Στη βιβλιογραφία παρατίθενται παρόμοιες προσπάθειες που ασχολούνται με τη χρήση κινητών τηλεφώνων. Αρχικά, η εφαρμογή Carat [35], [36], του τμήματος πληροφορικής του πανεπιστημίου του Ελσίνκι, συνδέει τη χρήση του με συγκεκριμένες εφαρμογές που εκτελούνται κάθε στιγμή, ωστόσο το dataset που είναι δημόσια διαθέσιμο δεν περιέχει τη χρήση του επεξεργαστή. Επιπλέον, η εφαρμογή Device Analyzer [37] ασχολείται κυρίως με τη συνδεσιμότητα της συσκευής, όπως η ασύρματη σύνδεση στο ίντερνετ και η χρήση του GPS, και πως επηρεάζει την μπαταρία. Ομοίως με πριν, απουσιάζει το φορτίο του επεξεργαστή και δε λαμβάνονται υπόψιν άλλες πληροφορίες που επηρεάζουν τη συμπεριφορά της μπαταρίας. Έτσι, έγινε η επιλογή να αναπτυχθεί η εφαρμογή BatteryApp, για την καταγραφή περισσότερων πληροφοριών και τη συσχέτιση αυτών με τη μεταβολή του επιπέδου φόρτισης της μπαταρίας.

Αξίζει να σημειωθεί, πως το Android δεν είναι το αμιγώς λειτουργικό σύστημα των περισσότερων κινητών, καθώς οι κατασκευαστές έχουν αναπτύξει τα δικά τους λειτουργικά, τα οποία στον πυρήνα τους βασίζονται στο Android (Xiaomi: MIUI, Huawei: EMUI κα), ωστόσο δύνανται να χειρίζονται τις ίδιες λειτουργίες εντελώς διαφορετικά. Η αρχική ιδέα, ήταν η εφαρμογή με την εγκατάστασή της να ενεργοποιείται στο κινητό τηλέφωνο του χρήστη και να εκτελείται συνεχώς στο παρασκήνιο (background) συλλέγοντας δεδομένα ανά τακτά χρονικά διαστήματα. Ωστόσο, σε διαφορετικές εκδόσεις του Android ή ακόμα και σε διαφορετικές συσκευές με την ίδια έκδοση, η εφαρμογή τερματίζόταν από το λειτουργικό εντός σύντομου χρονικού διαστήματος, για εξοικονόμηση ενέργειας. Επιπλέον, το σύστημα επιβάλλει περιορισμούς σε εφαρμογές που τρέχουν στο παρασκήνιο (background services), εάν δεν είναι ανοικτές στο προσκήνιο³. Έτσι, επιλέχθηκε η εφαρμογή να αναπτυχθεί ως υπηρεσία προσκηνίου (foreground service), με τον χρήστη να την ενεργοποιεί πριν από κάθε χρήση. Η διαφορά έγκειται στην εμφάνιση μιας ειδοποίησης, όπου ο χρήστης γνωρίζει πως η εφαρμογή εκτελείται, ακόμα και αν δεν αλληλεπιδρά μ' αυτή. Αυτήν η ειδοποίηση δεν μπορεί να απορριφθεί εκτός εάν η εφαρμογή σταματήσει ή καταργηθεί από το προσκήνιο. Τέλος, αξίζει να διευκρινιστεί πως εφαρμογές μπορούν να τρέχουν χωρίς περιορισμούς στο παρασκήνιο, αν ανήκουν στη λίστα επιτρεπόμενων εφαρμογών (whitelist), η οποία περιλαμβάνει όλες τις εφαρμογές συστήματος, αλλά δεν είναι επεξεργάσιμη από τον μέσο χρήστη, καθώς απαιτούνται δικαιώματα διαχειριστή (rooted phones).

4.1.1 Υποσυστήματα εφαρμογής

Η εφαρμογή διαχωρίζεται σε δύο κύρια υποσυστήματα. Αρχικά, είναι η δραστηριότητα (Activity), δηλαδή το γραφικό περιβάλλον με το οποίο αλληλεπιδρά ο χρήστης και στη συνέχεια η υπηρεσία (Service), που εκτελεί συνεχώς τη λογική της εφαρμογής.


² <https://play.google.com/store/apps/details?id=gr.auth.ee.issel.batteryapp>

³ <https://developer.android.com/guide/components/services>

4.1 Ανάπτυξη εφαρμογής BatteryApp


4.1.1.1 Γραφικό περιβάλλον εφαρμογής

Η δραστηριότητα απεικονίζει στο χρήστη όλες τις πληροφορίες που συλλέγονται κατά τη λειτουργία της. Σε πρώτο στάδιο συνοψίζονται οι ενδείξεις για την μπαταρία, όπως το επίπεδο, η θερμοκρασία, η τεχνολογία, η κατάσταση και η υγεία της. Στη συνέχεια, παρουσιάζονται οι μετρήσεις που αφορούν τη χρήση του κινητού. Πιο συγκεκριμένα, εμφανίζονται η συνδεσιμότητα της συσκευής, δηλαδή η ασύρματη σύνδεση στο ίντερνετ μέσω του WiFi ή του δικτύου κινητής τηλεφωνίας (Cellular Data) και η ενεργοποίηση του Bluetooth, και η κατάσταση των υπολογιστικών πόρων που εκτελούνται στη συσκευή, ειδικότερα η διαθέσιμη μνήμη RAM, η φωτεινότητα της οθόνης και το φορτίο του επεξεργαστή (CPU).



Εικόνα 12: Στιγμιότυπο εφαρμογής BatteryApp


Έπειτα, παρατίθενται τα στοιχεία με τα οποία αλληλεπιδρά ο χρήστης. Αρχικά, ένα στοιχείο editText, για να επιλέξει την περίοδο δειγματοληψίας που επιθυμεί. Η επιλογή αυτήν μπορεί να είναι μεταξύ 5 και 10 δευτερολέπτων, όπου πιο συχνή δειγματοληψία προσφέρει δεδομένα μικρότερων διακυμάνσεων, αλλά καταναλώνει -οριακά- περισσότερους πόρους. Η οριστικοποίηση της επιλογής γίνεται μέσω του κουμπιού SUBMIT. Αν επιλεγεί περίοδος δειγματοληψίας εκτός του παραπάνω εύρους, ο χρήστης ενημερώνεται με το κατάλληλο μήνυμα σφάλματος. Συνεχίζοντας, με το κουμπί START SESSION, η εφαρμογή ελαχιστοποιείται και ο χρήστης μπορεί να συνεχίσει να αξιοποιεί τη συσκευή. Έχοντας ολοκληρώσει τη λειτουργία της, με το κουμπί END SESSION η εφαρμογή τερματίζεται. Η χρήση του κινητού μεταξύ της επιλογής αυτών των δύο κουμπιών, ορίζεται ως ένα Session λειτουργίας και συνοδεύεται από ένα JSON αρχείο που αποθηκεύεται στη συσκευή.



Εικόνα 13: Μήνυμα σφάλματος περιόδου δειγματοληψίας άνω των 10 δευτερολέπτων

4.1 Ανάπτυξη εφαρμογής BatteryApp


Για τη μεταφόρτωση των αρχείων, χρησιμοποιείται το Upload Button, χωρίς αυτή να είναι απαιτούμενη σε κάθε χρήση της εφαρμογής, αφού τα αρχεία θα διαγραφούν μόνο μετά από επιτυχή μεταφορά στον διακομιστή (server). Σ' αυτό το σημείο να σημειωθεί πως πριν την αποθήκευση τους στη βάση δεδομένων, πραγματοποιούνται διάφοροι έλεγχοι για λόγους ασφαλείας, αλλά και εγκυρότητας των αρχείων. Οι κλήσεις αυτές είναι ασύγχρονες και ο χρήστης ενημερώνεται με κατάλληλα μηνύματα, για το αποτέλεσμα της ενέργειας του. Τέλος, με τον διακόπτη Upload Only via WiFi, ο χρήστης μπορεί να επιτρέψει τη μεταφόρτωση του αρχείου μέσω δεδομένων κινητής τηλεφωνίας.



Εικόνα 14: Μηνύματα ενημέρωσης χρήστη για τη μεταφόρτωση αρχείου


4.1.1.2 Λογική εφαρμογής

Σ' αυτό το σημείο αξίζει να τονιστεί πως η δραστηριότητα είναι υπεύθυνη και για ένα μέρος της λογικής που εκτελείται από την εφαρμογή. Πιο συγκεκριμένα, κατά την πρώτη εκτέλεση της εφαρμογής στη συσκευή, δημιουργεί ένα 32-ψήφιο αναγνωριστικό μοναδικό για κάθε χρήστη που χρησιμοποιείται για την ανωνυμία των δεδομένων. Επιπλέον, προγραμματίζει μια ειδοποίηση υπενθύμισης, σε περίπτωση που η εφαρμογή δε χρησιμοποιηθεί για μια ημέρα. Τέλος, αρχικοποιεί και εκκινεί την υπηρεσία που εκτελείται όταν η εφαρμογή ελαχιστοποιηθεί.



Εικόνα 15: Ειδοποίηση υπενθύμισης για χρήση εφαρμογής

Ξεκινώντας, η υπηρεσία δημιουργεί την ειδοποίηση που ενημερώνει τον χρήστη πως η εφαρμογή εκτελείται στο παρασκήνιο. Στη συνέχεια, εγγράφεται στον BroadcastReceiver⁴ για να ενημερώνεται αυτόματα για οποιαδήποτε μεταβολή στα χαρακτηριστικά της μπαταρίας. Επιπρόσθετα, ρυθμίζει τον χρονιστή (timer) να λαμβάνει δεδομένα ανά τακτά χρονικά διαστήματα, τα οποία ορίστηκαν από τον χρήστη. Τέλος, ενημερώνει το γραφικό περιβάλλον της εφαρμογής με τα πιο πρόσφατα ληφθέντα δεδομένα. Αυτό είναι δυνατό, με τη χρήση ενός BroadcastReceiver που ειδοποιεί τη δραστηριότητα για την επικαιροποίηση των πληροφοριών. Προτιμήθηκε αυτή η αρχιτεκτονική, καθώς οι ειδοποιήσεις είναι ασύγχρονες και θα ληφθούν από τη δραστηριότητα μόνο αν αυτή βρίσκεται στο προσκήνιο.



Εικόνα 16: Ειδοποίηση εκτέλεσης εφαρμογής στο παρασκήνιο

⁴ Ένας BroadcastReceiver είναι ένα στοιχείο του Android που επιτρέπει την εγγραφή για συμβάντα του συστήματος. Όλοι οι εγγεγραμμένοι δέκτες για ένα συμβάν ειδοποιούνται αυτόματα από το Android.

4.1.2 Συλλογή δεδομένων

Τα δεδομένα που συλλέγονται κατά την εκτέλεση της εφαρμογής προέρχονται από διάφορες πηγές. Αρχικά, για αυτά που αφορούν την μπαταρία χρησιμοποιείται η διεπαφή BatteryManager⁵, που παρέχει όλες τις απαιτούμενες πληροφορίες για αυτήν. Πιο συγκεκριμένα, καταγράφονται τα εξής πεδία:

- **level:** Το επίπεδο της.
- **temperature:** Η θερμοκρασία της σε βαθμούς Κελσίου (°C).
- **voltage:** Η τάση της σε Volt (V).
- **technology:** Η τεχνολογία της.
- **status:** Η κατάσταση της. Πρόκειται για κατηγορική μεταβλητή με τις εξής δυνατές τιμές: 1 Unknown, 2 Charging, 3 Discharging, 4 Not Charging, 5 Full.
- **health:** Η υγεία της. Πρόκειται για κατηγορική μεταβλητή με τις εξής δυνατές τιμές: 1 Unknown, 2 Good, 3 Overheat, 4 Dead, 5 Over Voltage, 6 Unspecified Failure, 7 Cold.
- **availCapacity:** Το % ποσοστό της χωρητικότητας που της απομένει.

Για τα δεδομένα που αφορούν τη συνδεσιμότητα και την αλληλεπίδραση του χρήστη με τη συσκευή, χρησιμοποιούνται οι διεπαφές ConnectivityManager⁶, BluetoothAdapter⁷, PowerManager⁸ και LocationManager⁹. Μέσω αυτών ορίζονται οι ακόλουθες δυαδικές μεταβλητές, όπου τιμή True δηλώνει ενεργοποίηση:

- **WiFi:** Σύνδεση στο ίντερνετ μέσω WiFi.
- **Cellular:** Σύνδεση στο ίντερνετ μέσω δεδομένων κινητής τηλεφωνίας.
- **Bluetooth:** Ενεργοποίηση Bluetooth.
- **GPS:** Ενεργοποίηση GPS.
- **isInteractive:** Αλληλεπίδραση με τη συσκευή.

Τέλος, υπάρχουν δεδομένα η καταγραφή των οποίων γίνεται είτε μέσω ανάγνωσης αρχείων που είναι αποθηκευμένα στον πυρήνα του Android είτε μέσω μεταβλητών συστήματος. Πιο συγκεκριμένα:

- **usage:** Η χρήση του επεξεργαστή. Στις νεότερες εκδόσεις του Android και για λόγους ασφάλειας¹⁰ η ανάγνωση της πραγματικής χρήσης απαγορεύτηκε. Έτσι, η χρήση του επεξεργαστή εκτιμάται, με τον εξής τύπο:

$$\text{coreUsage}[i] = \frac{\text{currFreq}[i] - \text{minFreq}[i]}{\text{maxFreq}[i] - \text{minFreq}[i]}, \quad i = 1, \dots, \text{cores}, \quad (4.1)$$

όπου cores, ο αριθμός των πυρήνων του επεξεργαστή και coreUsage, το ποσοστό χρήσης του εκάστοτε πυρήνα, όπου υπολογίζεται μέσω της τρέχουσας συχνότητας λειτουργίας του

$$\text{usage} = \frac{\sum_{i=1}^{\text{cores}} \text{coreUsage}[i]}{\text{cores}}. \quad (4.2)$$

⁵ <https://developer.android.com/reference/android/os/BatteryManager>

⁶ <https://developer.android.com/reference/android/net/ConnectivityManager>

⁷ <https://developer.android.com/reference/android/bluetooth/BluetoothAdapter>


⁸ <https://developer.android.com/reference/android/os/PowerManager>

⁹ <https://developer.android.com/reference/android/location/LocationManager>

¹⁰ <https://issuetracker.google.com/issues/37140047>

4.2 Ανάλυση δεδομένων

- Hotspot: Δυαδική μεταβλητή για μετατροπή της συσκευής σε σημείο πρόσβασης WiFi, όπου η τιμή True δηλώνει ενεργοποίηση.
- RAM: Το % ποσοστό της διαθέσιμης μνήμης RAM.
- Brightness: Η φωτεινότητα της οθόνης.
- brandModel: Η μάρκα και το μοντέλο της συσκευής.
- androidVersion: Η έκδοση του Android.
- Timestamp: Ο χρόνος λήψης του δείγματος (Unix Timestamp).



Εικόνα 17: Επικοινωνία των διαφόρων υποσυστημάτων της εφαρμογής

Αποθήκευση δεδομένων

Η αποθήκευση των αρχείων, γίνεται σε μια NoSQL βάση δεδομένων (MongoDB), λόγω της μορφής τους (JSON). Σε πρώτο στάδιο, για τη φιλοξενία (hosting) της βάσης αξιοποιήθηκε ένα Raspberry Pi Zero, όπου το hostname hostmpalaourgthesis.ddns.net, ανακατεύθυνε όλα τα αιτήματα στον δρομολογητή (router) και από εκεί στο Raspberry, εντός του οικιακού δικτύου. Στη συνέχεια, για μια πιο εύρωστη λύση η βάση μεταφέρθηκε σε μια εικονική μηχανή (virtual machine), που φιλοξενείται στο δίκτυο του okeanos.grnet.gr. Τέλος, για την ύπαρξη αντιγράφου ασφαλείας και τη δημιουργία στατιστικών, τα αρχεία αποθηκεύονται και στο cenote¹¹, ένα σύστημα διαχείρισης μεγάλων δεδομένων (Big Data Management-BDMS).

4.2 Ανάλυση δεδομένων

Στην Ενότητα αυτή, θα περιγραφεί η μεθοδολογία για την ανάλυση των δεδομένων που συλλέχθηκαν για την εκτίμηση της κατανάλωσης ενέργειας των κινητών τηλεφώνων. Σε πρώτο στάδιο, θα παρουσιαστεί η επεξεργασία των αρχείων πριν την αξιοποίηση τους (4.2.1) και η δημιουργία παραθύρων χρήστης για ομαλοποίηση των μετρήσεων (4.2.2). Στην Υποενότητα 4.2.3 ορίζεται η μεταβλητή εξόδου, energy drain, όπου διαφέρει από το επίπεδο φόρτισης, αλλά υπολογίζεται μέσω της μεταβολής αυτού. Τέλος, στις

¹¹ <https://cenote.sidero.services/>

4.2 Ανάλυση δεδομένων

Υποενότητες 4.2.4 και 4.2.5, θα επεξηγηθεί η διαδικασία για την ομαδοποίηση των παραθύρων χρήσης και για την εκτίμηση του energy drain, αντίστοιχα.

4.2.1 Προεπεξεργασία αρχείων

Ένα αρχείο, όπως αναφέρθηκε προηγουμένως, είναι ένα Session λειτουργίας της εφαρμογής. Αρχικά, πριν αυτό αξιοποιηθεί, πρέπει να ελεγχθεί αν η δομή του είναι σωστή. Οι έλεγχοι που πραγματοποιούνται αφορούν τη δειγματοληψία, δηλαδή αν τα δείγματα ισταπέχουν και αν αυτήν η απόσταση συμφωνεί με την περίοδο δειγματοληψίας που ο χρήστης έχει ορίσει. Επιπλέον, γίνεται έλεγχος για διπλότυπες εγγραφές εντός του ίδιου αρχείου και για το αν υπάρχουν μηδενικές ή αρνητικές τιμές σε πεδία που δε δικαιολογούνται, όπως η χρήση του επεξεργαστή, του επιπέδου της μπαταρίας και τη θερμοκρασία της. Έπειτα, χωρίζονται σε Sessions εκφόρτισης, φόρτισης και μικτού τύπου, σε περίπτωση φόρτισης και εκφόρτισης εντός του ίδιου Session. Τα τελευταία διαχωρίζονται στα επιμέρους αρχεία φόρτισης και εκφόρτισης που τα απαρτίζουν.

Στη συνέχεια, ακολούθησε η κανονικοποίηση των αρχείων, έτσι ώστε το κάθε χαρακτηριστικό να ορίζεται στο εύρος [0,1]. Αξίζει να σημειωθεί, πως η κάθε συσκευή έχει τα δικά της όρια λειτουργίας και η κανονικοποίηση έγινε ως προς το σύνολο των αρχείων της και όχι μόνο εντός του ίδιου Session. Οι τύποι για την κανονικοποίηση είναι οι εξής, με τις τυπικές τιμές να ορίζονται στο [36]:

$$\text{maxBrightness} = \max\{255, \text{brightness}\}, \quad (4.3)$$

$$\text{maxVoltage} = \max\{4.2, \text{voltage}\}, \quad \text{minVoltage} = \min\{3.4, \text{voltage}\}, \quad (4.4)$$

$$\text{maxTemp} = \max\{45, \text{temperature}\}, \quad \text{minTemp} = \min\{25, \text{temperature}\}, \quad (4.5)$$

$$\text{normalizedValue} = \frac{\text{value} - \text{min}}{\text{max} - \text{min}}. \quad (4.6)$$

Η παραπάνω εξίσωση χρησιμοποιείται για κάθε χαρακτηριστικό, ενώ για εκείνα που δεν υπολογίζεται η ελάχιστη και η μέγιστη τιμή, ορίζονται ως 0 και 100, αντίστοιχα.

4.2.2 Ορισμός παραθύρων χρήσης

Τα Sessions λειτουργίας, περιλαμβάνουν μετρήσεις αισθητήρων ανά τακτά χρονικά διαστήματα. Οι μετρήσεις αυτές για μέρος των χαρακτηριστικών περιείχαν μεγάλες διακυμάνσεις, ενώ για άλλα παρέμεναν σταθερές για αρκετά συνεχόμενα δείγματα. Πιο συγκεκριμένα, η χρήση του επεξεργαστή και η διαθέσιμη μνήμη RAM, εμφάνιζαν μεγάλη διακύμανση και τοπικά ακραίες τιμές, ενώ το επίπεδο και η τάση της μπαταρίας παρέμεναν σταθερά. Επιπλέον, υπήρχαν αρχεία με διαφορετικές περιόδους δειγματοληψίας, με αποτέλεσμα να μην μπορούν να συγκριθούν απευθείας. Έτσι, για την ομαλοποίηση των δεδομένων, αλλά και την αντιμετώπιση των υπόλοιπων προβλημάτων, δημιουργήθηκαν παράθυρα χρήσης, όπου για τα

- **Αριθμητικά χαρακτηριστικά**, λαμβάνεται ο μέσος όρος των τιμών εντός του παραθύρου.
- **Κατηγορικά χαρακτηριστικά**, ορίζεται ως τιμή, η τιμή της πλειοψηφίας των δεδομένων (majority vote) εντός του παραθύρου.

Επιλογή βέλτιστης χρονικής διάρκειας

Η επιλογή της βέλτιστης χρονικής διάρκειας έγινε βάσει της ομαλότητας των καμπυλών που εξασφαλίζει για τα αριθμητικά χαρακτηριστικά. Η σύγκριση της ομαλότητας, μπορεί να επιτευχθεί μέσω της ελαχιστοποίησης του roughness penalty, όπου υπολογίζεται ως

$$\text{roughness penalty} = \int [\text{f}''(\text{x})]^2 \text{dx}, \quad (4.7)$$


4.2 Ανάλυση δεδομένων

για μια διαφορίσιμη συνάρτηση f. Για διακριτές τιμές ο τύπος έχει τη μορφή

$$\text{roughness penalty} = \frac{\sum_i [x_i - 2x_{i-1} + x_{i-2}]^2}{4} = \frac{\sum_i [(x_i - x_{i-1}) - (x_{i-1} - x_{i-2})]^2}{4}, \quad (4.8)$$

όπου x το υπό εξέταση διακριτό σήμα και υπολογίζεται η διαφορά 2^{ης} τάξης.

Αυξάνοντας το μέγεθος του παραθύρου, ο παραπάνω συντελεστής θα μειώνεται και θα επιτυγχάνονται πιο ομαλές καμπύλες, με αντάλλαγμα να χαθεί χρήσιμη πληροφορία από τις μετρήσεις. Σ' αυτό το σημείο πρέπει να αναφερθεί, πως ο συντελεστής υπολογίζεται για κάθε αρχείο χωριστά. Στην παρακάτω εικόνα, παρουσιάζεται η μέση τιμή του roughness penalty, της χρήσης του επεξεργαστή και της διαθέσιμης μνήμης RAM, για διαφορετικά μεγέθη παραθύρων.



Εικόνα 18: Μέση τιμή roughness penalty για διαφορετικά μεγέθη παραθύρων

Η εικόνα επιβεβαιώνει πως λαμβάνονται πιο ομαλές καμπύλες. Έτσι, για την επιλογή του βέλτιστου μήκους παραθύρου ελέγχθηκαν οπτικά οι γραφικές παραστάσεις που υπολογίστηκαν για διάφορους χρήστες και παρατηρήθηκε πως για μήκη μεγαλύτερα των 60 δευτερολέπτων, εξαλειφόταν η τάση (trend) των καμπυλών. Επιπλέον, μεγάλα μήκη παραθύρων επηρέαζαν σημαντικά και τις τιμές των κατηγορικών δεδομένων για τον καθορισμό της πλειοψηφίας. Έτσι, για ισορροπία μεταξύ της ακρίβειας των τιμών και της ομαλότητας των καμπυλών, επιλέχθηκε ως βέλτιστο μήκος παραθύρου τα 50 δευτερόλεπτα.

4.2.3 Υπολογισμός μεταβλητής εξόδου (energy drain)

Η κατανάλωση ενέργειας (energy drain) της εκάστοτε χρήσης, δεν ανήκει στα δεδομένα που δειγματοληπτούνται ανά τακτά χρονικά διαστήματα. Έτσι, για τον υπολογισμό της ακολουθούνται τα εξής βήματα:


- Ανάγνωση αρχείου, δηλαδή ενός Session εκφόρτισης.
- Εύρεση των –μοναδικών- επιπέδων φόρτισης της μπαταρίας, l_i , $i = 0, \dots, n$, και της θέσης της πρώτης εμφάνισης τους, εντός του αρχείου, idx_i , $i = 0, \dots, n$.
- Υπολογισμός της μεταβολής του επιπέδου φόρτισης που σημειώθηκε μεταξύ διαδοχικών θέσεων idx , $\Delta l_i = l_i - l_{i+1}$, $i = 0, \dots, n - 1$ (συνήθως 1 ή 2 %).

4.2 Ανάλυση δεδομένων

- Υπολογισμός της διαφοράς δύο διαδοχικών θέσεων πτώσης του επιπέδου φόρτισης, $\Delta \text{idx}_i = \text{idx}_{i+1} - \text{idx}_i$, $i = 0, \dots, n - 1$, δηλαδή τον αριθμό των παραθύρων με ίδιο επίπεδο μπαταρίας. Τελικά,

$$\text{energy drain}_i = \frac{\Delta l_i}{\Delta \text{idx}_i} \left[\frac{\% \text{ μεταβολή}}{\text{παράθυρο χρήσης}} \right], \quad i = 0, \dots, n - 1 \quad (4.9)$$

Σε αυτό το σημείο να σημειωθεί πως έχει γίνει η υπόθεση ότι κάθε παράθυρο χρήσης έχει την ίδια συνεισφορά στην εκάστοτε μεταβολή Δl_i . Τέλος, παρουσιάζεται η συσχέτιση των χαρακτηριστικών εισόδου με την έξοδο




Εικόνα 19: Heatmap συσχέτισης χαρακτηριστικών εισόδου και εξόδου

4.2.4 Ομαδοποίηση παραθύρων χρήσης

Η δημιουργία ενός μοντέλου για κάθε πιθανή χρήση του κινητού τηλεφώνου αποτελεί ένα δύσκολο εγχείρημα, αν όχι αδύνατο. Έτσι, μετά τον ορισμό των παραθύρων και τον υπολογισμό της εξόδου, τα αρχεία του εκάστοτε πειράματος θα ενωθούν σε ένα και θα ακολουθήσει η ομαδοποίηση των παραθύρων βάσει χαρακτηριστικών που δείχνουν τη χρήση της συσκευής. Πιο συγκεκριμένα, εφαρμόζεται η ιεραρχική ομαδοποίηση, η οποία δεν επιβάλει την εξ' αρχής (apriori) επιλογή συγκεκριμένου αριθμού ομάδων και δεν εισάγει περιορισμούς στη συνάρτηση απόστασης που θα επιλεχθεί (σε αντίθεση για παράδειγμα με τον αλγόριθμο k-means, που χρησιμοποιεί την Ευκλείδεια απόσταση). Επιπλέον, για τη χρήση λιγότερων χαρακτηριστικών στην ομαδοποίηση, οπότε και λιγότερων διαστάσεων, υπολογίζεται η συσχέτιση μεταξύ των στηλών, έτσι ώστε υψηλά συσχετιζόμενα χαρακτηριστικά να αποκλειστούν.

4.2 Ανάλυση δεδομένων




Εικόνα 20: Heatmap συσχέτισης αρχικών χαρακτηριστικών χρήσης κινητού

Στην παραπάνω εικόνα, φαίνεται πως τα χαρακτηριστικά Cellular και WiFi, έχουν υψηλή αρνητική συσχέτιση. Κάτι τέτοιο είναι λογικό, καθώς τα κινητά είναι έτσι ρυθμισμένα που επιτρέπουν τη σύνδεση στο διαδίκτυο είτε μέσω WiFi είτε δεδομένων κινητής τηλεφωνίας. Έτσι, τα δύο αυτά χαρακτηριστικά «ενώνονται» με τη χρήση του τελεστή OR, για τη δημιουργία ενός νέου, το Connectivity. Επιπλέον, υψηλή θετική συσχέτιση εμφανίζουν τα Brightness και isInteractive. Ομοίως με πριν οφείλεται στις ρυθμίσεις του κινητού, όπου για isInteractive=False, η φωτεινότητα είναι 0. Έτσι, παραμένει μόνο το Brightness, καθώς περιέχει την πληροφορία και των δύο. Κλείνοντας, παρουσιάζονται τα -τελικά- χαρακτηριστικά χρήσης του κινητού και η συσχέτιση τους.

Πίνακας 6: Τελικά χαρακτηριστικά χρήσης κινητού

Χαρακτηριστικά	Τύπος	Εύρος
usage, RAM, Brightness	Αριθμητικά	[0,1]
GPS, Bluetooth, Connectivity	Δυαδικά	[False, True]



Εικόνα 21: Heatmap συσχέτισης τελικών χαρακτηριστικών χρήσης κινητού

4.2.5 Παλινδρόμηση για εκτίμηση μεταβλητής εξόδου

Το αποτέλεσμα της ομαδοποίησης, θα είναι η ανάθεση του κάθε παραθύρου σε μια ομάδα, η οποία θα περιγράφει διαφορετικές χρήσεις. Για κάθε μια από αυτές, θα υλοποιηθούν μοντέλα παλινδρόμησης με σκοπό την εκτίμηση του energy drain. Πιο συγκεκριμένα, θα χρησιμοποιηθεί ένα απλό γραμμικό μοντέλο (linear), δύο παραλλαγές του που εισάγουν την έννοια της ποινής για την εύρεση των πιο σημαντικών χαρακτηριστικών (ridge, lasso) και ένα μη γραμμικό (xgboost). Αξίζει να σημειωθεί πως τα δεδομένα θα διαχωριστούν σε 75% δεδομένα εκπαίδευσης (training set) και 25% δεδομένα ελέγχου (test set) για την αξιολόγηση των μεθόδων.

Πίνακας 7: Χαρακτηριστικά περιγραφής μπαταρίας

Χαρακτηριστικά	Τύπος	Εύρος
level, temperature, voltage	Αριθμητικά	[0,1]
status	Κατηγορικό	[1, 2, 3, 4, 5]
health	Κατηγορικό	[1, 2, 3, 4, 5, 6, 7]

Δημιουργία χαρακτηριστικών

Το κατηγορικό χαρακτηριστικό status δε θα χρησιμοποιηθεί στην εκτίμηση του energy drain, καθώς λαμβάνονται υπόψιν μόνο Sessions εκφόρτισης (status=3). Ομοίως δεν θα αξιοποιηθεί το health, καθώς για κάθε παράθυρο χρήσης είχε την τιμή GOOD (health=2). Πιο συγκεκριμένα, στην πρώτη προσπάθεια εκτίμησης, χρησιμοποιήθηκαν

4.2 Ανάλυση δεδομένων

τα εναπομείναντα χαρακτηριστικά που περιείχαν πληροφορία για την μπαταρία, σε συνδυασμό με αυτά της χρήσης του κινητού, χωρίς ωστόσο να επιτευχθεί κάποιο αξιοσημείωτο αποτέλεσμα. Έτσι, για την καλύτερη εκμετάλλευση τους, θα υπολογιστούν οι πολυωνυμικοί συνδυασμοί, βαθμού 2, των αριθμητικών μεταβλητών, όπου για ένα διάνυσμα εισόδου $[1 \times 3]$, η έξοδος θα είναι το διάνυσμα

$$\text{PolynomialTransform}([a, b, c], 2) = [a, b, c, a^2, b^2, c^2, ab, ac, bc] \quad (4.10)$$

Πίνακας 8: Τελικά χαρακτηριστικά παλινδρόμησης

Χαρακτηριστικά	Τύπος	Εύρος
PolynomialTransform([level, temperature, usage, Brightness, RAM], 2)	Αριθμητικά	[0,1]
GPS, Bluetooth, Connectivity	Δυαδικά	[False, True]

Διασταυρωμένη επικύρωση (Cross validation)

Οι προαναφερθείσες μέθοδοι (εκτός του γραμμικού μοντέλου), περιλαμβάνουν παραμέτρους που επηρεάζουν και ρυθμίζουν την απόδοση τους. Έτσι, για την εύρεση του βέλτιστου συνδυασμού αυτών, θα χρησιμοποιηθεί η διασταυρωμένη επικύρωση. Τα δεδομένα, εκπαίδευσης θα χωριστούν σε k υποσύνολα (folds), όπου σε κάθε επανάληψη τα $k - 1$ εξ αυτών θα χρησιμοποιούνται για εκπαίδευση (training set) και το τελευταίο για επικύρωση των αποτελεσμάτων (validation set). Τέλος, ως μετρικές αξιολόγησης θα χρησιμοποιηθούν το MAE και το RMSE.

Πίνακας 9: Παράμετρος μεθόδου Ridge και Lasso

Ridge / Lasso regression	
alpha	Το βάρος των περιορισμών που εισάγονται στους συντελεστές της παλινδρόμησης. Ισχύει πάντα $\alpha \geq 0$, όπου για $\alpha = 0$ η μέθοδος ταυτίζεται με τη γραμμική παλινδρόμηση (linear model).

Πίνακας 10: Παράμετροι μεθόδου xgboost

xgboost regression	
n_estimators	Ο αριθμός των δέντρων που θα χρησιμοποιηθούν. Η σημαντικότερη παράμετρος σ' αυτή τη μέθοδο, καθώς λίγα δέντρα δεν μπορούν να «εξηγήσουν» τα δεδομένα, ενώ πολλά οδηγούν σε υπερεκπαίδευση (overfitting). Τέλος, εξαρτάται και από τον αριθμό των δεδομένων.
learning rate	Το βάρος της διόρθωσης που εισάγουν τα νέα δέντρα, όταν προστίθενται στο μοντέλο. Ουσιαστικά, ρυθμίζει πόσο γρήγορα «βελτιώνεται» το μοντέλο από τα δεδομένα εκπαίδευσης, για αποφυγή της υπερεκπαίδευσης.
max_depth	Το βάθος κάθε δέντρου, δηλαδή η μέγιστη απόσταση από την ρίζα του έως ένα φύλλο. Αύξηση αυτής της τιμής, οδηγεί σε πιο περίπλοκα και ευπαθή σε υπερεκπαίδευση, μοντέλα.
colsample_bytree	Το κλάσμα των χαρακτηριστικών, που θα δειγματοληπτηθούν τυχαία για την κατασκευή του κάθε δέντρου. Ουσιαστικά, ρυθμίζει τον ρόλο που έχει το κάθε χαρακτηριστικό στην τελική εκτίμηση και χρησιμοποιείται για αποφυγή της υπερεκπαίδευσης.

4.2 Ανάλυση δεδομένων


reg_lambda	Το βάρος των περιορισμών που εισάγονται στους συντελεστές της παλινδρόμησης (στα φύλλα των δέντρων). Η αύξηση αυτής της τιμής θα κάνει το μοντέλο πιο συντηρητικό και θα βοηθήσει στην αποφυγή της υπερεκπαίδευσης. (ανάλογο με το Ridge μοντέλο)
------------	---

5 Πειράματα & Αποτελέσματα

Το Κεφάλαιο αυτό παρουσιάζει τα πειράματα που εκτελέστηκαν και τα αποτελέσματα τους. Αναλυτικότερα, συνοψίζονται τα στατιστικά των δεδομένων που συλλέχθηκαν (Ενότητα 5.1). Αναπτύσσονται οι αναλύσεις για έναν μεμονωμένο χρήστη (Ενότητα 5.2) και για πολλαπλούς, αφενός με διαφορετική (Ενότητα 5.3) και αφετέρου με ίδια χωρητικότητα μπαταρίας (Ενότητα 5.4).


5.1 Στατιστικά αρχείων

Η συλλογή δεδομένων διήρκησε περίπου δύο μήνες, με τον συνολικό αριθμό αρχείων που συλλέχθηκαν να είναι 906. Τα αρχεία αυτά αποτελούνται, από Sessions εκφόρτισης, φόρτισης και μικτού τύπου. Έτσι, παρακάτω παρουσιάζονται αναλυτικά οι εμφανίσεις του εκάστοτε τύπου Session, αφού πρώτα τα Sessions μικτού τύπου διαχωριστούν στα επιμέρους φόρτισης και εκφόρτισης.



Εικόνα 22: Τύποι αρχείων


Επιπλέον, υπήρχαν 23 μοναδικοί χρήστες. Στη συνέχεια, παρατίθεται το ιστόγραμμα μεταφορτωμένων αρχείων, με το μέγεθος κάδων (bins) να ισούται με 20 αρχεία.




Εικόνα 23: Ιστόγραμμα μεταφορτωμένων αρχείων

5.1 Στατιστικά αρχείων

Σ' αυτό το σημείο, αξίζει να σημειωθεί πως παρατηρήθηκαν αρκετές διαφορετικές χρήσεις, είτε ως προς τη διάρκεια τους είτε ως προς τη μεταβολή του επιπέδου της μπαταρίας που καταγράφηκε. Για αυτό το λόγο, παρουσιάζεται το ιστόγραμμα της πτώσης του επιπέδου της μπαταρίας, με το μέγεθος των bins να ισούται με 5% πτώση, και η αθροιστική συνάρτηση κατανομής, όπου φαίνεται πως περίπου 80% των αρχείων περιγράφουν πτώση μπαταρίας έως 10%.




Εικόνα 24: Ιστόγραμμα πτώσης επιπέδου μπαταρίας




Εικόνα 25: Αθροιστική συνάρτηση κατανομής πτώσης επιπέδου μπαταρίας

Τέλος, ομοίως με πριν αναδεικνύονται οι γραφικές παραστάσεις της χρονικής διάρκειας των Sessions, πρώτα το ιστόγραμμα με το μέγεθος των bins να ισούται με 30 λεπτά και στη συνέχεια η αθροιστική συνάρτηση κατανομής, όπου διαπιστώνεται πως 80% των αρχείων έχουν διάρκεια έως 60 λεπτά.

5.2 Πείραμα 1: Μεμονωμένος χρήστης



Εικόνα 26: Ιστόγραμμα χρονικής διάρκειας Session



Εικόνα 27: Αθροιστική συνάρτηση κατανομής χρονικής διάρκειας Session

5.2 Πείραμα 1: Μεμονωμένος χρήστης

Το πρώτο πείραμα της παρούσας διπλωματικής, είναι η εκτίμηση του energy drain, για έναν μεμονωμένο χρήστη, βάσει όλων των Sessions λειτουργίας που έχει παράγει. Η μεθοδολογία για την ανάλυση των αρχείων αυτών, περιγράφηκε στο Κεφάλαιο 4.2, συνοπτικά περιλαμβάνει τον ορισμό παραθύρων χρήσης των 50 δευτερολέπτων, με σκοπό την ομαλοποίηση των δεδομένων, την ομαδοποίηση των παραθύρων αυτών σε ομάδες (clusters) βάσει της χρήσης της συσκευής και τέλος, την εκπαίδευση μοντέλων παλινδρόμησης για την εκτίμηση του energy drain για κάθε ομάδα.


Ομαδοποίηση

Για την ομαδοποίηση των δεδομένων, χρησιμοποιήθηκε η iεραρχική ομαδοποίηση, με την απόσταση να υπολογίζεται μέσω της συνάρτησης απόστασης του Gower, λόγω της ταυτόχρονης ύπαρξης αριθμητικών και δυαδικών χαρακτηριστικών στα δεδομένα.


5.2 Πείραμα 1: Μεμονωμένος χρήστης

Επιπλέον, για τη σύγκριση μεταξύ διαφορετικών ιεραρχικών ομαδοποιήσεων χρησιμοποιήθηκε ο συντελεστής συσχέτισης Cophenetic (CPCC), με τιμή κοντά στο 1 να δηλώνει υψηλό βαθμό γραμμικής συσχέτισης των Cophenetic αποστάσεων του δέντρου και των πραγματικών αποστάσεων των δεδομένων και άρα πιο έγκυρες ομάδες. Τέλος, για την επιλογή του αριθμού των ομάδων χρησιμοποιήθηκε η μέση τιμή του συντελεστή Silhouette, όπου για κάθε ομάδα υπολογίζει πόσο όμοιο είναι ένα αντικείμενο με τα υπόλοιπα αντικείμενα που ανήκουν στην ίδια ομάδα, με τιμές κοντά στο 1 να δηλώνουν καλύτερη ομαδοποίηση.

Αρχικά, παρουσιάζονται τα δενδρογράμματα για τις τρεις περιπτώσεις της ιεραρχικής ομαδοποίησης, Single, Complete και Average, με CPCC 0.80, 0.85 και 0.87, αντίστοιχα.




Εικόνα 28: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=single [Πείραμα 1]




Εικόνα 29: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=complete [Πείραμα 1]

5.2 Πείραμα 1: Μεμονωμένος χρήστης




Εικόνα 30: Δενδρόγραμμα Ιεραρχικής ομαδοποίησης linkage=average [Πείραμα 1]

Στη συνέχεια, για τις δύο καλύτερες ομαδοποιήσεις βάσει του CPCC, Complete και Average, γίνεται έλεγχος για την εύρεση του βέλτιστου αριθμού ομάδων.



Εικόνα 31: Mean Silhouette ανά αριθμό ομάδων linkage=complete [Πείραμα 1]



Εικόνα 32: Mean Silhouette ανά αριθμό ομάδων linkage=average [Πείραμα 1]

5.2 Πείραμα 1: Μεμονωμένος χρήστης

Στην περίπτωση του Complete, δημιουργήθηκαν 5 ομάδες, με μέσο Silhouette 0.63, ενώ στην περίπτωση του Average, σχηματίστηκαν 4 ομάδες με μέσο Silhouette 0.62. Επιπλέον, για την περαιτέρω αξιολόγηση των ομάδων και την επιλογή της καλύτερης ομαδοποίησης, ελέγχονται τα επιμέρους χαρακτηριστικά της εκάστοτε ομάδας

Πίνακας 11: Αξιολόγηση ομαδοποίησης [Πείραμα 1]


		Αριθμός ομάδας				
		0	1	2	3	4
Complete	Bluetooth	80	0	0	450	74
	GPS	0	4628	3	450	74
	Connectivity	3441	4628	0	450	0
	Σύνολο	3441	4628	19	450	74
Average	Bluetooth	80	74	450	0	—
	GPS	0	77	450	4628	—
	Connectivity	3441	0	450	4628	—
	Σύνολο	3457	77	450	4628	—

Ο παραπάνω πίνακας, παρουσιάζει τον αριθμό των παραθύρων που έχουν ενεργοποιημένο το Bluetooth, το GPS ή/και το Connectivity, ανά ομάδα για κάθε μια από τις δύο προηγούμενες περιπτώσεις. Είναι φανερό, πως και στις δύο περιπτώσεις η ομαδοποίηση κατάφερε να σχηματίσει ομάδες που έχουν κοινά χαρακτηριστικά και περιγράφουν παρόμοιες χρήσεις. Στην περίπτωση του Complete, οι ομάδες είναι -οριακά- καλύτερες, όπου για παράδειγμα η ομάδα 0, περιέχει όλα τα παράθυρα χρήσεων που είχαν ενεργοποιημένα ταυτόχρονα το Bluetooth και το Connectivity και η ομάδα 1, εκείνα με το GPS και το Connectivity.

Οι ομάδες αυτές στη συνέχεια, θα χρησιμοποιηθούν ως ετικέτες για την εκπαίδευση μοντέλων παλινδρόμησης, με τις ομάδες 2 και 4 να περιέχουν λίγα στοιχεία για να μπορέσει να εξαχθεί κάποιο συμπέρασμα. Παράλληλα, παρακάτω επιδεικνύονται τα θηκογράμματα (boxplots) για τη χρήση του επεξεργαστή, τη διαθέσιμη μνήμη RAM και τη φωτεινότητα της συσκευής, για τις ομάδες 0, 1 και 3. Οι διαφορές που εντοπίζονται αφορούν κυρίως τη φωτεινότητα της συσκευής, για τις ομάδες 0, 1 και 3. Οι διαφορές που εντοπίζονται αφορούν κυρίως τη φωτεινότητα της συσκευής. Πιο συγκεκριμένα, η ομάδα 0, αφορά μέση χρήση, η ομάδα 1 μέση προς υψηλή και η ομάδα 3, περιγράφει μια γενικότερη οικογένεια χρήσεων. Έτσι, για τη συνέχεια της ανάλυσης θα επιλεχθούν μόνο τα δεδομένα των ομάδων 0 και 1, που παρουσιάζουν και την περισσότερη πληροφορία.


5.2 Πείραμα 1: Μεμονωμένος χρήστης

Phone usage boxplots ~ cluster 0




Εικόνα 33: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 0]
[Πείραμα 1]

Phone usage boxplots ~ cluster 1



Εικόνα 34: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 1]
[Πείραμα 1]


Phone usage boxplots ~ cluster 3




Εικόνα 35: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 3]
[Πείραμα 1]

5.2 Πείραμα 1: Μεμονωμένος χρήστης

Επιπλέον, μέσω του αλγορίθμου MDS, οι δύο ομάδες απεικονίζονται στον δισδιάστατο και τρισδιάστατο χώρο, εμφανώς διαχωρισμένες.



Εικόνα 36: Απεικόνιση ομάδων στον δισδιάστατο χώρο [Πείραμα 1]



Εικόνα 37: Απεικόνιση ομάδων στον τρισδιάστατο χώρο [Πείραμα 1]

Παλινδρόμηση

Για την εκτίμηση του energy drain για τα επιμέρους μοντέλα, θα χρησιμοποιηθούν ένα απλό γραμμικό μοντέλο, δύο παραλλαγές της γραμμικής παλινδρόμησης, όπου εισάγεται η έννοια της ποινής (Ridge και Lasso Regression), και ένα μη γραμμικό μοντέλο, που ανήκει στην κατηγορία του Ensemble Learning (eXtreme Gradient Boosted trees, xgboost). Πιο συγκεκριμένα, για κάθε αλγόριθμο χρησιμοποιήθηκε η διασταυρωμένη επικύρωση για 3 υποσύνολα (3-fold Cross validation), στο σετ δεδομένων εκπαίδευσης, έτσι ώστε να βρεθούν οι βέλτιστοι παράμετροι για το κάθε μοντέλο.

Αναλυτικότερα, για τις μεθόδους Ridge και Lasso, η παράμετρος alpha ελέγχθηκε στις εξής τιμές, $\text{alpha} = [0.001, 0.01, 0.1, 1, 10, 100, 1000]$. Επιπλέον, για τη μέθοδο xgboost, αρχικά έγινε διερεύνηση ως προς τις τιμές των δύο σημαντικότερων παραμέτρων της, $n_estimators$ και learning rate,

$$\begin{cases} n_estimators = [100, 200, 300, \dots, 1900, 2000] \\ \text{learning rate} = [0.1, 0.2, 0.3, 0.4] \end{cases} \quad (5.1)$$

5.2 Πείραμα 1: Μεμονωμένος χρήστης

Η αύξηση των δέντρων μετά τα 1000, οδήγησε σε ελάχιστη βελτίωση του MAE, ενώ αύξανε την πολυπλοκότητα και το κόστος της μεθόδου. Στους ρυθμούς εκμάθησης, καλύτερο αποτέλεσμα έδωσε το 0.1, όπου όμως ήταν και η μικρότερη δυνατή τιμή του διανύσματος που ελέγχθηκε. Έτσι, στη συνέχεια, για αριθμό δέντρων ίσο με 1000, έγινε περαιτέρω διερεύνηση για τις υπόλοιπες παραμέτρους του αλγορίθμου,

$$\begin{cases} \text{learning rate} = [0.02, 0.03, 0.04, \dots, 0.1] \\ \text{max depths} = [4, 5, 6, \dots, 11] \\ \text{colsample_bytree} = [0.40, 0.45, \dots, 0.65] \\ \text{reg_lambda} = [0.3, 0.4, \dots, 0.8] \end{cases} \quad (5.2)$$

Στους παρακάτω πίνακες, παρουσιάζονται τα αποτελέσματα για τα δύο μοντέλα, για τις καλύτερες παραμέτρους κάθε μεθόδου.

Πίνακας 12: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_0] [Πείραμα 1]

	model_0 (3-fold Cross Validation)		
	Mean-MAE	Mean-RMSE	Parameters
linear	0.046	0.060	—
ridge	0.047	0.060	alpha = 0.001
lasso	0.048	0.062	alpha = 0.001
xgboost	0.028	0.044	n_estimators = 1000, learning rate = 0.05, max_depth = 6, colsample_bytree = 0.6, reg_lambda = 0.3

Πίνακας 13: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_1] [Πείραμα 1]

	model_1 (3-fold Cross Validation)		
	Mean-MAE	Mean-RMSE	Parameters
linear	0.045	0.057	—
ridge	0.045	0.057	alpha = 0.01
lasso	0.046	0.058	alpha = 0.001
xgboost	0.027	0.040	n_estimators = 1000, learning rate = 0.03, max_depth = 8, colsample_bytree = 0.5, reg_lambda = 0.4


Τα βέλτιστα alpha, που υπολογιστήκαν και για τα δύο μοντέλα, τόσο στη μέθοδο Lasso, όσο και στη μέθοδο Ridge, φανερώνουν πως εν γένει εκτελέστηκε ο αλγόριθμος των ελαχίστων τετραγώνων. Κάτι τέτοιο επιβεβαιώνεται και από το γεγονός πως τα αποτελέσματα αυτών των μεθόδων είναι ίδια με το γραμμικό μοντέλο χωρίς ποινή. Η μέθοδος xgboost καταφέρνει να επιτύχει 40% μικρότερο μέσο απόλυτο σφάλμα (MAE), σε σχέση με τις γραμμικές μεθόδους και για τα δύο μοντέλα. Επιπλέον, μειώνει την τυπική απόκλιση των σφαλμάτων (RMSE), που σημαίνει πως τα δεδομένα είναι πιο συγκεντρωμένα γύρω από την καμπύλη παλινδρόμησης. Τα παραπάνω αποτελέσματα, αφορούν τις μέσες τιμές για το σετ επικύρωσης (validation set) κάθε επανάληψης της διασταυρωμένης επικύρωσης. Στη συνέχεια του πειράματος θα χρησιμοποιηθεί μόνο η μέθοδος xgboost, καθώς παρέχει ανώτερα αποτελέσματα.

Επιλογή χαρακτηριστικών


Τα μοντέλα αυτήν τη στιγμή, προσπαθούν να εκτιμήσουν την τιμή του energy drain βασιζόμενα σε 26 χαρακτηριστικά, όπου μπορεί να μην είναι όλα χρήσιμα στην πρόβλεψη. Χρησιμοποιώντας τη διασταυρωμένη επικύρωση 3 υποσυνόλων, με σταθερές

5.2 Πείραμα 1: Μεμονωμένος χρήστης

τις παραμέτρους των μοντέλων, ελέγχεται η απόδοση των μοντέλων για διαφορετικά όρια σπουδαιότητας (importance) των χαρακτηριστικών, στα δεδομένα εκπαίδευσης.



Εικόνα 38: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 1]



Εικόνα 39: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 1]

Αυξάνοντας το όριο σπουδαιότητας σημαίνει πως χρησιμοποιούνται λιγότερα χαρακτηριστικά. Έτσι, είναι εμφανές από τις γραφικές παραστάσεις πως αφήνοντας εκτός ορισμένα χαρακτηριστικά επιτυγχάνονται καλύτερα αποτελέσματα (μικρότερο μέσο MAE). Πιο συγκεκριμένα, για όριο σπουδαιότητας το **0.043** και **0.037** για τα μοντέλα 0 και 1, δηλαδή 9 και 10 χαρακτηριστικά, επιτυγχάνονται τα αποτελέσματα


Πίνακας 14: Αποτελέσματα επιλογής χαρακτηριστικών [Πείραμα 1]

	Validation Set (3-fold)	
	Mean-MAE	Mean-RMSE
model_0	0.024	0.041
model_1	0.022	0.034


5.2 Πείραμα 1: Μεμονωμένος χρήστης

Πίνακας 15: Σπουδαιότερα χαρακτηριστικά μοντέλων [Πείραμα 1]

model_0	model_1
Brightness ²	Brightness ²
temperature * Brightness	usage * Brightness
usage * Brightness	Brightness
level	temperature * Brightness
Brightness	level * temperature
level ²	level ²
level * Brightness	level * Brightness
usage ²	Brightness * RAM
level * temperature	level
—	level * RAM



Εικόνα 40: Σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 1]



Εικόνα 41: Σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 1]

5.2 Πείραμα 1: Μεμονωμένος χρήστης

Ρύθμιση υπερπαραμέτρων μεθόδου xgboost

Η ρύθμιση των υπερπαραμέτρων, γίνεται ακολουθώντας την ίδια διαδικασία αναζήτησης (3 fold cross validation-grid search) με προηγουμένως, για τις παραμέτρους της, με τις εξής τιμές

$$\left\{ \begin{array}{l} \text{n_estimators} = [400, 500, \dots, 1400, 1500] \\ \text{learning rate} = [0.03, 0.04, \dots, 0.09, 0.10] \\ \text{max_depth} = [4, 5, 6, 7, 8] \\ \text{colsample_bytree} = [0.35, 0.40, \dots, 0.60, 0.65] \\ \text{reg_lambda} = [0.20, 0.25, \dots, 0.45] \end{array} \right. \quad (5.3)$$

Τα αποτελέσματα της ρύθμισης και για τα δύο μοντέλα παρουσιάζονται παρακάτω

Πίνακας 16: Αποτελέσματα ρύθμισης υπερπαραμέτρων [Πείραμα 1]


	Mean-MAE	Mean-RMSE	Parameters
model_0	0.023	0.039	n_estimators = 600, learning rate = 0.06, max_depth = 8, colsample_bytree = 0.35, reg_lambda = 0.3
model_1	0.022	0.034	n_estimators = 1000, learning rate = 0.03, max_depth = 8, colsample_bytree = 0.5, reg_lambda = 0.4

Για το μοντέλο 0, κατάφερε με 400 λιγότερα δέντρα, να επιτύχει καλύτερες τιμές στις μετρικές, με μέσο **MAE = 0.023** και **RMSE = 0.039**, ενώ για το 1, καλύτερο μοντέλο είναι αυτό της αρχικής αναζήτησης με τιμές, **0.022** και **0.034**, αντίστοιχα.


Στη συνέχεια, παρουσιάζονται τα σφάλματα της μεθόδου για το σετ δεδομένων ελέγχου, δεδομένα άγνωστα έως αυτήν τη στιγμή.

Πίνακας 17: Αποτελέσματα σετ δεδομένων ελέγχου (test set) [Πείραμα 1]

	MAE	RMSE
model_0	0.021	0.036
model_1	0.019	0.029




Εικόνα 42: Πρόβλεψη energy drain [selected model_1] [Πείραμα 1]



Εικόνα 43: Ιστόγραμμα σφαλμάτων πρόβλεψης [selected model_1] [Πείραμα 1]

5.3 Πείραμα 2: Πολλαπλοί χρήστες



Εικόνα 44: Μεγένθυνση πρόβλεψης energy drain [selected model_1] [Πείραμα 1]


Στη γραφική παράσταση των προβλέψεων, παρατηρούμε πως το μοντέλο 1 υστερεί στις προβλέψεις των -σχετικά- μεγάλων τιμών (> 0.30). Ωστόσο, στο ιστόγραμμα των σφαλμάτων φαίνεται πως οι περιπτώσεις αυτές υπάρχουν σπάνια, με την πληθώρα των περιπτώσεων να επιτυγχάνει σφάλμα μικρότερο του 0.05. Επιπλέον, παρουσιάζεται ένα μέρος των προβλέψεων και των σφαλμάτων τους, για καλύτερη εποπτεία. Τέλος, να σημειωθεί πως η συμπεριφορά του μοντέλου 0 είναι παρόμοια.

5.3 Πείραμα 2: Πολλαπλοί χρήστες

Το δεύτερο πείραμα αφορά πολλαπλούς χρήστες και τα Sessions λειτουργίας που έχουν παράγει, με διάρκεια έως και 30 λεπτά. Ουσιαστικά, το πείραμα ασχολείται με τη συνεχόμενη χρήση της συσκευής, με τα αρχεία αυτά να αποτελούν -περίπου- το 55% των συνολικών αρχείων που συλλέχθηκαν. Τέλος, οι χρήστες που συμμετέχουν πρέπει να έχουν τουλάχιστον 20 αρχεία, έτσι ώστε υπάρχει ικανός αριθμός διαφορετικών χρήσεων της συσκευής τους.


Ομαδοποίηση

Η μεθοδολογία που ακολουθήθηκε είναι η ίδια με το προηγούμενο πείραμα. Αρχικά, παρουσιάζονται τα δενδρογράμματα για τις τρεις περιπτώσεις της ιεραρχικής ομαδοποίησης, Single, Complete και Average, με **CPCC 0.74, 0.75 και 0.81**, αντίστοιχα.




Εικόνα 45: Δενδρογράμμα ιεραρχικής ομαδοποίησης linkage=single [Πείραμα 2]

5.3 Πείραμα 2: Πολλαπλοί χρήστες




Εικόνα 46: Δενδρόγραμμα ιεραρχικής ομαδοποίησης $linkage=complete$ [Πείραμα 2]




Εικόνα 47: Δενδρόγραμμα Ιεραρχικής ομαδοποίησης $linkage=average$ [Πείραμα 2]

Στη συνέχεια, για τις δύο καλύτερες ομαδοποίησεις βάσει του CPCC, Complete και Average, γίνεται έλεγχος για την εύρεση του βέλτιστου αριθμού ομάδων.



Εικόνα 48: Mean Silhouette ανά αριθμό ομάδων $linkage=complete$ [Πείραμα 2]

5.3 Πείραμα 2: Πολλαπλοί χρήστες



Εικόνα 49: Mean Silhouette ανά αριθμό ομάδων linkage=average [Πείραμα 2]

Στην περίπτωση του Complete, δημιουργήθηκαν 6 ομάδες, με **μέσο Silhouette 0.581**, ενώ στην περίπτωση του Average, σχηματίστηκαν 7 ομάδες με **μέσο Silhouette 0.580**. Επιπλέον, για την περαιτέρω αξιολόγηση των ομάδων και την επιλογή της καλύτερης ομαδοποίησης, ελέγχονται τα επιμέρους χαρακτηριστικά της εκάστοτε ομάδας

Πίνακας 18: Αξιολόγηση ομαδοποίησης [Πείραμα 2]


		Αριθμός ομάδας						
		0	1	2	3	4	5	6
Complete	Bluetooth	1022	0	0	23	149	0	—
	GPS	1022	0	2065	46	0	0	—
	Connectivity	1022	2672	2065	0	144	0	—
	Σύνολο	1022	2672	2065	46	149	465	—
Average	Bluetooth	1163	23	0	0	5	3	0
	GPS	1019	46	2065	0	0	3	0
	Connectivity	1163	0	2065	0	0	3	2672
	Σύνολο	1163	46	2065	465	5	3	2672

Είναι εύκολα κατανοητό, πως και οι δύο περιπτώσεις σχηματίζουν ομάδες με κοινά χαρακτηριστικά και παρόμοιων χρήσεων. Στην περίπτωση του Complete, οι ομάδες είναι –οριακά- καλύτερες, όπου για η ομάδα 0 περιέχει όλα τα παράθυρα χρήσεων που είχαν ταυτόχρονα ενεργοποιημένα το Bluetooth, το GPS και το Connectivity, η ομάδα 1, εκείνα με το Connectivity και η ομάδα 2, με το GPS και το Connectivity.

Οι ομάδες αυτές στη συνέχεια, θα χρησιμοποιηθούν ως ετικέτες για την εκπαίδευση μοντέλων παλινδρόμησης, με τις ομάδες 3, 4 και 5 να περιέχουν λίγα στοιχεία για να μπορέσει να εξαχθεί κάποιο συμπέρασμα. Τα θηκογράμματα για τη χρήση του επεξεργαστή, τη διαθέσιμη μνήμη RAM και τη φωτεινότητα της συσκευής, για τις ομάδες 0, 1 και 2, φανερώνουν πως οι διαφορές τους για τα τρία αυτά χαρακτηριστικά έγκεινται κυρίως στη φωτεινότητα. Πιο συγκεκριμένα, η ομάδα 0, αφορά χαμηλή χρήση, η ομάδα 1 χαμηλή προς μέση και η ομάδα 2, περιγράφει μια γενικότερη οικογένεια χρήσεων.


5.3 Πείραμα 2: Πολλαπλοί χρήστες

Phone usage boxplots ~ cluster 0




Εικόνα 50: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 0]
[Πείραμα 2]

Phone usage boxplots ~ cluster 1



Εικόνα 51: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 1]
[Πείραμα 2]


Phone usage boxplots ~ cluster 2




Εικόνα 52: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 2]
[Πείραμα 2]

5.3 Πείραμα 2: Πολλαπλοί χρήστες

Επιπλέον, μέσω του αλγορίθμου MDS, οι τρεις ομάδες απεικονίζονται στον δισδιάστατο και τρισδιάστατο χώρο, εμφανώς διαχωρισμένες.



Εικόνα 53: Απεικόνιση ομάδων στον δισδιάστατο χώρο [Πείραμα 2]



Εικόνα 54: Απεικόνιση ομάδων στον τρισδιάστατο χώρο [Πείραμα 2]

Παλινδρόμηση

Η διαδικασία εκτίμησης του energy drain είναι η ίδια με το πείραμα 1. Πιο αναλυτικά, για τις μεθόδους Ridge και Lasso, η παράμετρος alpha ελέγχθηκε στις τιμές, $\text{alpha} = [0.001, 0.01, 0.1, 1, 10, 100, 1000]$. Επιπλέον, για τη μέθοδο xgboost, υλοποιήθηκε η αναζήτηση πλέγματος (grid search) για τις παραμέτρους της, με τις εξής τιμές

$$\left\{ \begin{array}{l} \text{n_estimators} = [100, 200, 300, \dots, 1400, 1500] \\ \text{learning rate} = [0.03, 0.04, \dots, 0.09, 0.10] \\ \text{max_depth} = [6, 7, 8, 9] \\ \text{colsample_bytree} = [0.40, 0.45, 0.50, 0.55] \\ \text{reg_lambda} = [0.40, 0.45, 0.50] \end{array} \right. \quad (5.4)$$

Στους παρακάτω πίνακες, παρουσιάζονται τα αποτελέσματα για τα τρία μοντέλα, για τις καλύτερες παραμέτρους κάθε μεθόδου.

5.3 Πείραμα 2: Πολλαπλοί χρήστες

Πίνακας 19: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_0] [Πείραμα 2]

	model_0 (3-fold Cross Validation)		
	Mean-MAE	Mean-RMSE	Parameters
linear	0.047	0.063	—
ridge	0.046	0.062	alpha = 0.01
lasso	0.050	0.066	alpha = 0.001
xgboost	0.028	0.046	n_estimators = 600, learning rate = 0.06, max_depth = 6, colsample_bytree = 0.45, reg_lambda = 0.4

Πίνακας 20: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_1] [Πείραμα 2]

	model_1 (3-fold Cross Validation)		
	Mean-MAE	Mean-RMSE	Parameters
linear	0.051	0.065	—
ridge	0.052	0.066	alpha = 0.001
lasso	0.056	0.069	alpha = 0.001
xgboost	0.031	0.046	n_estimators = 1100, learning rate = 0.04, max_depth = 6, colsample_bytree = 0.4, reg_lambda = 0.4

Πίνακας 21: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_2] [Πείραμα 2]


	model_2 (3-fold Cross Validation)		
	Mean-MAE	Mean-RMSE	Parameters
linear	0.069	0.094	—
ridge	0.069	0.094	alpha = 0.1
lasso	0.071	0.096	alpha = 0.001
xgboost	0.051	0.079	n_estimators = 1100, learning rate = 0.03, max_depth = 7, colsample_bytree = 0.5, reg_lambda = 0.4

Τα παραπάνω αποτελέσματα, αφορούν τις μέσες τιμές για το σετ επικύρωσης (validation set) κάθε επανάληψης της διασταυρωμένης επικύρωσης. Η απλή γραμμική παλινδρόμηση και οι μέθοδοι Ridge και Lasso, παρουσιάζουν πανομοιότυπα σφάλματα. Τα βέλτιστα alpha προδίδουν πως εν γένει σε όλες τις περιπτώσεις εκτελέστηκε ο αλγόριθμος των ελαχίστων τετραγώνων. Από την άλλη, η μέθοδος xgboost καταφέρνει να επιτύχει 40% μικρότερο μέσο απόλυτο σφάλμα (MAE), για τα δύο πρώτα μοντέλα σε σχέση με τις γραμμικές μεθόδους και 26% για το τρίτο. Επιπλέον, μειώνει την τυπική απόκλιση των σφαλμάτων (RMSE), που σημαίνει πως τα δεδομένα είναι πιο συγκεντρωμένα γύρω από την καμπύλη παλινδρόμησης. Στη συνέχεια του πειράματος θα χρησιμοποιηθεί μόνο η μέθοδος xgboost, καθώς παρέχει ανώτερα αποτελέσματα.


Επιλογή χαρακτηριστικών

Η πρόβλεψη του energy drain βασίζεται στα 26 χαρακτηριστικά του dataset, χωρίς να είναι αναγκαία η χρήση όλων. Χρησιμοποιώντας τη διασταυρωμένη επικύρωση 3 υποσυνόλων, με σταθερές τις παραμέτρους των μοντέλων, ελέγχεται η απόδοση των μοντέλων για διαφορετικά όρια σπουδαιότητας (importance) των χαρακτηριστικών, στα δεδομένα εκπαίδευσης.


5.3 Πείραμα 2: Πολλαπλοί χρήστες



Εικόνα 55: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 2]



Εικόνα 56: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 2]



Εικόνα 57: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_2] [Πείραμα 2]

5.3 Πείραμα 2: Πολλαπλοί χρήστες


Είναι εμφανές από τις γραφικές παραστάσεις πως αφήνοντας εκτός ορισμένα από τα χαρακτηριστικά επιτυγχάνονται καλύτερα αποτελέσματα (μικρότερο μέσο MAE). Πιο συγκεκριμένα, για όριο σπουδαιότητας το **0.046**, **0.044** και **0.044** για τα μοντέλα 0, 1 και 2, δηλαδή 7, 11 και 10 χαρακτηριστικά, αντίστοιχα, επιτυγχάνονται τα αποτελέσματα

Πίνακας 22: Αποτελέσματα επιλογής χαρακτηριστικών [Πείραμα 2]

	Validation Set (3-fold)	
	Mean-MAE	Mean-RMSE
model_0	0.025	0.044
model_1	0.027	0.042
model_2	0.046	0.074


Πίνακας 23: Σπουδαιότερα χαρακτηριστικά μοντέλων [Πείραμα 2]

model_0	model_1	model_2
temperature * Brightness	Brightness ²	Brightness ²
Brightness * RAM	temperature * Brightness	usage * Brightness
Brightness ²	level * Brightness	temperature * usage
usage * Brightness	usage ²	temperature * Brightness
level * Brightness	level	level * Brightness
level	level ²	Brightness
temperature * RAM	usage * Brightness	level * temperature
—	Brightness * RAM	temperature ²
—	Brightness	Brightness * RAM
—	temperature ²	level
—	level * temperature	—




Εικόνα 58: Σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 2]

5.3 Πείραμα 2: Πολλαπλοί χρήστες



Εικόνα 59: Σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 2]



Εικόνα 60: Σπουδαιότητα χαρακτηριστικών [model_2] [Πείραμα 2]

Ρύθμιση υπερπαραμέτρων μεθόδου xgboost

Η ρύθμιση των υπερπαραμέτρων, γίνεται ακολουθώντας την ίδια διαδικασία αναζήτησης (3 fold cross validation-grid search) με προηγουμένως, για τις παραμέτρους της, με τις εξής τιμές

$$\begin{cases} n_estimators = [100, 200, 300, \dots, 1400, 1500] \\ learning\ rate = [0.03, 0.04, \dots, 0.09, 0.10] \\ max_depth = [4, 5, 6, 7, 8] \\ colsample_bytree = [0.40, 0.45, 0.50, 0.55] \\ reg_lambda = [0.30, 0.35, 0.40, 0.45] \end{cases} \quad (5.5)$$

Τα αποτελέσματα της ρύθμισης και για τα τρία μοντέλα παρουσιάζονται παρακάτω

5.3 Πείραμα 2: Πολλαπλοί χρήστες

Πίνακας 24: Αποτελέσματα ρύθμισης υπερπαραμέτρων [Πείραμα 2]


	Mean-MAE	Mean-RMSE	Parameters
model_0	0.025	0.044	n_estimators = 600, learning rate = 0.06, max_depth = 6, colsample_bytree = 0.45, reg_lambda = 0.4
model_1	0.026	0.041	n_estimators = 600, learning rate = 0.06, max_depth = 8, colsample_bytree = 0.4, reg_lambda = 0.45
model_2	0.046	0.074	n_estimators = 1100, learning rate = 0.03, max_depth = 7, colsample_bytree = 0.5, reg_lambda = 0.4

Για τα μοντέλα 0 και 2, καλύτερα αναδείχθηκαν τα μοντέλα της αρχικής αναζήτησης, χωρίς να υπάρξει περαιτέρω βελτίωση των αποτελεσμάτων. Από την άλλη, το μοντέλο 2 κατάφερε με 500 λιγότερα δέντρα, να επιτύχει μικρότερα σφάλματα, με μέσο **MAE = 0.026** και **RMSE = 0.041**.


Στη συνέχεια, παρουσιάζονται τα σφάλματα της μεθόδου για το σετ δεδομένων ελέγχου, δεδομένα άγνωστα έως αυτή τη στιγμή.

Πίνακας 25: Αποτελέσματα σετ δεδομένων ελέγχου (test set) [Πείραμα 2]

	MAE	RMSE
model_0	0.023	0.037
model_1	0.021	0.033
model_2	0.041	0.070




Εικόνα 61: Πρόβλεψη energy drain [selected model_1] [Πείραμα 2]



Εικόνα 62: Ιστόγραμμα σφαλμάτων πρόβλεψης [selected model_1] [Πείραμα 2]

Η γραφική παράσταση των προβλέψεων, όπως και στο προηγούμενο πείραμα, κάνει εμφανές πως το μοντέλο 1 μειονεκτεί στην εκτίμηση των μεγάλων τιμών (> 0.30). Το ιστόγραμμα των σφαλμάτων, μας πληροφορεί πως η πληθώρα των περιπτώσεων επιτυγχάνει σφάλμα μικρότερο του 0.05. Επιπλέον, παρουσιάζεται ένα μέρος των προβλέψεων και των σφαλμάτων τους, για καλύτερη εποπτεία.

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας



Εικόνα 63: Μεγένθυνση πρόβλεψης energy drain [selected model_1] [Πείραμα 2]


Η συμπεριφορά του μοντέλου 0 είναι παρόμοια, με τα πλειοψηφία των περιπτώσεων να παρουσιάζουν σφάλμα μικρότερο του 0.05. Από την άλλη το μοντέλο 2, περιέχει μεγαλύτερα σφάλματα, της τάξης του 0.1 και παρουσιάζει μεγάλο RMSE, δηλαδή μεγάλη διακύμανση των σφαλμάτων. Κάτι τέτοιο, δικαιολογείται αν παρατηρήσουμε τον αριθμό των δέντρων που απαιτεί το μοντέλο, που μαρτυρά ένα πιο σύνθετο πρόβλημα προς επίλυση, και το θηκόγραμμα της χρήσης των συσκευών, το οποίο περιγράφει μια γενικότερη οικογένεια χρήσεων.

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας

Τα μεγάλα σφάλματα του προηγούμενου πειράματος, επαληθεύουν την πολυπλοκότητα του προβλήματος προς επίλυση, ειδικά για διαφορετικούς χρήστες και συσκευές. Έτσι, το πείραμα 3 επαναλαμβάνει την διαδικασία του, αλλά ασχολείται μόνο με συσκευές που έχουν ίδια χωρητικότητα μπαταρίας (4000 mAh).


Ομαδοποίηση

Η μεθοδολογία που ακολουθήθηκε είναι η ίδια με τα προηγούμενα πειράματα. Αρχικά, παρουσιάζονται τα δενδρογράμματα για τις τρεις περιπτώσεις της ιεραρχικής ομαδοποίησης, Single, Complete και Average, με **CPCC 0.75, 0.81** και **0.82**, αντίστοιχα.




Εικόνα 64: Δενδρόγραμμα ιεραρχικής ομαδοποίησης linkage=single [Πείραμα 3]

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας




Εικόνα 65: Δενδρόγραμμα ιεραρχικής ομαδοποίησης *linkage=complete* [Πείραμα 3]




Εικόνα 66: Δενδρόγραμμα Ιεραρχικής ομαδοποίησης *linkage=average* [Πείραμα 3]

Στη συνέχεια, για τις δύο καλύτερες ομαδοποιήσεις βάσει του CPCC, Complete και Average, γίνεται έλεγχος για την εύρεση του βέλτιστου αριθμού ομάδων.



Εικόνα 67: Mean Silhouette ανά αριθμό ομάδων *linkage=complete* [Πείραμα 3]

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας



Εικόνα 68: Mean Silhouette ανά αριθμό ομάδων linkage=average [Πείραμα 3]

Οι δύο περιπτώσεις δημιουργούν 5 ομάδες, με **μέσο Silhouette 0.556**. Επιπλέον, για την περαιτέρω αξιολόγηση των ομάδων, ελέγχονται τα επιμέρους χαρακτηριστικά τους

Πίνακας 26: Αξιολόγηση ομαδοποίησης [Πείραμα 3]


		Αριθμός ομάδας				
		0	1	2	3	4
Complete	Bluetooth	1144	0	23	0	5
	GPS	1000	0	43	1521	0
	Connectivity	1144	2333	0	1521	0
	Σύνολο	1144	2333	43	1521	17
Average	Bluetooth	1144	0	5	23	0
	GPS	1000	1521	0	43	0
	Connectivity	1144	1521	0	0	2333
	Σύνολο	1144	1521	17	43	2333

Είναι φανερό, αφενός πως η ομαδοποίηση και στις δύο περιπτώσεις είναι η ίδια και αφετέρου πως οι ομάδες που έχουν σχηματιστεί διαθέτουν κοινά χαρακτηριστικά και περιγράφουν παρόμοιες χρήσεις. Επιπρόσθετα, αξίζει να σημειωθεί ότι το αποτέλεσμα της ομαδοποίησης είναι πανομοιότυπο με αυτό του προηγούμενου πειράματος.

Οι ομάδες αυτές στη συνέχεια, θα χρησιμοποιηθούν ως ετικέτες για την εκπαίδευση μοντέλων παλινδρόμησης, με τις ομάδες 2 και 4 να περιέχουν λίγα στοιχεία για να μπορέσει να εξαχθεί κάποιο συμπέρασμα. Τα θηκογράμματα για τη χρήση του επεξεργαστή, τη διαθέσιμη μνήμη RAM και τη φωτεινότητα της συσκευής, για τις ομάδες 0, 1 και 3, μαρτυρούν πως οι διαφορές τους για τα τρία αυτά χαρακτηριστικά έγκεινται κυρίως στη φωτεινότητα. Πιο συγκεκριμένα, η ομάδα 0, αφορά χαμηλή χρήση, η ομάδα 1 χαμηλή προς μέση και η ομάδα 2, περιγράφει μια γενικότερη οικογένεια χρήσεων.


5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας

Phone usage boxplots ~ cluster 0




Εικόνα 69: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 0]
[Πείραμα 3]

Phone usage boxplots ~ cluster 1



Εικόνα 70: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 1]
[Πείραμα 3]


Phone usage boxplots ~ cluster 3




Εικόνα 71: Θηκόγραμμα χρήσης CPU, διαθέσιμης RAM και φωτεινότητας [Ομάδα 3]
[Πείραμα 3]

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας

Επιπλέον, μέσω του αλγορίθμου MDS, οι τρεις ομάδες απεικονίζονται στον δισδιάστατο και τρισδιάστατο χώρο, εμφανώς διαχωρισμένες.



Εικόνα 72: Απεικόνιση ομάδων στον δισδιάστατο χώρο [Πείραμα 3]



Εικόνα 73: Απεικόνιση ομάδων στον τρισδιάστατο χώρο [Πείραμα 3]

Παλινδρόμηση

Η διαδικασία εκτίμησης του energy drain είναι η ίδια με τα πείραμα 1 και 2. Πιο αναλυτικά, για τις μεθόδους Ridge και Lasso, η παράμετρος alpha ελέγχθηκε στις τιμές, $\text{alpha} = [0.001, 0.01, 0.1, 1, 10, 100, 1000]$. Επιπλέον, για τη μέθοδο xgboost, υλοποιήθηκε η αναζήτηση πλέγματος (grid search) για τις παραμέτρους της, με τις εξής τιμές

$$\left\{ \begin{array}{l} \text{n_estimators} = [100, 200, 300, \dots, 1400, 1500] \\ \text{learning rate} = [0.03, 0.04, \dots, 0.09, 0.10] \\ \text{max_depth} = [4, 5, 6, 7, 8] \\ \text{colsample_bytree} = [0.40, 0.45, 0.50, 0.55, 0.60] \\ \text{reg_lambda} = [0.40, 0.45, 0.50] \end{array} \right. \quad (5.6)$$

Στους παρακάτω πίνακες, παρουσιάζονται τα αποτελέσματα για τα τρία μοντέλα, για τις καλύτερες παραμέτρους κάθε μεθόδου.

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας

Πίνακας 27: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_0] [Πείραμα 3]

	model_0 (3-fold Cross Validation)		
	Mean-MAE	Mean-RMSE	Parameters
linear	0.044	0.059	—
ridge	0.044	0.060	alpha = 0.1
lasso	0.047	0.062	alpha = 0.001
xgboost	0.029	0.045	n_estimators = 900, learning rate = 0.06, max_depth = 4, colsample_bytree = 0.45, reg_lambda = 0.45

Πίνακας 28: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_1] [Πείραμα 3]

	model_1 (3-fold Cross Validation)		
	Mean-MAE	Mean-RMSE	Parameters
linear	0.053	0.067	—
ridge	0.053	0.067	alpha = 0.001
lasso	0.056	0.070	alpha = 0.001
xgboost	0.030	0.044	n_estimators = 900, learning rate = 0.03, max_depth = 8, colsample_bytree = 0.5, reg_lambda = 0.4

Πίνακας 29: Αποτελέσματα αρχικής αναζήτησης πλέγματος [model_3] [Πείραμα 3]


	model_3 (3-fold Cross Validation)		
	Mean-MAE	Mean-RMSE	Parameters
linear	0.070	0.094	—
ridge	0.069	0.094	alpha = 0.1
lasso	0.070	0.096	alpha = 0.001
xgboost	0.054	0.082	n_estimators = 1200, learning rate = 0.06, max_depth = 4, colsample_bytree = 0.4, reg_lambda = 0.4

Τα παραπάνω αποτελέσματα, αφορούν τις μέσες τιμές για το σετ επικύρωσης (validation set) κάθε επανάληψης της διασταυρωμένης επικύρωσης. Ομοίως με τα προηγούμενα πειράματα, η απλή γραμμική παλινδρόμηση και οι μέθοδοι Ridge και Lasso, παρουσιάζουν μεγάλα σφάλματα. Η μέθοδος xgboost καταφέρνει να επιτύχει 35% μικρότερο μέσο απόλυτο σφάλμα (MAE) για το μοντέλο 0, 43% για το 1 και 23% για το 3. Επιπλέον, μειώνει την τυπική απόκλιση των σφαλμάτων (RMSE), που σημαίνει πως τα δεδομένα είναι πιο συγκεντρωμένα γύρω από την καμπύλη παλινδρόμησης. Στη συνέχεια του πειράματος θα χρησιμοποιηθεί μόνο η μέθοδος xgboost, καθώς παρέχει ανώτερα αποτελέσματα.


Επιλογή χαρακτηριστικών

Οι εκτιμήσεις των μοντέλων, βασίζονται στο σύνολο των χαρακτηριστικών (26) του dataset, χωρίς να είναι απαραίτητη η χρήση όλων. Χρησιμοποιώντας τη διασταυρωμένη επικύρωση 3 υποσυνόλων, με σταθερές τις παραμέτρους των μοντέλων, ελέγχεται η απόδοση των μοντέλων για διαφορετικά όρια σπουδαιότητας (importance) των χαρακτηριστικών, στα δεδομένα εκπαίδευσης.


5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας



Εικόνα 74: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 3]



Εικόνα 75: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 3]



Εικόνα 76: Mean MAE ανά σπουδαιότητα χαρακτηριστικών [model_3] [Πείραμα 3]

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας


Είναι φανερό από τις γραφικές παραστάσεις πως αφήνοντας εκτός ορισμένα χαρακτηριστικά επιτυγχάνονται καλύτερα αποτελέσματα (μικρότερο μέσο MAE). Πιο συγκεκριμένα, για όριο σπουδαιότητας το **0.048**, **0.052** και **0.038** για τα μοντέλα 0, 1 και 3, δηλαδή 8, 7 και 12 χαρακτηριστικά, αντίστοιχα, επιτυγχάνονται τα αποτελέσματα

Πίνακας 30: Αποτελέσματα επιλογής χαρακτηριστικών [Πείραμα 3]

	Validation Set (3-fold)	
	Mean-MAE	Mean-RMSE
model_0	0.025	0.041
model_1	0.023	0.038
model_3	0.048	0.077


Πίνακας 31: Σπουδαιότερα χαρακτηριστικά μοντέλων [Πείραμα 3]

model_0	model_1	model_3
temperature * Brightness	Brightness ²	temperature * Brightness
usage * Brightness	temperature * Brightness	Brightness
Brightness ²	usage * Brightness	usage ²
level * Brightness	level * Brightness	temperature * usage
level ²	Brightness * RAM	usage * Brightness
Brightness * RAM	level	level ²
level	usage ²	level Brightness
temperature ²	—	temperature ²
—	—	level
—	—	Brightness * RAM
—	—	level * temperature
-	-	usage




Εικόνα 77: Σπουδαιότητα χαρακτηριστικών [model_0] [Πείραμα 3]

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας



Εικόνα 78: Σπουδαιότητα χαρακτηριστικών [model_1] [Πείραμα 3]



Εικόνα 79: Σπουδαιότητα χαρακτηριστικών [model_3] [Πείραμα 3]

Ρύθμιση υπερπαραμέτρων μεθόδου xgboost

Η ρύθμιση των υπερπαραμέτρων, γίνεται ακολουθώντας την ίδια διαδικασία αναζήτησης (3 fold cross validation-grid search) με προηγουμένως, για τις παραμέτρους της, με τις εξής τιμές

$$\begin{cases} n_estimators = [100, 200, 300, \dots, 1400, 1500] \\ learning\ rate = [0.03, 0.04, \dots, 0.09, 0.10] \\ max_depth = [3, 4, 5, 6, 7, 8] \\ colsample_bytree = [0.40, 0.45, 0.50, 0.55] \\ reg_lambda = [0.30, 0.35, 0.40, 0.45] \end{cases} \quad (5.7)$$

Τα αποτελέσματα της ρύθμισης και για τα τρία μοντέλα παρουσιάζονται παρακάτω

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας

Πίνακας 32: Αποτελέσματα ρύθμισης υπερπαραμέτρων [Πείραμα 3]


	Mean-MAE	Mean-RMSE	Parameters
model_0	0.022	0.041	n_estimators = 600, learning rate = 0.03, max_depth = 8, colsample_bytree = 0.4, reg_lambda = 0.4
model_1	0.023	0.038	n_estimators = 900, learning rate = 0.03, max_depth = 8, colsample_bytree = 0.5, reg_lambda = 0.4
model_3	0.048	0.077	n_estimators = 1200, learning rate = 0.06, max_depth = 4, colsample_bytree = 0.4, reg_lambda = 0.4

Το μοντέλο 0, κατάφερε με 300 λιγότερα δέντρα, αλλά με το διπλάσιο βάθος, να επιτύχει καλύτερα αποτελέσματα βελτιώνοντας ελάχιστα τις εκτιμήσεις του με μέσο **MAE = 0.022** και **RMSE = 0.041**. Από την άλλη, για τα μοντέλα 1 και 3, καλύτερα αναδείχθηκαν εκείνα της αρχικής αναζήτησης χωρίς να υπάρξει περαιτέρω βελτίωση.


Στη συνέχεια, παρουσιάζονται τα σφάλματα της μεθόδου για το σετ δεδομένων ελέγχου, δεδομένα άγνωστα έως αυτή τη στιγμή.

Πίνακας 33: Αποτελέσματα σετ δεδομένων ελέγχου (test set) [Πείραμα 3]

	MAE	RMSE
model_0	0.018	0.031
model_1	0.022	0.034
model_3	0.042	0.068




Εικόνα 80: Πρόβλεψη energy drain [selected model_1] [Πείραμα 3]



Εικόνα 81: Ιστόγραμμα σφαλμάτων πρόβλεψης [selected model_1] [Πείραμα 3]

Η γραφική παράσταση των προβλέψεων, για άλλη μια φορά καταδεικνύει την αδυναμία του μοντέλου να εκτιμήσει τις μεγάλες τιμές (> 0.30). Επιπλέον, τα αποτελέσματα αυτού του πειράματος είναι πανομοιότυπα με αυτά του προηγούμενου, όπου η πλειοψηφία των περιπτώσεων για τα μοντέλα 0 και 1, παρουσιάζει σφάλμα μικρότερο του 0.05, ενώ για το μοντέλο 3 είναι μεγαλύτερα, της τάξης του 0.1, και με υψηλό RMSE, δηλαδή χαρακτηρίζονται από μεγάλη διακύμανση.

5.4 Πείραμα 3: Όμοια χωρητικότητα μπαταρίας



Εικόνα 82: Μεγένθυνση πρόβλεψης energy drain [selected model_1] [Πείραμα 3]

6 Σύνοψη

Στο τελευταίο Κεφάλαιο περιλαμβάνονται τα συμπεράσματα της μεθοδολογίας που ακολουθήθηκε και μελλοντικές βελτιώσεις αυτής. Πιο συγκεκριμένα, στις ακόλουθες Ενότητες παρουσιάζονται συνοπτικά τα προβλήματα που εμφανίστηκαν (Ενότητα 6.1), τα ποιοτικά χαρακτηριστικά της ανάλυσης που προηγήθηκε (Ενότητα 6.2) και προτείνονται αλλαγές και προσθήκες για τη βελτίωση της (Ενότητα 6.3).

6.1 Προβλήματα

Ένα από τα αρχικά προβλήματα που επιλύθηκε είναι η ανάπτυξη της εφαρμογής για πολλαπλές συσκευές. Σε διαφορετικές εκδόσεις του Android, ή ακόμα και σε διαφορετικές συσκευές με την ίδια έκδοση, αυτήν τερματίζοταν από το λειτουργικό εντός σύντομου χρονικού διαστήματος, για εξοικονόμηση ενέργειας. Επιπρόσθετα, τα δεδομένα που καταγράφονται είναι πραγματικής χρήσης, με αποτέλεσμα να απαιτούν αρκετή προεπεξεργασία για τον εντοπισμό ακατάλληλων ή/και εξωκείμενων τιμών. Επιπλέον, στην τωρινή έκδοση της δεν υπάρχει καταγραφή χαρακτηριστικών που να ενημερώνουν για την ηλικία και την καταπόνηση της συσκευής, καθιστώντας την ανάλυση ακόμα δυσκολότερη.

Η ανάλυση, όπως έχει αναφερθεί, εφαρμόζεται στο σύνολο των Sessions λειτουργίας όλων των χρηστών. Τα παράθυρα χρήσης που δημιουργούνται με σκοπό την ομαδοποίηση των δεδομένων, έχουν ως αντίκτυπο την απώλεια χρήσιμης πληροφορίας. Στη συνέχεια, πρόκληση υπήρξε η εύρεση της κατάλληλης μεθόδου ομαδοποίησης, λόγω της ταυτόχρονης ύπαρξης κατηγορικών (δυαδικών) και αριθμητικών χαρακτηριστικών στα δεδομένα που δεν επέτρεπε τη χρήση της Euclidean απόστασης. Η λύση δόθηκε από την ιεραρχική ομαδοποίηση, με αξιοποίηση της συνάρτησης απόστασης Gower. Τέλος, το πρόβλημα παλινδρόμησης αποδείχθηκε ισχυρά μη γραμμικό, με αποτέλεσμα οι συμβατικές τεχνικές να αποτύχουν. Έτσι, χρησιμοποιήθηκε η μέθοδος xgboost που ανήκει στην κατηγορία του Ensemble Learning και είναι χρήσιμη στην επίλυση τέτοιου είδους προβλημάτων.

6.2 Συμπεράσματα

Στόχος της εν λόγω διπλωματικής εργασίας είναι η ανάλυση της χρήσης των κινητών τηλεφώνων και η εκτίμηση της κατανάλωσης ενέργειας της μπαταρίας τους. Για τον σκοπό αυτό αναπτύχθηκε σε πρώτο στάδιο η εφαρμογή BatteryApp για τη συλλογή των απαιτούμενων δεδομένων, όπου στη συνέχεια αναλυθήκαν με τη χρήση τεχνικών μηχανικής μάθησης.

Αρχικά, υπήρξε η ομαδοποίηση όμοιων χρήσεων των κινητών, όπου για την επίτευξη της χρησιμοποιήθηκαν μόνο χαρακτηριστικά που αντικατοπτρίζουν τη λειτουργία των συσκευών (Πίνακας 6). Για όλα τα πειράματα, η ομαδοποίηση βασίστηκε στα δυαδικά χαρακτηριστικά, GPS, Bluetooth και Connectivity. Ο ποιοτικός έλεγχος και η αξιολόγηση της, μέσω των boxplots για τα αριθμητικά χαρακτηριστικά, μαρτυρά πως η κύρια διαφορά εμφανίζεται στη φωτεινότητα της συσκευής, γεγονός που δικαιολογεί την υπερίσχυση των δυαδικών κατά τον σχηματισμό των ομάδων.

Στη συνέχεια ακολούθησε η εκτίμηση του energy drain για κάθε μια από αυτές ομάδες. Αρχικά, οι επιδόσεις της γραμμικής παλινδρόμησης και των μεθόδων Ridge και Lasso, επιβεβαιώνουν πως το πρόβλημα προς επίλυση είναι ισχυρά μη γραμμικό. Επιπλέον, παρατηρώντας τα σπουδαιότερα χαρακτηριστικά κάθε πειράματος (Πίνακας 15, 23, 31) είναι φανερό πως η φωτεινότητα της οθόνης, η θερμοκρασία της μπαταρίας, το επίπεδο της και το φορτίο του επεξεργαστή, διαδραματίζουν εμφανή ρόλο στην κατασκευή της

6.3 Μελλοντική Εργασία

πρόβλεψης. Από την άλλη, η διαθέσιμη μνήμη RAM και τα δυαδικά χαρακτηριστικά, είτε εμφανίζονται χαμηλότερα είτε απουσιάζουν τελείως, χωρίς να συμμετέχουν σημαντικά σ' αυτή.

Οι γραφικές παραστάσεις των προβλέψεων και των σφαλμάτων, δείχνουν αδυναμία των μοντέλων για την πρόβλεψη των μεγάλων τιμών, αφήνοντας ανοιχτό το περιθώριο βελτίωσής της. Συγκρίνοντας τα σφάλματα των πειραμάτων 1, 2 (Πίνακας 17, 25), αναδεικνύεται πως η εκτίμηση της συμπεριφοράς της μπαταρίας είναι πιο εύκολη με μια συσκευή παρά με την ύπαρξη πολλών και διαφορετικών, το οποίο συμφωνεί και με τη διαίσθηση μας. Τέλος, εκτελέστηκε το πείραμα 3 για τον έλεγχο της συμπεριφοράς διαφορετικών συσκευών, αλλά με ίδια χωρητικότητα μπαταρίας. Τα αποτελέσματα (Πίνακας 33) αποκαλύπτουν μια μικρή βελτίωση για την ομάδα 0, με την υπόλοιπη ανάλυση να δίνει πανομοιότυπα αποτελέσματα με πριν. Κάτι τέτοιο οδηγεί στο συμπέρασμα, πως η συνολική χωρητικότητα δεν επηρεάζει αισθητά την κατανάλωση ενέργειας, όσο άλλα χαρακτηριστικά (πχ. ηλικία και καταπόνηση μπαταρίας).

6.3 Μελλοντική Εργασία

Η εκτίμηση της κατανάλωσης ενέργειας των μπαταριών μέσω της χρήσης των κινητών τηλεφώνων είναι ένα αρκετά ενδιαφέρον προς μελέτη ερώτημα. Δίνει τη δυνατότητα στους χρήστες να αποκτούν καλύτερο έλεγχο της συσκευής τους, αναγνωρίζοντας μοτίβα λειτουργιών. Βελτιώνοντας την ακρίβεια των προβλέψεων, η κατανάλωση ενέργειας μπορεί να χρησιμοποιηθεί με σκοπό την εκτίμηση του υπολειπόμενου χρόνου αποφόρτισης (RUL), ένα ακόμα βασικό και αρκετά δύσκολο πρόβλημα των μπαταριών. Έτσι, μετά την αποτίμηση της μεθοδολογίας που ακολουθήθηκε, χρήσιμη θα ήταν η πρόταση πιθανών αλλαγών και προσθηκών σ' αυτή.

Αρχικά, η εφαρμογή BatteryApp βρίσκεται σε πρώιμο στάδιο. Υπάρχει η δυνατότητα καταγραφής περισσότερων δεδομένων χρήσης της συσκευής, είτε νέων, είτε ήδη υπαρχόντων με μεγαλύτερη λεπτομέρεια, όπως για παράδειγμα ο διαχωρισμός της ενεργοποίησης του Bluetooth (enable) και της σύνδεσης με μια συσκευή (connect). Επιπλέον, η διαδικασία εκτίμησης αυτήν τη στιγμή είναι offline, με τα δεδομένα να πρέπει να μεταφορτωθούν στον διακομιστή και στη συνέχεια να πραγματοποιηθεί η ανάλυση τους. Μια πιθανή λύση θα ήταν η ενσωμάτωση του μοντέλου μηχανικής μάθησης εντός της εφαρμογής, όπου θα επέτρεπε την online εκτίμηση. Επίσης, σε περίπτωση που κάτι τέτοιο δεν είναι εφικτό, υπάρχει η δυνατότητα ανάπτυξης ενός API, ως διαμεσολαβητή με τον διακομιστή που θα φιλοξενεί το μοντέλο, για να λαμβάνει τα αιτήματα των χρηστών και να πραγματοποιεί την πρόβλεψη. Παράλληλα, η απόκτηση στατιστικών πληροφοριών των χρηστών της εφαρμογής, όπως η συχνότητα φόρτισης της συσκευής και η ηλικία της, μέσω της συμπλήρωσης ενός ερωτηματολογίου θα ήταν ωφέλιμη κατά την ανάλυση των δεδομένων.

Επιπρόσθετα, τα δεδομένα που λαμβάνονται είναι πραγματικής χρήσης. Έγινε η επιλογή στο στάδιο της προεπεξεργασίας, για την ομαλοποίηση τους να διαχωριστούν σε μη επικαλυπτόμενα παράθυρα χρήσης 50 δευτερολέπτων, με αποτέλεσμα κομμάτι χρήσιμης πληροφορίας να χαθεί. Επιπλέον, για την ομαδοποίηση τους χρησιμοποιήθηκαν μόνο τα δεδομένα χρήσης της συσκευής. Η δοκιμή περισσότερων αλγορίθμων ομαδοποίησης και με διαφορετικά χαρακτηριστικά εισόδου κρίνεται σκόπιμη για την εύρεση νέων ομαδοποίησεων, που πιθανώς να συνδέονται και με τα γνωρίσματα της μπαταρίας.

Κλείνοντας με την παλινδρόμηση, η αξιοποίηση των πολυωνυμικών συνδυασμών των αριθμητικών μεταβλητών, αποτελεί μια μόνο από τις τεχνικές κατασκευής χαρακτηριστικών. Η εξέταση περισσότερων τέτοιων μεθόδων, που θα περιλαμβάνει και

6.3 Μελλοντική Εργασία

τα δυαδικά, κρίνεται αναγκαία για την εύρεση ουσιαστικών σχέσεων μεταξύ του διανύσματος εισόδου και της εξόδου και την πλήρη εκμετάλλευση αυτών. Τέλος, ο έλεγχος επιπλέον μη γραμμικών μοντέλων παλινδρόμησης μπορεί να επιφέρει βελτίωση των εκτιμήσεων.

Βιβλιογραφία

- [1] Dong Tingting, Li Jun, Zhao Fuquan, You Yi and Jin Qiqian, "Analysis on the influence of measurement error on state of charge estimation of LiFePO₄ power Battery," 2011 International Conference on Materials for Renewable Energy & Environment, Shanghai, 2011, pp. 644-649, doi: 10.1109/ICMREE.2011.5930893.
- [2] Iryna Snihir, William Rey, Evgeny Verbitskiy, Afifa Belfadhel-Ayeb, Peter H.L. Notten, Battery open-circuit voltage estimation by a method of statistical analysis, Journal of Power Sources, Volume 159, Issue 2, 2006, Pages 1484-1487, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2005.11.090
- [3] Linfeng Zheng, Lei Zhang, Jianguo Zhu, Guoxiu Wang, Jiuchun Jiang, Co-estimation of state-of-charge, capacity and resistance for lithium-ion batteries based on a high-fidelity electrochemical model, Applied Energy, Volume 180, 2016, Pages 424-434, ISSN 0306-2619, doi.org/10.1016/j.apenergy.2016.08.016.
- [4] Fangdan Zheng, Yinjiao Xing, Jiuchun Jiang, Bingxiang Sun, Jonghoon Kim, Michael Pecht, Influence of different open circuit voltage tests on state of charge online estimation for lithium-ion batteries, Applied Energy, Volume 183, 2016, Pages 513-525, ISSN 0306-2619, doi.org/10.1016/j.apenergy.2016.09.010.
- [5] Michael A. Roscher, Dirk Uwe Sauer, Dynamic electric behavior and open-circuit-voltage modeling of LiFePO₄-based lithium ion secondary batteries, Journal of Power Sources, Volume 196, Issue 1, 2011, Pages 331-336, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2010.06.098.
- [6] Kong Soon Ng, Chin-Sien Moo, Yi-Ping Chen, Yao-Ching Hsieh, Enhanced coulomb counting method for estimating state-of-charge and state-of-health of lithium-ion batteries, Applied Energy, Volume 86, Issue 9, 2009, Pages 1506-1511, ISSN 0306-2619, doi.org/10.1016/j.apenergy.2008.11.021.
- [7] Yanhui Zhang, Wenji Song, Shili Lin, Ziping Feng, A novel model of the initial state of charge estimation for LiFePO₄ batteries, Journal of Power Sources, Volume 248, 2014, Pages 1028-1033, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2013.09.135.
- [8] Yuejiu Zheng, Minggao Ouyang, Xuebing Han, Languang Lu, Jianqiu Li, Investigating the error sources of the online state of charge estimation methods for lithium-ion batteries in electric vehicles, Journal of Power Sources, Volume 377, 2018, Pages 161-188, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2017.11.094.
- [9] Feng Leng, Cher Ming Tan, Rachid Yazami, Minh Duc Le, A practical framework of electrical based online state-of-charge estimation of lithium ion batteries, Journal of Power Sources, Volume 255, 2014, Pages 423-430, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2014.01.020.
- [10] Xiaopeng Tang, Yujie Wang, Zonghai Chen, a method for state-of-charge estimation of LiFePO₄ batteries based on a dual-circuit state observer, Journal of Power Sources, Volume 296, 2015, Pages 23-29, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2015.07.028.

- [11] Mingheng Li, Li-ion dynamics and state of charge estimation, *Renewable Energy*, Volume 100, 2017, Pages 44-52, ISSN 0960-1481, doi.org/10.1016/j.renene.2016.06.009.
- [12] Languang Lu, Xuebing Han, Jianqiu Li, Jianfeng Hua, Minggao Ouyang, A review on the key issues for lithium-ion battery management in electric vehicles, *Journal of Power Sources*, Volume 226, 2013, Pages 272-288, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2012.10.060.
- [13] Wladislaw Waag, Stefan Käbitz, Dirk Uwe Sauer, Experimental investigation of the lithium-ion battery impedance characteristic at various conditions and aging states and its influence on the application, *Applied Energy*, Volume 102, 2013, Pages 885-897, ISSN 0306-2619, doi.org/10.1016/j.apenergy.2012.09.030.
- [14] Welch, Greg, and Gary Bishop. "An introduction to the Kalman filter." (1995).
- [15] Ting TO, Man KL, Lim EG, Leach M. Tuning of Kalman Filter Parameters via Genetic Algorithm for State-of-Charge Estimation in Battery Management System;2014; 2014.
- [16] M. Urbain, S. Rael, B. Davat and P. Desprez, "State Estimation of a Lithium-Ion Battery Through Kalman Filter," 2007 IEEE Power Electronics Specialists Conference, Orlando, FL, 2007, pp. 2804-2810, doi: 10.1109/PESC.2007.4342463.
- [17] M. W. Yatsui and H. Bai, "Kalman filter based state-of-charge estimation for lithium-ion batteries in hybrid electric vehicles using pulse charging," 2011 IEEE Vehicle Power and Propulsion Conference, Chicago, IL, 2011, pp. 1-5, doi: 10.1109/VPPC.2011.6042988.
- [18] Xiaosong Hu, Fengchun Sun, Yuan Zou, Comparison between two model-based algorithms for Li-ion battery SOC estimation in electric vehicles, *Simulation Modelling Practice and Theory*, Volume 34, 2013, Pages 1-11, ISSN 1569-190X, doi.org/10.1016/j.simpat.2013.01.001.
- [19] Z. Chen, Y. Fu and C. C. Mi, "State of Charge Estimation of Lithium-Ion Batteries in Electric Drive Vehicles Using Extended Kalman Filtering," in *IEEE Transactions on Vehicular Technology*, vol. 62, no. 3, pp. 1020-1030, March 2013, doi: 10.1109/TVT.2012.2235474.
- [20] Z. Zhu, J. Sun and D. Liu, "Online state of charge EKF estimation for LiFePO₄ battery management systems," 2012 International Symposium on Intelligent Signal Processing and Communications Systems, Taipei, 2012, pp. 609-614, doi: 10.1109/ISPACS.2012.6473562.
- [21] H. He, R. Xiong, X. Zhang, F. Sun and J. Fan, "State-of-Charge Estimation of the Lithium-Ion Battery Using an Adaptive Extended Kalman Filter Based on an Improved Thevenin Model," in *IEEE Transactions on Vehicular Technology*, vol. 60, no. 4, pp. 1461-1469, May 2011, doi: 10.1109/TVT.2011.2132812.
- [22] E. A. Wan and R. Van Der Merwe, "The unscented Kalman filter for nonlinear estimation," Proceedings of the IEEE 2000 Adaptive Systems for Signal Processing, Communications, and Control Symposium (Cat. No.00EX373), Lake Louise, Alberta, Canada, 2000, pp. 153-158, doi: 10.1109/ASSPCC.2000.882463.

- [23] Wei He, Nicholas Williard, Chaochao Chen, Michael Pecht, State of charge estimation for electric vehicle batteries using unscented kalman filtering, Microelectronics Reliability, Volume 53, Issue 6, 2013, Pages 840-847, ISSN 0026-2714, doi.org/10.1016/j.microrel.2012.11.010.
- [24] Fengchun Sun, Xiaosong Hu, Yuan Zou, Siguang Li, Adaptive unscented Kalman filtering for state of charge estimation of a lithium-ion battery for electric vehicles, Energy, Volume 36, Issue 5, 2011, Pages 3531-3540, ISSN 0360-5442, doi.org/10.1016/j.energy.2011.03.059.
- [25] Davis, Lawrence. "Handbook of genetic algorithms." (1991).
- [26] Yuejiu Zheng, Languang Lu, Xuebing Han, Jianqiu Li, Minggao Ouyang, LiFePO₄ battery pack capacity estimation for electric vehicles based on charging cell voltage curve transformation, Journal of Power Sources, Volume 226, 2013, Pages 33-41, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2012.10.057.
- [27] L. Chen et al., "A Novel State-of-Charge Estimation Method of Lithium-Ion Batteries Combining the Grey Model and Genetic Algorithms," in IEEE Transactions on Power Electronics, vol. 33, no. 10, pp. 8797-8807, Oct. 2018, doi: 10.1109/TPEL.2017.2782721.
- [28] Hao Mu, Rui Xiong, Hongfei Zheng, Yuhua Chang, Zeyu Chen, a novel fractional order model based state-of-charge estimation method for lithium-ion battery, Applied Energy, Volume 207, 2017, Pages 384-393, ISSN 0306-2619, doi.org/10.1016/j.apenergy.2017.07.003.
- [29] A. Affanni, A. Bellini, C. Concari, G. Franceschini, E. Lorenzani and C. Tassoni, "EV battery state of charge: neural network based estimation," IEEE International Electric Machines and Drives Conference, 2003. IEMDC'03., Madison, WI, USA, 2003, pp. 684-688 vol.2, doi: 10.1109/IEMDC.2003.1210310.
- [30] Wei He, Nicholas Williard, Chaochao Chen, Michael Pecht, State of charge estimation for Li-ion batteries using neural network modeling and unscented Kalman filter-based error cancellation, International Journal of Electrical Power & Energy Systems, Volume 62, 2014, Pages 783-791, ISSN 0142-0615, doi.org/10.1016/j.ijepes.2014.04.059.
- [31] M. A. Hannan, M. S. H. Lipu, A. Hussain, M. H. Saad and A. Ayob, "Neural Network Approach for Estimating State of Charge of Lithium-Ion Battery Using Backtracking Search Algorithm," in IEEE Access, vol. 6, pp. 10069-10079, 2018, doi: 10.1109/ACCESS.2018.2797976.
- [32] J. C. Álvarez Antón, P. J. García Nieto, C. Blanco Viejo and J. A. Vilán Vilán, "Support Vector Machines Used to Estimate the Battery State of Charge," in IEEE Transactions on Power Electronics, vol. 28, no. 12, pp. 5919-5926, Dec. 2013, doi: 10.1109/TPEL.2013.2243918.
- [33] Hanmin Sheng, Jian Xiao, Electric vehicle state of charge estimation: Nonlinear correlation and fuzzy support vector machine, Journal of Power Sources, Volume 281, 2015, Pages 131-137, ISSN 0378-7753, doi.org/10.1016/j.jpowsour.2015.01.145.
- [34] Xie, F., Wang, S., Xie, Y., Fernandezb, C., Li, X. and Zou, C., 2020. A Novel Battery State of Charge Estimation Based on the Joint Unscented Kalman Filter and Support Vector Machine Algorithms. Int. J. Electrochem. Sci, 15, pp.7935-7953, doi: 10.20964/2020.08.83

- [35] Adam J. Oliner, Anand P. Iyer, Ion Stoica, Eemil Lagerspetz, and Sasu Tarkoma. 2013. Carat: collaborative energy diagnosis for mobile devices. In Proceedings of the 11th ACM Conference on Embedded Networked Sensor Systems (SenSys '13). Association for Computing Machinery, New York, NY, USA, Article 10, 1–14, doi: 10.1145/2517351.2517354
- [36] Mohammad A. Hoque and Sasu Tarkoma. 2016. Characterizing smartphone power management in the wild. In Proceedings of the 2016 ACM International Joint Conference on Pervasive and Ubiquitous Computing: Adjunct (UbiComp '16). Association for Computing Machinery, New York, NY, USA, 1279–1286m doi: 10.1145/2968219.2968295
- [37] Wagner DT, Rice A, Beresford AR. Device analyzer. In Proc. HOTMOBILE 2011 12th Workshop on Mobile Computing Systems and Applications 2011.
- [38] Scrosati, Bruno & Garche, Juergen. (2010). Lithium Batteries: Status, Prospects and Future. *Journal of Power Sources*. 195. 2419-2430. 10.1016/j.jpowsour.2009.11.048.
- [39] https://batteryuniversity.com/learn/article/lithium_based_batteries
- [40] Α. Νταλαγιάννης και Κ. Φωτιαδάκης, "Μελέτη και κατασκευή φορτιστή συσσωρευτών ηλεκτροκίνητου οχήματος", Πάτρα: Πανεπιστήμιο Πατρών, 2016.
- [41] F. Baronti, G. Fantechi, E. Leonardi, R. Roncella and R. Saletti, "Hierarchical platform for monitoring, managing and charge balancing of LiPo batteries," 2011 IEEE Vehicle Power and Propulsion Conference, Chicago, IL, 2011, pp. 1-6, doi: 10.1109/VPPC.2011.6043074.
- [42] Mitchell, Tom. (1997). Machine Learning. McGraw Hill. p. 2. ISBN 0-07-042807-7.
- [43] Russell, Stuart; Norvig, Peter (Revision: 2003) [1995].
- [44] Gower, J. (1971). A General Coefficient of Similarity and Some of Its Properties. *Biometrics*, 27(4), 857-871. doi:10.2307/2528823
- [45] Peter J. Rousseeuw, Silhouettes: A graphical aid to the interpretation and validation of cluster analysis, *Journal of Computational and Applied Mathematics*, Volume 20, 1987, Pages 53-65, ISSN 0377-0427, doi:10.1016/0377-0427(87)90125-7.
- [46] Sokal, R., & Rohlf, F. (1962). The Comparison of Dendograms by Objective Methods. *Taxon*, 11(2), 33-40. doi:10.2307/1217208
- [47] Palacio-Niño, Julio-Omar, and Fernando Berzal. "Evaluation metrics for unsupervised learning algorithms." arXiv preprint arXiv:1905.05667 (2019).
- [48] Tan, P.N., Steinbach, M. and Kumar, V., 2016. Introduction to data mining. Pearson Education India.
- [49] Torgerson, W.S., 1952. Multidimensional scaling: I. Theory and method. *Psychometrika*, 17(4), pp.401-419.
- [50] Hoerl, A.E. and Kennard, R.W., 1970. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), pp.55-67.
- [51] Tibshirani, R., 1996. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), pp.267-288.

Βιβλιογραφία

- [52] Chen, T. and Guestrin, C., 2016, August. Xgboost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining (pp. 785-794).
- [53] A. Colin Cameron, Frank A.G. Windmeijer, An R-squared measure of goodness of fit for some common nonlinear regression models, Journal of Econometrics, Volume 77, Issue 2, 1997, Pages 329-342, ISSN 0304-4076, doi:10.1016/S0304-4076(96)01818-0. (page 329-330)
- [54] Saha, Biswajit. "Green computing." International Journal of Computer Trends and Technology (IJCTT) 14, no. 2 (2014): 46-50.